

Universidad Internacional de La Rioja

Escuela Superior de Ingeniería y Tecnología

Universidad de Alcalá

Escuela de Posgrado

Universidad Rey Juan Carlos

Escuela de Másteres oficiales

Máster Universitario en Inteligencia Artificial para el Sector de
la Energía y las Infraestructuras

**Comparativa del desempeño entre redes
neuronales recurrentes y modelos estadísticos
en la predicción del consumo energético en
Ecuador**

Trabajo fin de estudio presentado por:	Mendoza Pico, Erick Manuel
Tipo de trabajo:	Comparativa de soluciones
Director/a:	Alonso Rincón, Ricardo Serafín
Fecha:	23/07/25

Resumen

Ecuador depende en un 78 % de la generación hidroeléctrica, lo que lo hace altamente vulnerable ante fenómenos climáticos como El Niño. Esta vulnerabilidad afecta la planificación y operación del sistema eléctrico, especialmente cuando la demanda presenta comportamientos no lineales y difíciles de anticipar. Los enfoques tradicionales como ARIMA y SARIMA muestran limitaciones en estos contextos. El estado del arte evidencia un rezago en la adopción de modelos de inteligencia artificial en el país, pese a sus beneficios demostrados en otros sectores.

Este trabajo propone una metodología en seis etapas para predecir el consumo energético mensual en Ecuador entre 2014 y 2024. Se construye un conjunto de datos a partir de fuentes oficiales, se aplica un proceso de limpieza y normalización, y se comparan modelos estadísticos (ARIMA, SARIMA) con redes neuronales recurrentes (LSTM, BiLSTM).

Los resultados indican que el modelo LSTM desagregado alcanza la mayor precisión, con un RMSE de 68 GWh y un MAPE de 2.65 % bajo condiciones normales. Además, demuestra una mejor adaptación ante escenarios anómalos. Estas evidencias respaldan el uso de redes neuronales para fortalecer la planificación energética y aumentar la resiliencia del sistema eléctrico ecuatoriano.

Palabras clave: ARIMA, Consumo Eléctrico, LSTM, Planificación Energética, Predicción Energética, Redes Neuronales Recurrentes.

Abstract

Ecuador relies 78 % on hydroelectric generation, making it highly vulnerable to climate phenomena such as El Niño. This vulnerability affects the planning and operation of the electricity system, especially when demand exhibits nonlinear behaviors that are difficult to anticipate. Traditional approaches such as ARIMA and SARIMA show limitations in these contexts. The state of the art shows a lag in adoption of artificial intelligence models in the country, despite their proven benefits in other sectors.

This work proposes a six-stage methodology to predict monthly energy consumption in Ecuador between 2014 and 2024. A dataset is constructed from official sources, a cleaning and normalization process is applied, and statistical models (ARIMA, SARIMA) are compared with recurrent neural networks (LSTM, BiLSTM).

The results indicate that the disaggregated LSTM model achieves the highest accuracy, with an RMSE of 68 GWh and a MAPE of 2.65 % under normal conditions. Furthermore, it demonstrates improved adaptation to anomalous scenarios. These findings support the application of neural networks to enhance energy planning and increase the resilience of the Ecuadorian electricity system.

Keywords: Energy Forecasting, Recurrent Neural Networks, LSTM, ARIMA, Electricity Consumption, Energy Planning.

Índice de contenidos

1. Introducción	13
1.1. Motivación	13
1.2. Planteamiento del Trabajo	15
1.3. Estructura de la Memoria	16
2. Contexto y estado del arte	19
2.1. Problemática	19
2.2. Estado del Arte	24
2.2.1. Técnicas Estadísticas	27
2.2.2. Técnicas de Aprendizaje Automático (ML)	29
2.2.3. Otras técnicas	36
2.3. Conclusiones	38
3. Objetivos y Metodología de Trabajo	41
3.1. Objetivo General	41
3.2. Objetivo Específico	41
3.3. Metodología	42
3.3.1. Etapa 1: Recolección y análisis exploratorio de datos	42
3.3.2. Etapa 2: Preprocesamiento y estructuración del Dataset	44
3.3.3. Etapa 3: Implementación de modelos estadísticos	44
3.3.4. Etapa 4: Desarrollo de modelos de Redes Neuronales Recurrentes	44
3.3.5. Etapa 5: Evaluación comparativa y análisis de robustez	45
3.3.6. Etapa 6: Recomendaciones para la planificación energética	46
4. Desarrollo de la contribución	47
4.1. Etapa 1: Recolección y análisis exploratorio de datos	47

4.2.	Etapa 2: Preprocesamiento y estructuración del Dataset.....	51
4.3.	Etapa 3: Implementación de modelos estadísticos.....	52
4.3.1.	Implementación del modelo estadístico ARIMA	53
4.3.2.	Implementación del modelo estadístico SARIMA	63
4.4.	Etapa 4: Desarrollo de modelos de Redes Neuronales Recurrentes	67
4.4.1.	Implementación del modelo Long Short-Term Memory (LSTM)	67
4.4.2.	Implementación del modelo Bidirectional LSTM (BiLSTM)	72
4.5.	Etapa 5: Evaluación comparativa y análisis de robustez	76
4.5.1.	Comparación de Modelos.....	77
4.5.2.	Análisis de robustez ante eventos anómalos	78
4.5.3.	Conclusiones de la Evaluación	80
4.6.	Recomendaciones para la planificación energética	81
4.6.1.	Recomendaciones técnicas	82
4.6.2.	Recomendaciones operativas.....	82
4.6.3.	Recomendaciones estratégicas	83
5.	Conclusiones y Trabajo a Futuro	85
5.1.	Conclusiones.....	85
5.2.	Líneas Futuras.....	87
	Referencias bibliográficas.....	89
Anexo I.	Estructura del dataset energético consolidado.....	117
Anexo II.	Listado de Código	118
Anexo III.	Artículo	174

Índice de figuras

Figura 1.Composición de la generación eléctrica por fuente en Ecuador (Agencia de Regulación y Control de Electricidad (ARCONEL), 2023)	14
Figura 2. Enfoque metodológico propuesto para la predicción del consumo energético mediante técnicas estadísticas y redes neuronales (Fuente: Elaboración Propia).	15
Figura 3. Crecimiento de la demanda Energética a través del tiempo (Ember , Global Electricity Review, 2024).	20
Figura 4. Fuentes de generación de electricidad, América Central y del Sur (International Energy Agency (IEA), 2022).....	21
Figura 5. Producción bruta energética anual porcentual (Operador Nacional de Electricidad (CENACE), 2023).	23
Figura 6. Año de publicación de los diferentes modelos utilizados en planificación energética (Debnath y Mourshed, 2018).	26
Figura 7. Diagrama Esquemático de una Red Neuronal Artificial (Debnath y Mourshed, 2018).	29
Figura 8. Proceso de una Red Neuronal Artificial (Debnath y Mourshed, 2018).	30
Figura 9. RNN y LSTM comparativa (Kobiela et al., 2022).	32
Figura 10. Diagrama de la Metodología por etapas (Fuente: Elaboración propia).....	42
Figura 11. Consumo energético mensual total en Ecuador 2014-2024 (GWh) (Fuente: Elaboración Propia).	49
Figura 12. Consumo energético mensual por grupo de consumo en Ecuador 2014-2024 (GWh) (Fuente: Elaboración propia).	50
Figura 13. Metodología Box-Jenkins (Martínez-Álvarez et al, 2015).	53
Figura 14. Serie temporal diferenciada (Fuente: Elaboración Propia).	55
Figura 15. Gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF) (Fuente: Elaboración Propia).	55

Figura 16. Predicción del consumo energético con ARIMA (1,1,1) (Fuente: Elaboración Propia).	56
Figura 17. Predicción del consumo energético (2014-2024) con ARIMA (1,1,1) (Fuente: Elaboración Propia).	59
Figura 18. Predicción del consumo energético (2014-2023) con ARIMA Desagregado (Fuente: Elaboración Propia).	61
Figura 19. Predicción del consumo energético (2014-2024) con ARIMA Desagregado (Fuente: Elaboración Propia).	62
Figura 20. Predicción del consumo energético (2014-2023) con SARIMA Desagregado (Fuente: Elaboración Propia).	64
Figura 21. Predicción del consumo energético (2014-2024) con SARIMA Desagregado (Fuente: Elaboración Propia).	65
Figura 22. Predicción del consumo energético (2014-2023) con LSTM Desagregado (Fuente: Elaboración Propia).	70
Figura 23. Predicción del consumo energético (2014-2024) con LSTM Desagregado (Fuente: Elaboración Propia).	71
Figura 24. Predicción del consumo energético (2014-2023) con BiLSTM Desagregado (Fuente: Elaboración Propia).	74
Figura 25. Predicción del consumo energético (2014-2024) con BiLSTM Desagregado (Fuente: Elaboración Propia).	75

Índice de tablas

Tabla 1. Ventajas y Desventajas de los Métodos Simples (Fallah et al., 2018).....	34
Tabla 2. Ventajas y Desventajas de los Métodos Híbridos (Fallah et al., 2018).....	35
Tabla 3. Comparativa de herramientas de análisis de datos para la predicción del consumo energético (Fuente: Elaboración propia basada en Chollet (2021), Kelleher et al. (2020)).....	43
Tabla 4. Comparativa de herramientas para redes neuronales (Fuente: Elaboración propia basada en Chollet (2021), Kelleher et al. (2020)).....	45
Tabla 5. DataFrame Final después del preprocesamiento (Fuente: Elaboración Propia).....	52
Tabla 6. Resultados de la prueba ADF (Fuente: Elaboración Propia).....	54
Tabla 7. Métricas del Modelo ARIMA (Fuente: Elaboración Propia).	57
Tabla 8. Comparativas de las Métricas de los Modelo ARIMA (Fuente: Elaboración Propia).	58
Tabla 9. Métricas del Modelo ARIMA Desagregado (Fuente: Elaboración Propia).	61
Tabla 10. Comparativas de las Métricas de los Modelo ARIMA Desagregado (Fuente: Elaboración Propia).	62
Tabla 11. Métricas del Modelo SARIMA Desagregado (Fuente: Elaboración Propia).....	65
Tabla 12. Comparativas de las Métricas de los Modelo SARIMA Desagregado (Fuente: Elaboración Propia).	66
Tabla 13. Métricas del Modelo LSTM Desagregado (Fuente: Elaboración Propia).....	70
Tabla 14. Comparativas de las Métricas de los Modelo LSTM Desagregado (Fuente: Elaboración Propia).	72
Tabla 15. Métricas del Modelo BiLSTM Desagregado (Fuente: Elaboración Propia).....	74
Tabla 16. Comparativas de las Métricas de los Modelo BiLSTM Desagregado (Fuente: Elaboración Propia).	75
Tabla 17. Comparación de modelos predictivos del Año 2023 (Fuente: Elaboración Propia).	78
Tabla 18. Comparación de modelos predictivos del Año 2024 (Fuente: Elaboración Propia).	79

1. Introducción

El presente trabajo aborda la problemática de la predicción del consumo energético en Ecuador mediante un enfoque comparativo entre modelos estadísticos clásicos y redes neuronales recurrentes. A partir del análisis de datos históricos del período 2014–2024, se busca evaluar la precisión de diferentes técnicas de modelado en escenarios tanto normales como anómalos, con el fin de proponer herramientas más robustas para la planificación energética nacional. En la Sección 1.1 se presenta el contexto que motiva el estudio, en la Sección 1.2 se muestran los fundamentos teóricos y tecnológicos sobre los que se sustenta y en la Sección 1.3 se define el planteamiento general del trabajo y la estructura de la memoria técnica.

1.1. Motivación

La planificación energética constituye un proceso estratégico fundamental para garantizar la seguridad, sostenibilidad y eficiencia de los sistemas eléctricos, especialmente en países en desarrollo con alta dependencia de fuentes renovables sujetas a variabilidad climática (IEA, 2022).

En este contexto, el caso del Ecuador resulta particularmente desafiante: aproximadamente el 69 % de su matriz de generación eléctrica proviene de energía hidroeléctrica, como se muestra en la Figura 1, lo que convierte al sistema en altamente vulnerable ante fenómenos climáticos extremos como El Niño (SENPLADES, 2021). Esta dependencia estructural limita la capacidad de respuesta del sistema energético frente a crisis hídricas prolongadas, afectando tanto la oferta como la distribución de electricidad a nivel nacional (CEPAL, 2023).

En los últimos años, la creciente inestabilidad climática ha derivado en eventos de gran impacto, como la crisis energética de 2024, que provoca cortes prolongados del suministro en varias regiones del país (Ministerio de Energía y Minas, 2024). Este tipo de situaciones evidencia la necesidad urgente de contar con herramientas de pronóstico más precisas y robustas que permitan anticipar variaciones en la demanda y facilitar una respuesta oportuna por parte de los operadores del sistema (Faria y Vale, 2023).

Tradicionalmente, la predicción de la demanda energética se basa en modelos estadísticos lineales como ARIMA y SARIMA (Box et al., 2016). Si bien estos modelos presentan buen rendimiento bajo condiciones regulares, su desempeño se ve comprometido ante escenarios dinámicos y no lineales, como aquellos influenciados por estacionalidad climática, shocks económicos o eventos extremos (Contreras et al., 2003). En contraste, el desarrollo de algoritmos de aprendizaje profundo y la creciente disponibilidad de datos abren nuevas posibilidades para capturar patrones complejos en series temporales mediante técnicas como las redes neuronales recurrentes (RNN) (Hochreiter y Schmidhuber, 1997).




Figura 1. Composición de la generación eléctrica por fuente en Ecuador (Agencia de Regulación y Control de Electricidad (ARCONEL), 2023).

En particular, las redes LSTM (Long Short-Term Memory) y sus variantes bidireccionales (BiLSTM) han demostrado un rendimiento superior en la predicción de series temporales en sectores como energía, salud y finanzas (Kong et al., 2019). Sin embargo, en Ecuador su aplicación sigue siendo limitada debido a la escasez de estudios aplicados y a la baja incorporación de estas tecnologías en los sistemas de planificación energética (Carpio Suarez y Daga Lopez, 2019).

Una limitación adicional para el uso de modelos avanzados es la disponibilidad y calidad de los datos. Muchos registros oficiales presentan frecuencia mensual, cobertura geográfica limitada o inconsistencias estructurales (ARCONEL, 2023). Estas condiciones dificultan el entrenamiento efectivo de modelos de aprendizaje profundo, que requieren gran volumen y granularidad para su correcto ajuste (Runge y Zmeureanu, 2021). Por tanto, resulta crucial fortalecer la infraestructura de datos abiertos y estandarizados para fomentar la investigación e innovación tecnológica en el sector eléctrico nacional.

Por estas razones, se motiva el presente trabajo, que analiza comparativamente el desempeño de modelos estadísticos frente a redes neuronales recurrentes en la predicción del consumo energético mensual en Ecuador. El estudio evalúa el rendimiento bajo escenarios normales y anómalos, y propone recomendaciones para fortalecer la planificación energética basada en inteligencia artificial.

1.2. Planteamiento del Trabajo

Dado el contexto descrito, caracterizado por alta sensibilidad a la variabilidad climática, limitada precisión de modelos estadísticos y bajo aprovechamiento de técnicas de inteligencia artificial en Ecuador, el objetivo principal de este trabajo es desarrollar un estudio comparativo entre modelos estadísticos (ARIMA y SARIMA) y redes neuronales recurrentes (LSTM y BiLSTM), en la predicción del consumo energético mensual.




Figura 2. Enfoque metodológico propuesto para la predicción del consumo energético mediante técnicas estadísticas y redes neuronales (Fuente: Elaboración Propia).

El trabajo propone implementar y evaluar cuatro modelos: dos estadísticos clásicos: ARIMA y SARIMA y dos modelos de aprendizaje profundo: LSTM (*Long Short-Term Memory*) y BiLSTM (*Bidirectional LSTM*), con el fin de determinar cuál de ellos ofrece un mejor desempeño en la predicción del consumo energético mensual en Ecuador. La hipótesis de partida es que los modelos basados en RNN, por su capacidad de modelar dependencias temporales no lineales,

pueden superar significativamente a los modelos estadísticos en términos de precisión y robustez (G. Zhang et al., 1998).

Para ello, se utiliza un conjunto de datos históricos del consumo eléctrico nacional entre 2014 y 2024, recolectado a partir de reportes oficiales del sector eléctrico, que incluye información mensual por grupo de consumo y región geográfica. El enfoque metodológico, el cual se muestra en Figura 2, y se divide en seis etapas: recolección y análisis exploratorio de datos, preprocesamiento y estructuración del dataset, implementación de modelos estadísticos, desarrollo de modelos de redes neuronales, evaluación comparativa y análisis de robustez, y formulación de recomendaciones aplicadas a la planificación energética.

Adicionalmente, se incorpora un análisis específico de los modelos bajo condiciones normales (año 2023) y en escenarios anómalos (año 2024), con el objetivo de evaluar no solo la precisión general de cada modelo, sino también su capacidad de adaptación frente a eventos inesperados. De este modo, el trabajo no solo pretende validar la viabilidad de las redes neuronales recurrentes para la predicción energética en Ecuador, sino también generar conocimiento útil para el desarrollo de estrategias de planificación más resilientes y basadas en datos.

Como parte del enfoque metodológico adoptado, se ha documentado todo el código utilizado durante el desarrollo del trabajo, el cual se presenta íntegramente en el Anexo II. Asimismo, se publicará en un repositorio GitHub de acceso público para facilitar su verificación y reutilización por parte de investigadores o profesionales interesados.

Finalmente, este planteamiento se orienta a generar un aporte práctico en el campo de la inteligencia artificial aplicada al sector eléctrico ecuatoriano, demostrando cómo el uso de técnicas avanzadas de predicción puede aportar valor real a la toma de decisiones en contextos de alta incertidumbre.

1.3. Estructura de la Memoria

La presente memoria se estructura en seis Capítulos, cada uno de los cuales desarrolla una parte clave del trabajo. A continuación, se describe brevemente el contenido de cada uno:

- **Capítulo 1. Introducción:** Presenta la motivación del estudio, el planteamiento general del problema, los objetivos que guían la investigación y la estructura del documento.

Se contextualiza la necesidad de modelos predictivos precisos para el consumo energético en Ecuador y se introduce la propuesta metodológica general.

- **Capítulo 2. Contexto y estado del arte:** Describe la problemática energética en el país, con énfasis en la dependencia hidroeléctrica y la vulnerabilidad climática. Se realiza una revisión exhaustiva de las técnicas tradicionales y moderna de predicción energética, incluyendo modelos estadísticos, redes neuronales y enfoques híbridos, así como una síntesis de investigaciones relevantes a nivel nacional e internacional.
- **Capítulo 3. Objetivos y metodología de trabajo:** Detalla los objetivos general y específicos del estudio, y presenta la metodología adoptada. Se describen las seis etapas del proceso: recolección de datos, preprocesamiento, implementación de modelos estadísticos, desarrollo de modelos de redes neuronales, evaluación comparativa y formulación de recomendaciones.
- **Capítulo 4. Desarrollo de la contribución:** Expone el trabajo práctico realizado en cada etapa metodológica. Se incluyen la evaluación inicial de los datos para el análisis exploratorio, la preparación del dataset, la implementación de los modelos ARIMA, SARIMA, LSTM y BiLSTM, y los resultados obtenidos. Se documenta el rendimiento de cada modelo bajo condiciones normales y anómalas.
- **Capítulo 5. Conclusiones y trabajo a futuro:** Presenta las principales conclusiones del estudio, asociadas directamente con los objetivos planteados. Además, se proponen líneas de investigación futuras orientadas a mejorar los modelos desarrollados, superar las limitaciones detectadas y fomentar la aplicación de la inteligencia artificial en el sector energético.
- **Anexo I. Estructura del dataset energético consolidado:** Muestra un extracto del archivo consolidado utilizado como base para el análisis predictivo
- **Anexo II. Listado de Código:** Se presenta el código completo utilizado para el desarrollo del trabajo
- **Anexo III. Artículo:** Se muestran los artículos desarrollados como parte del Trabajo.

2. Contexto y estado del arte

En este Capítulo se presenta el análisis detallado de la problemática que motiva el presente trabajo, así mismo se lleva a cabo una revisión minuciosa del estado actual del arte, por último, se desarrolla un apartado de conclusiones donde se conecta la problemática y el estado del arte demostrando así la necesidad de resolver el problema. En la Sección 2.1 se profundiza en la problemática centrándose en los desafíos relacionados con la predicción del consumo energético en Ecuador, en la Sección 2.2 se desarrolla el estado del arte explorando los principales enfoques y modelos utilizados en la literatura para el pronóstico energético, se analiza desde métodos estadísticos tradicionales hasta técnicas avanzadas de aprendizaje automático y redes neuronales. Por último, en la Sección 2.3 se describen las conclusiones destacando la relevancia de las soluciones que se abordan en profundidad en este mismo Capítulo.

2.1. Problemática

La electricidad constituye un pilar esencial para el progreso económico y social de cualquier país. Jaramillo y Carrión (2022) destacan que la adecuada operación y gestión del Sistema Eléctrico de Potencia (SEP) resulta crucial para el crecimiento y la estabilidad de una nación. Así mismo indican que la planificación eficiente de su expansión permite a los gobiernos y a las empresas generadoras, mediante políticas energéticas, asegurar el suministro eléctrico necesario para satisfacer la demanda futura y alcanzar los objetivos del sector.

Por otro lado, Bedi y Toshniwal (2019) indican que el crecimiento económico y la evolución tecnológica impulsan un aumento considerable en el consumo de electricidad. Además, explican que este incremento se debe a factores como el crecimiento poblacional, la multiplicación de dispositivos inteligentes y la inclusión de vehículos eléctricos en el sistema de transporte.

En este sentido la Figura 3 muestra la evolución de consumo eléctrico global desde el año 2000 hasta el año 2023, la demanda eléctrica mundial casi se duplicó en las últimas dos décadas, pasando de 15 277 TWh en 2000 a 29 471 TWh en 2023. En gran parte se debe al crecimiento

económico de Asia, en donde la demanda eléctrica de Asia en 2023 fue casi tan alta como la demanda mundial total de electricidad en 2020.

Por ello, se sostiene que la capacidad de generación eléctrica de un país debe ser confiable y eficiente para responder a las necesidades de su economía. García (2021) destaca que una planificación energética adecuada implica evaluar el consumo actual y proyectar la demanda futura, considerando múltiples factores incluyendo aspectos políticos, económicos, sociales, ambientales y tecnológicos.




Figura 3. Crecimiento de la demanda Energética a través del tiempo (Ember , Global Electricity Review, 2024).

Debido a que la demanda eléctrica es un fenómeno dinámico sujeto a variaciones constantes resulta indispensable contar con modelos predictivos que permitan anticipar su comportamiento y optimizar la infraestructura del sistema eléctrico. Rafiq et al. (2023) enfatizan que esta demanda varía en función de numerosos factores lo cual exige metodologías precisas para su estimación en distintos horizontes temporales (corto, mediano y largo plazo).


En la investigación de Kang y Reiner (2022) se revisa cuáles son los efectos del clima en el consumo eléctrico doméstico, y se demuestra que la temperatura tiene efectos robustos y

relativamente estables en la demanda eléctrica, mientras que la lluvia y la intensidad del sol muestran un mayor potencial para afectar el comportamiento individual y las rutinas diarias.

De acuerdo con esto, Fikru y Gautier (2015) realizaron una investigación del impacto de la variación del clima en el consumo eléctrico en dos casas, la primera una casa convencional, y la segunda una casa solar neta con características de eficiencia avanzada, se concluye que la segunda casa es menos sensible a los cambios climáticos frente a la casa convencional. Además, sugieren que las variables no relacionadas con la temperatura, como la radiación solar y la humedad, afectan el uso de energía.

La Figura 4 muestra los porcentajes de aportes de las distintas fuentes de generación eléctrica en América Central y del Sur, la *International Energy Agency* (IEA) indica que el 54 % de la generación en esta región proviene de una fuente hidroeléctrica, además de los aportes de generación de las demás fuentes renovables, se constituye como una región con gran dependencia de fuente de recursos con incertidumbre climática.

Electricity generation sources, Central & South America, 2022



Source: International Energy Agency. Licence: CC BY 4.0

Figura 4. Fuentes de generación de electricidad, América Central y del Sur (*International Energy Agency* (IEA), 2022).

Zalakeviciute et al. (2024) indican que la grave sequía acentuada por el fenómeno de El Niño, que normalmente reduce las precipitaciones y aumenta las temperaturas en la región ha provocado niveles récord bajos en el río Amazonas y su cuenca, lo que ha afectado al transporte, las comunidades, la vida silvestre y, fundamentalmente, la producción de energía hidroeléctrica, de la misma forma afirman que en países como Brasil en donde existe un 80 % de dependencia hidroeléctrica, Colombia con un 79 % de dependencia, Venezuela un 68 %,

Bolivia un 32 % y finalmente Perú y Ecuador con un 55 % de dependencia, por lo que se afirma que, la hidroelectricidad es una fuente de energía clave.

En Ecuador la crisis energética representa un desafío significativo en su crecimiento económico y social, de esta manera, Jason y Erick (2025) afirman que en las últimas décadas, la demanda energética ha experimentado un crecimiento debido al incremento de la población y al desarrollo industrial, poniendo a prueba la capacidad de generación eléctrica del país, además, las limitaciones en infraestructura y la falta de diversificación de fuentes de energía han derivado en problemas de suministro y altos costos de operación de importación de combustibles fósiles para suplir la necesidad.

En este contexto, la investigación y el desarrollo de modelos avanzados de predicción del consumo eléctrico se plantea como una necesidad clave para mejorar la planificación energética y ajustar las proyecciones de demanda con mayor precisión.

La predicción de acontecimientos ha creado un gran interés al ser humano desde tiempos antiguos, Chong y Aguilar (2016) mencionan que el primer registro que se tiene de una predicción se le adjudica a Thales de Mileto, quien realizó la predicción de que el 28 de mayo de 585 a.C. sucediera lugar un eclipse solar, lo cual se convirtió en una base cronológica de eclipses documentadas por los astrónomos.. Este hallazgo demuestra que por naturaleza la humanidad se ha fascinado por la predicción de eventos, y esto toma mayor relevancia debido a lo crítico que puede ser una correcta planificación en el sector energético.

Una herramienta esencial en la planificación energética es la previsión de la demanda de electricidad a corto, mediano y largo plazo. Bai et al. (2022) indican que esta permite que los nuevos usuarios de la red eléctrica cumplan con sus necesidades energéticas lo que se transmite en el correcto desarrollo económico y social del sector, permitiendo que los grandes consumidores de electricidad como las industrias generen nuevos empleos.

Sin embargo, entre los diferentes tipos de previsión de la demanda de electricidad, Gao et al. (2022) mencionan que el más importante y utilizado es la planificación a mediano plazo, que facilita herramientas para la expansión del sistema de transmisión y medidas políticas inteligentes de consumo eléctrico para el usuario (planes tarifarios y políticas de incentivos para el ahorro energético).

Considerando el contexto energético ecuatoriano, la planificación energética adquiere una importancia estratégica cuya matriz energética depende en gran medida de la generación hidroeléctrica. Esta dependencia lo hace particularmente vulnerable a fenómenos climáticos como El Niño que en años recientes han afectado severamente la capacidad de generación eléctrica provocando cortes de energía prolongados en distintas regiones del país. Frente a esta situación se vuelve crucial no solo prever los posibles escenarios de escasez sino también anticipar con precisión la evolución del consumo eléctrico en distintos sectores y regiones. La Figura 5 muestra la participación de las distintas fuentes de generación de electricidad, en donde se afirma la dependencia hidro energética de Ecuador, el operador CENACE el cual ostenta el control operativo del Sistema Eléctrico Nacional, indica que en 2023 la generación hidroeléctrica constituye un 78 % de la producción energética anual.

Si bien existen esfuerzos institucionales para anticipar el comportamiento de la demanda energética estas predicciones no siempre logran capturar la complejidad dinámica de los patrones de consumo en el país. Esta situación genera desafíos significativos para la planificación energética especialmente en contextos de incertidumbre climática o cambios económicos abruptos. En este contexto se plantea la necesidad de explorar enfoques alternativos que permitan una predicción más precisa adaptable y robusta del consumo eléctrico particularmente en escenarios donde los modelos convencionales tienden a perder precisión.




Figura 5. Producción bruta energética anual porcentual (Operador Nacional de Electricidad (CENACE), 2023).

A partir de esta problemática, el presente estudio se enfoca en evaluar qué tan eficaces son los modelos de inteligencia artificial frente a los métodos tradicionales en la predicción de la demanda eléctrica en Ecuador. La intención es generar evidencia que respalde el uso de tecnologías más avanzadas en la planificación energética especialmente en un contexto donde la incertidumbre climática y la volatilidad del consumo exigen herramientas predictivas más dinámicas y precisas.

En particular, este estudio se centrará en comparar el desempeño de modelos tradicionales (como ARIMA) frente a modelos de inteligencia artificial (como redes neuronales recurrentes) utilizando datos históricos del consumo eléctrico en Ecuador. La hipótesis es que los modelos basados en aprendizaje profundo pueden superar en precisión a los métodos convencionales especialmente en series temporales con comportamientos no lineales o altamente variables.

Esta comparación no solo busca determinar cuál modelo ofrece mejores resultados en términos de precisión sino también aportar evidencia que permita fortalecer los procesos de planificación energética en Ecuador. En un país altamente dependiente de la hidroelectricidad y vulnerable a eventos climáticos extremos, anticipar de manera confiable la demanda energética representa una necesidad estratégica.

2.2. Estado del Arte

La predicción de demanda energética ha evolucionado desde modelos estadísticos univariantes hasta técnicas avanzadas de inteligencia artificial. En la Sección 2.2.1 se desarrolla los métodos clásicos los cuales incluyen enfoques tradicionales como ARIMA, la Sección 2.2.2 trata sobre el aprendizaje automático en donde se mencionan los modelos no lineales como las redes neuronales, por último, la Sección 2.2.3 explica las técnicas complementarias donde se analizan métodos híbridos y emergentes. El análisis sigue un criterio cronológico y de complejidad creciente, priorizando aquellos modelos con potencial para abordar la volatilidad climática del contexto ecuatoriano descrita en la Sección 2.1. Adicionalmente, se identifican brechas metodológicas relevantes para la planificación energética en sistemas altamente dependientes de hidroelectricidad.

Los esfuerzos de las políticas energéticas actuales buscan una transición del clásico sistema energético hacia uno fiable, ecológico y rentable. Para lograrlo la forma en que se modelan los sistemas energéticos cumple un papel importante dentro de los procesos de planificación

estructuras de los sistemas eléctricos. L. Bai et al. (2016) indican que los modelos energéticos se expanden a múltiples infraestructuras lo que los convierte en modelos cada vez más detallados y complejos, que permiten modelar con mayor precisión las características de los sistemas. De acuerdo con esto, Lopion et al. (2018) precisan que una información fundamentada correctamente acerca de la demanda energética futura es uno de los insumos con mayor importancia en este contexto.

Los procesos de toma de decisiones se ven directamente afectados por las predicciones, Verwiebe et al. (2021) concuerdan y mencionan que dentro de los elementos involucrados se encuentra la operación de la red en tiempo real, así como la planificación a largo plazo de la ampliación de la infraestructura.

En consecuencia, se genera la necesidad de utilizar modelos de predicción con gran porcentaje de confiabilidad que predigan y simulen la demanda energética o consumo de energía, dado la importancia de este, el modelado de la demanda energética es la base esencial para todos los posibles escenarios entorno al consumo energético.

Hong y Fan (2016) afirman que existe todo un campo de investigación que gira en torno a definir como modelar la demanda de energía eléctrica utilizando diferentes enfoques, diferentes escalas, visto desde lo global o desde un solo punto como un electrodoméstico.

En esta línea, Debnath y Mourshed (2018) indican que la cantidad de información sobre el tema a lo largo del tiempo se ha incrementado. En 2009, existían alrededor de 60 artículos en inglés indexados en "*Web of Science*" los cuales incluían "*energy demand*" y "*model*" en su título. Hasta el año 2020 la cifra se encontraba en 641 artículos, demostrando así el interés por el tema.

En este sentido, la Figura 6 muestra que los métodos de inteligencia computacional en los últimos años han progresado significativamente., mientras que los métodos estadísticos muestran un descenso gradual desde 2010.

Las aplicaciones para los modelos de demanda energética son variadas, pueden abarcar desde la previsión del consumo energético a corto plazo en redes y mercados eléctricos, simulación de las cargas de calor y electricidad en los edificios, hasta proyecciones econométricas a largo plazo (Verwiebe et al., 2021).

Dentro de la literatura científica se distinguen diversas clasificaciones de técnicas para modelar el consumo energético. Debnath y Mourshed (2018) diferencian entre técnicas estadísticas, inteligencia computacional (*computational intelligence*, CI) y programación matemática, a su vez las técnicas pueden ser independientes e híbridas. Dentro de la categoría técnicas estadísticas, definen la regresión, el análisis de series temporales (*time series análisis*, TSA) y las técnicas de heterocedasticidad condicional autorregresiva (*autoregressive conditional heteroscedasticity*, ARCH). Dentro de la categoría de inteligencia computacional se menciona el aprendizaje automático (*machine learning*, ML), la incertidumbre y las técnicas metaheurísticas, así como métodos basados en expertos.

Por otra parte, Hong y Fan (2016) definen solo dos categorías generales de técnicas estadísticas e inteligencia artificial: la primera incluye la regresión lineal múltiple y las técnicas de TSA, y la segunda, las ANN (Redes Neuronales), la regresión difusa, las máquinas de vectores de soporte (SVM) y las máquinas de impulso de gradiente.




Figura 6. Año de publicación de los diferentes modelos utilizados en planificación energética (Debnath y Mourshed, 2018).

Mientras que Wei et al. (2019) diferencian entre técnicas convencionales, como el TSA, la regresión y los modelos grises, y técnicas de inteligencia artificial, como las ANN y SVM. Con el aporte de los autores, se definen cinco categorías: estadísticas, aprendizaje automático, metaheurísticas, estocásticas/difusas/grises y técnicas basadas en ingeniería.

2.2.1. Técnicas Estadísticas

Los primeros enfoques para predecir demanda energética se basaron en modelos estadísticos univariantes. Entre ellos, destacan técnicas de regresión y TSA, generalmente utilizadas en econometría para explorar la interrelación entre la demanda energética y el desarrollo económico. De acuerdo con Fallah et al. (2018) las técnicas de regresión son usadas para la resolución de problemas de regresión subyacentes los cuales consisten en encontrar una aproximación de la relación funcional entre variables numéricas de entrada y salida, para encontrar la solución se emplean diferentes métodos, comúnmente se utiliza la suma de los cuadrados de los errores. En este contexto, Huang et al. (2019) afirman que para relaciones lineales se puede realizar el método de mínimos cuadrados ordinarios, para relaciones no lineales se utilizan métodos de descenso más pronunciados o funciones de kernel.

Las técnicas de TSA llevan a cabo sus proyecciones a partir de una serie histórica de datos de consumo energético. Numerosos métodos de TSA son modelos de regresión, donde el valor estimado se calcula basándose en uno o varios valores anteriores. Esta clase abarca modelos de series de tiempo univariados. Ye et al. (2019) describe modelos de media móvil autorregresiva (ARMA), junto con otras técnicas frecuentemente utilizadas como los modelos de media móvil integrada autorregresiva (ARIMA) para series de tiempo no estacionarias, los modelos de media móvil integrada autorregresiva estacional (SARIMA) para la estacionalidad y los modelos ARMA con variables exógenas (ARMAX).

Los modelos de series temporales son los más sencillos para el análisis de tendencias en el pronóstico energético. Barak y Sadegh (2016) afirman que algunos enfoques de series temporales, como los modelos estadísticos habituales, entre ellos, la media móvil, el suavizado exponencial y ARIMA, son métodos de pronóstico lineal.

A principios de los años 70, George Box y Gwilym Jenkins desarrollaron el Modelo Autorregresivo Integrado y de Promedio Móvil (ARIMA) para la predicción. En el modelo

ARIMA, el valor estimado de una variable es una combinación lineal de los valores y errores pasados.

Camara et al. (2016) indica que, normalmente, el procedimiento de pronóstico se realiza después de modelar las series temporales. La metodología *Box-Jenkins* es una metodología popular para modelar y pronosticar series temporales, y en particular el modelo ARIMA, consta de estos pasos: identificación del modelo, evaluación de parámetros y pruebas de diagnóstico. Los términos autorregresivos (AR) y los términos de media móvil (MA) constituyen las dos partes de la ecuación en el enfoque ARIMA.

El modelo ARIMA es uno de los modelos de series temporales más populares y se ha utilizado ampliamente. Pappas et al. (2008) proponen el modelo ARIMA para pronosticar el consumo de electricidad en Grecia y lo compararon con tres modelos analíticos de series temporales. Los resultados mostraron que el modelo ARIMA es más eficiente que otros modelos de series temporales. Sin embargo, los métodos de pronóstico estadístico generalmente requieren datos normales, mientras que los grandes conjuntos de datos con patrones de tendencia o estacionales suelen ser inadecuados o ruidosos. Es decir, los modelos ARIMA son lineales, a diferencia de las series temporales reales, las cuales normalmente no tienen una estructura lineal.

Zhuang et al. (2022) indican que el uso de series temporales destaca entre las demás metodologías en la predicción energética, estas plantean el uso de diversos modelos matemáticos capaces de describir un conjunto de datos con precisión y posteriormente generar predicciones sobre ellos. Adicional a esto, Mir et al. (2020) determinan que los modelos más comunes y utilizados son los modelos autorregresivos (*auto-regressive*, AR), los modelos de media móvil (*moving average*, MA), los modelos autorregresivos y de media móvil (*auto-regressive and moving average*, ARMA), los modelos autorregresivos y de media móvil integrales (*autoregressive and moving average integral models*, ARIMA).

La demanda energética se pronostica normalmente en base a índices económicos y no económicos. Como consecuencia, Azadeh et al. (2008) afirman que la no linealidad de estos índices y la demanda energética han promovido la búsqueda de enfoques de inteligencia artificial como son las redes neuronales o los modelos difusos.

2.2.2. Técnicas de Aprendizaje Automático (ML)

Ante las limitaciones de los modelos estadísticos, el auge de la inteligencia artificial permitió desarrollar técnicas no lineales. En esta subsección se analizan una amplia variedad de aplicaciones en el modelado y la predicción del consumo energético y generalmente se dividen en dos clases: aprendizaje supervisado y aprendizaje no supervisado.

Las orientaciones de aprendizaje supervisado usan conjuntos de datos de entrenamiento etiquetados con el fin de derivar una función que describe una correspondencia entre entradas y salidas basándose en ejemplos de pares de entrada-salida. Shaffer et al. (2016) indica que esta metodología se puede aplicar a variables numéricas en casos de regresión y a variables categóricas en caso de problemas de clasificación.

Además, los autores Alamaniotis et al. (2016) definen una serie de técnicas frecuentemente utilizadas, como lo son, las redes neuronales artificiales (ANN), y los algoritmos basados en instancias, como las máquinas de k-vecinos más cercanos (*k-nearest neighbor*) y las máquinas kernel.

Como afirman Song et al. (2017), un ejemplo de la utilización de las máquinas kernel, son las máquinas de modelado de secuencias (SVM) las cuales convierten los problemas no lineales en un espacio de baja dimensión, en problemas lineales en un espacio de alta dimensión. Además, en esta clase se incluyen árboles de decisión, algoritmos bayesianos y enfoques de aprendizaje por conjuntos, como las máquinas de gradiente boosting.




Figura 7. Diagrama Esquemático de una Red Neuronal Artificial (Debnath y Mourshed, 2018).

Por otra parte, Brownlee (2016) menciona que los enfoques de aprendizaje no supervisados se emplean con frecuencia en problemas de agrupamiento, estos algoritmos deducen las

estructuras en un conjunto de datos de entrada no etiquetados, por ejemplo, mediante la búsqueda de similitudes.

En los últimos años, las ANN han crecido considerablemente dentro del ámbito de la predicción de series temporales debido a su idoneidad inherente para tareas de modelado de secuencias (Alizadegan et al., 2025).

Para ejemplificar las redes neuronales recurrentes (ANN) se puede recurrir a las redes neuronales artificiales como se muestra en la Figura 7 cual muestra un diagrama esquemático de la arquitectura de una red neuronal de propagación hacia adelante. Las RNN tienen tres capas: entrada, oculta y salida. En la Figura 7 solo se muestra una capa oculta y el número puede ser mayor dependiendo de la complejidad del problema analizado. Cada neurona está conectada a todas las demás neuronas de la capa anterior mediante un peso sináptico adaptable. A su vez, la Figura 8 muestra el proceso de una RNN simplificado, para entrenar las RNN, se lleva a cabo un proceso de entrenamiento modificando los pesos de conexión, que se ajustan para producir los resultados deseados.




Figura 8. Proceso de una Red Neuronal Artificial (Debnath y Mourshed, 2018).

Dentro de las predicciones de series temporales se encuentra las redes LSTM (*long short-term memory* o memoria a corto-largo plazo) las cuales son una variante de las ANN, por ejemplo, Gundu y Simon (2021) formularon un modelo LSTM para la predicción del precio de la electricidad, aprovechando la optimización por enjambre de partículas (PSO).

Abbasimehr et al. (2020) desarrollaron un modelo LSTM apilado optimizado para la predicción de la demanda en una empresa de muebles, superando los modelos de referencia convencionales. De forma similar, Fischer y Krauss (2018) investigaron el rendimiento de las redes LSTM en la previsión de mercados financieros, manifestando su superioridad sobre los métodos clásicos.

Law et al. (2019) plantearon un marco de aprendizaje profundo aplicado a la previsión de la demanda turística. Sumado a esto, Kulshrestha et al. (2020) presentaron un modelo combinado que contempla LSTM bidireccional y optimización bayesiana (BO) para la previsión de la demanda turística, revelando un rendimiento mejorado en comparación con métodos clásicos como la regresión de vectores de soporte (SVR), las redes neuronales de función de base radial (RBFNN) y el modelo autorregresivo de rezagos distribuidos (ADLM).

Da Silva y Meneses (2023) compararon dos modelos de aprendizaje profundo, LSTM y LSTM bidireccional (Bi-LSTM), para la predicción univariante del consumo eléctrico a corto plazo en varios conjuntos de datos. La evidencia estadística, mostro que Bi-LSTM supera significativamente a LSTM.

Además los modelos híbridos RLMD Bi-LSTM mostrados por Singla et al. (2023) el cual integra RLMD y LSTM bidireccional, mejoró significativamente el RMSE y el MAE, superando a los modelos tradicionales y basados en RLMD para las predicciones a corto plazo en Hisar y Jaipur.

Los estudios indican que la tendencia de investigación se dirige a los métodos de Redes Neuronales Recurrentes como las LSTM para predicción de series temporales, y en general los métodos que impliquen inteligencia artificial se encuentran en auge por encima de los métodos clásicos, fundamentado en la optimización de resultados.

Por ejemplo, Alizadegan et al. (2025) compara los métodos LSTM, Bi-LSTM y métodos tradicionales, demostraron que sus modelos LSTM y Bi-LSTM para el pronóstico preciso de series temporales obtuvieron resultados que superan a todos los métodos de evaluación comparativos en términos de error absoluto medio (MAE). En concreto, el error cuadrático medio (RMSE) de Bi-LSTM es un 5.35 %, un 46.08 % y un 50.6 % inferior al de LSTM, ARIMA y SARIMA, respectivamente, en una parte de sus datos.

La Figura 9 muestra la comparación de una unidad de una RNN clásica frente a una LSTM, estas últimas son capaces de aprender dependencias a largo plazo mediante un mecanismo llamado puertas, que son diferentes operaciones tensoriales que pueden aprender qué información añadir o eliminar del estado oculto.

Aristizábal (2024) realiza un análisis comparativo para proporcionar predicciones precisas del índice bursátil utilizando variables exógenas, se utilizan los métodos ARIMA, SARIMAX y LSTM, dentro de sus conclusiones determinan que el modelo ARIMA muestra limitaciones en

términos de precisión, el modelo SARIMAX mejoró significativamente la precisión respecto al modelo ARIMA, sin embargo el modelo LSTM demostró ser el más efectivo, su arquitectura de redes neuronales recurrentes permite una modelación flexible y precisa, superando significativamente los resultados en términos de precisión y ajuste a sus rivales.




Figura 9. RNN y LSTM comparativa (Kobiela et al., 2022).

Otra investigación realizada por Menacho Chiok (2014) comparó los resultados de métodos estadísticos clásicos aplicados al análisis de series de tiempo, el análisis se realizó con 8 series de tiempo, en donde los resultados de los modelos de redes neuronales tuvieron menores valores de MAPE en las 8 series y menores valores de MAD y MSE en 4 de las series de tiempo analizadas.

Siarni-Namini et al. (2019) realizó una comparación entre los modelos ARIMA, LSTM y modelos LSTM Bidireccionales (BiLSTMs), la pregunta que se propuso en la investigación se centró en si el entrenamiento de datos en dirección opuesta (es decir, de derecha a izquierda) incluyendo el entrenamiento regular (es decir, de izquierda a derecha) tuvo beneficios en la mejora de la precisión del pronóstico de series temporales. Los resultados mostraron que el uso de una capa adicional de entrenamiento ayudaría a mejorar la precisión del pronóstico en un 37.78 % en promedio, lo que resulta útil para el modelado.

Jaramillo et al. (2022) indican que, en los últimos años, se han utilizado metodologías de aprendizaje automático como redes neuronales y redes neuronales profundas para estudiar y resolver problemas relacionados con los sistemas eléctricos, entre los que se incluyen la predicción de datos y el modelado de la conducta de los sistemas. Con el apogeo del

aprendizaje automático y las técnicas de inteligencia artificial se han aplicado nuevas técnicas para la predicción de series temporales en la previsión del consumo energético.

En esa línea, se ha comprobado que el uso de Inteligencia Artificial con sus aplicaciones como el aprendizaje automático o las redes neuronales puede superar a las metodologías tradicionales en escenarios que involucran series temporales impredecibles o inusuales, como lo mencionan Mañay Chochos et al. (2022).

Así mismo, Sachin et al. (2020) describen en su investigación, utilizando datos de medidores inteligentes en Londres, que la metodología ARIMA demuestra un buen rendimiento en pronóstico a corto plazo, sin embargo, a medida que aumenta el tiempo, el rendimiento de ARIMA cae por debajo de los demás modelos, ANN y LSTM demostraron un rendimiento comparable al de ARIMA en predicciones a corto plazo y superando a todos los demás modelos en predicciones a mediano y largo plazo, concluyendo así que estas metodologías son capaces de pronosticar el consumo eléctrico con alta precisión.

Además, Mpawenimana et al. (2020) proponen un sistema que pueda predecir una carga energética diaria futura en un hogar inteligente utilizando modelos LSTM y ARIMA, se comparan los métodos a corto y mediano plazo, y en todos los casos los resultados muestran que LSTM supera a ARIMA, y se estimó que el modelo LSTM predice con una precisión de 80 %.

Panklib et al. (2015) proponen una red neuronal artificial (RNN) y modelos de regresión que se emplean para la predicción de la demanda de electricidad a largo plazo en Tailandia. Se determinó que la RNN proporciona resultados más precisos en balance con los modelos de regresión. El estudio propuso como métrica de validación del modelo los resultados reales de los años 2010, 2015 y 2020. Para ello la red neuronal se entrenó con datos de 1989 a 2008 obteniendo como resultado la predicción anual la cual presentó un error del 1.82 %.

Yu et al. (2015) utilizan un modelo híbrido auto adaptativo de optimización de enjambre de partículas y algoritmo genético para predecir la demanda de electricidad en Wuhan, China en este estudio se toma como datos conocidos el consumo de electricidad en dicha región entre 1990 y 2013 tras lo cual se predice la demanda de electricidad para el período 2014-2020.

Günay (2016) predice el consumo de electricidad anual en Turquía basándose en datos históricos entre 1975 y 2013 obteniendo valores de pronóstico de la demanda de electricidad

para el período 2014-2028 en este trabajo se utiliza modelos de regresión lineal junto con redes neuronales artificiales, se evalúa el error del modelo antes de la predicción (error inferior al 5 %).

Marwala y Twala (2014) muestran un modelo ARMA que utiliza en combinación redes neuronales y sistemas neuro difusos. El escenario de estudio utilizado fue la demanda de electricidad en Sudáfrica entre 1985 y 2011. Los resultados de este trabajo generaron valores de error de hasta el 13.5 %.

Pierre et al. (2023), concluye que el enfoque híbrido ARIMA-LSTM obtuvo mejores rendimientos de predicción de consumo energético, con un error cuadrático medio (RMSE) de 7.35 frente al enfoque híbrido ARIMA-GRU el cual obtuvo 9.6 en RMSE. Concluyen que los enfoques híbridos superan a los enfoques individuales, como GRU, LSTM y ARIMA.

Tabla 1. Ventajas y Desventajas de los Métodos Simples (Fallah et al., 2018).

Tipos	Método	Ventajas	Desventajas
Método simple	FL (Lógica Difusa)	Toma de decisiones con información incierta	Inconveniente de incertidumbres cognitivas
	ANN (Red Neuronal)	Aprendizaje no supervisado	Sobreajuste (<i>overfitting</i>)
	SVM (Máquinas de Vectores de Soporte)	Minimización del riesgo estructural	Incertidumbre de parámetros
	GP (Programación Genética)	Búsqueda óptima	Falta de memoria
	PSO (Optimización por Enjambre de Partículas)	Almacenamiento de memoria	Inconveniente de mínimos locales
	NF (Red Neuronal Difusa)	Caracterización de datos	Número óptimo de clústeres desconocido

En la Tabla 1 se muestran las ventajas y desventajas de los métodos simples, mientras que en la Tabla 2 se muestran las ventajas y desventajas de los métodos híbridos, esto sirve para contrastar las opciones, ya que ningún método es perfecto para generalizar todas las

aplicaciones, pero cada método tiene ventajas en aplicaciones específicas según sus características.

Aunque los estudios antes mencionados fueron realizados en países con características de consumo energético diferentes como Sudáfrica o Tailandia, sus resultados ofrecen lecciones importantes sobre cómo las técnicas avanzadas pueden ser aplicadas en el contexto ecuatoriano especialmente si se considera la dependencia Hidroeléctrica de Ecuador. Dada dicha dependencia y la vulnerabilidad a fenómenos climáticos como El Niño el uso de modelos avanzados de predicción puede proporcionar una ventaja importante al prever la demanda y ajustar la planificación energética en tiempo real.

Tabla 2. Ventajas y Desventajas de los Métodos Híbridos (Fallah et al., 2018).

Tipos	Método	Ventajas	Desventajas
Método híbrido	ANN + <i>k-shape clustering</i>	Extracción de características mediante procedimiento no supervisado	Número óptimo de clústeres desconocido
	ANN-WT (ANN + Transformed Wavelet)	Selección de entrada	Solo resolución en frecuencia
	SVM-FOA	Algoritmo de búsqueda rápida	Arquitectura complicada
	SVM-HS (SVM + <i>Harmony Search</i>)	Adecuado para muestras pequeñas y mayor velocidad de cálculo	Arquitectura complicada

Estos modelos de predicción ya son fuente de investigación en Ecuador, Chicaiza Yugcha et al. (2024) prevén el consumo eléctrico en el cantón Salcedo, utilizando técnicas de aprendizaje automático (Random Forest y XGBoost) para pronosticar 6 parroquias con datos desde el 2017 hasta el 2022, utilizando RMSE y MAPE como métricas determinaron que el modelo Random Forest obtuvo datos con mayor eficacia en la previsión de la demanda.

De manera similar, Guamán et al. (2025) indican que los modelos econométricos tradicionales utilizados en Ecuador a menudo no logran predecir con precisión la demanda de electricidad

a largo plazo debido a su incapacidad para adaptarse a la naturaleza dinámica del consumo energético, este estudio emplea un modelo Perceptrón Multicapa (MLP), integrado con predicciones de Redes Neuronales Autorregresivas No Lineales de población, producto interno bruto, acceso a la electricidad y población urbana, para pronosticar la demanda de electricidad de Ecuador entre 2023 y 2050. El análisis comparativo muestra que el modelo MLP supera significativamente a otros modelos de aprendizaje automático, como las Máquinas de Vectores de Soporte y la Regresión Lineal Robusta, demostrando menores errores de predicción y mayor precisión. El estudio revela que el consumo de electricidad en Ecuador podría oscilar entre 38.74 TWh y 62.1 TWh entre 2023 y 2050, lo que subraya el potencial de las redes neuronales avanzadas para mejorar la confiabilidad de la previsión de la demanda de electricidad en los países en desarrollo.

Estas investigaciones reafirman la importancia de utilizar ANN para la predicción de series temporales con características volátiles, frente a los métodos tradicionales, sin la necesidad de excluirlos totalmente, debido a que, todos los enfoques presentan herramientas útiles que utilizados correctamente mejoraran la metodología.

2.2.3. Otras técnicas

La combinación de métodos clásicos y de IA ha generado enfoques híbridos que superan las limitaciones individuales. A continuación, se exploran algunos de los modelos más influyentes.

Las técnicas metaheurísticas se utilizan frecuentemente para resolver problemas de optimización y pueden incorporarse a otras técnicas para mejorar el rendimiento. Fallah et al. (2018) menciona que esta categoría incluye algoritmos evolutivos, que imitan mecanismos inspirados en procesos biológicos, como la reproducción, la mutación, la recombinación y la selección. Además, incluye algoritmos genéticos, optimización de enjambres de partículas, optimización de colonias de abejas, algoritmos de luciérnagas y más.

De acuerdo con esto, Al-Shammari et al. (2016) indican que en combinación con enfoques de aprendizaje automático (ML), pueden emplearse para la optimización de parámetros en SVM, o la optimización de pesos en ANN, dando lugar a enfoques como la red neuronal con el algoritmo de luciérnagas. Los algoritmos genéticos también se utilizan para la selección de características en enfoques de aprendizaje automático.

Las técnicas de la teoría de sistemas estocásticos, difusos y grises se utilizan para modelar diferentes tipos de incertidumbre. Zimmermann (2012) describe dos formas básicas de incertidumbre: la lógica tradicional de la probabilidad describe la aleatoriedad en la ocurrencia de un evento, mientras que la imprecisión describe la ambigüedad de un evento, es decir, en qué medida ocurre.

Hajek et al. (2013) señalan que la probabilidad y la lógica difusa representan diferentes tipos de incertidumbre. La teoría de la probabilidad se utiliza para describir procesos estocásticos en los que los estados futuros de un sistema se describen a partir de sus estados pasados más un cambio aleatorio. En el modelado de la demanda energética, se utilizan procesos estocásticos como las cadenas de Márkov para la predicción y simulación de perfiles de carga.

Como afirma Tien (2009) la incertidumbre difusa puede analizarse mediante la teoría de sistemas grises, y se puede clasificar como métodos de incertidumbre. El modelo gris fundamental GM (1,1) se basa en tan solo cuatro puntos de datos recientes para pronosticar los puntos de datos futuros.

Las técnicas de ingeniería siguen un enfoque ascendente y utilizan diversos parámetros externos e internos para describir con gran detalle un sistema de consumo de energía. Chuan y Ukil (2015) afirman que a menudo, se consideran las cargas individuales de los electrodomésticos para obtener perfiles agregados. Ejemplos comunes son los modelos a nivel de vivienda individual, como el estudio de McKenna y Thomson (2016), o de procesos industriales, investigados por Rehfeldt et al. (2018), así como las simulaciones de edificios mencionados por Nouvel et al. (2017) en donde se utilizan ciudades modeladas en 3D.

Los modelos de ingeniería han demostrado su eficacia en la planificación y el diseño de sistemas técnicos, permitiendo simular el comportamiento de un sistema en condiciones para las que aún se dispone de pocos datos históricos. Sancho-Tomás et al. (2017) afirma, que son enfoques prometedores en cuanto a la inclusión de los efectos de la composición del hogar y el comportamiento individual de los habitantes, así como para probar estrategias de gestión de la demanda.

Estas técnicas complementan el espectro de metodologías disponibles para la predicción del consumo energético, aunque no forman parte del enfoque central de este trabajo, permiten

contextualizar y establecer los avances actuales en el uso de inteligencia artificial aplicada a la predicción de demanda energética.

A pesar de la amplia variedad de enfoques existentes en el contexto ecuatoriano se ha explorado poco la aplicación de modelos de aprendizaje profundo para la predicción de la demanda eléctrica lo cual constituye el objetivo principal de este trabajo, generar evidencia de las posibles ventajas que pueden tener los métodos de Inteligencia Artificial frente a los métodos tradicionales.

2.3. Conclusiones

La predicción del consumo energético es una necesidad crítica para una adecuada planificación en el sector eléctrico especialmente en el contexto de países como Ecuador donde la estabilidad del sistema y la eficiencia de los recursos energéticos dependen en gran medida de una estimación precisa de la demanda que está relacionada fuertemente con la variabilidad climática del país. Como se aborda en la problemática los métodos utilizados actualmente presentan limitaciones importantes tanto en precisión como en capacidad de adaptación a cambios dinámicos en los patrones de consumo.

El análisis del estado del arte ha permitido identificar una amplia gama de enfoques para la predicción de series temporales desde modelos estadísticos clásicos como ARIMA hasta métodos más recientes basados en aprendizaje automático incluyendo redes neuronales y técnicas híbridas. Estos enfoques demuestran diferentes grados de efectividad dependiendo del contexto, los datos disponibles y las características del problema.

Sin embargo, uno de los principales puntos a fortalecer es la implementación de técnicas de aprendizaje profundo, particularmente en el contexto ecuatoriano, especialmente considerando que en otros países se ha demostrado su eficacia. Esto genera una problemática en la que esta investigación puede aportar pruebas de las ventajas de los métodos de Inteligencia Artificial frente a los métodos tradicionales.

En este sentido, se identifica la necesidad de realizar un estudio comparativo que permita evaluar el desempeño de modelos de aprendizaje profundo, como las redes neuronales recurrentes, en la predicción de la demanda energética en Ecuador. Esta comparación debe realizarse frente a enfoques clásicos como ARIMA, con el objetivo de generar evidencia sobre

su aplicabilidad y posibles ventajas en términos de precisión, capacidad de adaptación y robustez.

Debido a la importancia de un sistema energético robusto dentro del desarrollo de un país, en el que la correcta planificación juega un papel fundamental, lo que justifica el desarrollo del presente trabajo. En el siguiente Capítulo se establecen los objetivos de investigación y la metodología a seguir, los cuales permiten abordar la problemática planteada y contribuyen al desarrollo de herramientas más precisas y eficaces para la predicción del consumo energético en el país.

3. Objetivos y Metodología de Trabajo

Este Capítulo presenta los objetivos que guían el desarrollo del presente trabajo de investigación, así como la metodología adoptada para su ejecución. Los objetivos tanto general como específicos, se han formulado bajo el enfoque SMART, asegurando que estos sean claros, medibles, alcanzables, relevantes y definidos en el tiempo.

A partir de la problemática identificada se establecen las metas que orientan el análisis comparativo entre modelos tradicionales y redes neuronales recurrentes en la predicción del consumo eléctrico en Ecuador, dichas metas se presentan en forma de objetivos en las Secciones 3.1 y 3.2. Finalmente se describe de manera general la metodología en la Sección 3.3 que permite llevar a cabo dicha comparación, lo que justifica la elección de los enfoques empleados.

3.1. Objetivo General

Evaluar la precisión de las redes neuronales recurrentes utilizando modelos LSTM y BiLSTM frente a modelos tradicionales de predicción como ARIMA y SARIMA, para estimar el consumo eléctrico en Ecuador a partir de series temporales históricas comprendidas entre 2014 y 2024, con el fin de identificar la metodología más precisa y robusta que contribuya a una planificación energética eficaz en contextos de alta variabilidad e incertidumbre climática.

3.2. Objetivo Específico

- **OE1:** Analizar la problemática existente del consumo energético en Ecuador entre 2014 y 2024, considerando la influencia de la variabilidad climática y sus implicaciones en la construcción de modelos predictivos precisos y robustos.
- **OE2:** Estudiar el estado del arte de los métodos tradicionales y de inteligencia artificial aplicados a la predicción del consumo eléctrico, con énfasis en metodologías con características altamente variables.
- **OE3:** Preparar y estructurar el conjunto de datos para su uso en modelos de predicción, garantizando su calidad mediante técnicas de limpieza, transformación y selección de variables.

- **OE4:** Implementar y comparar modelos tradicionales (ARIMA y SARIMA) y modelos basados en redes neuronales recurrentes (LSTM y BiLSTM), evaluando su rendimiento mediante métricas como RMSE, MAE y MAPE.
- **OE5:** Evaluar la aplicabilidad de los modelos desarrollados para la planificación energética ecuatoriana, formulando recomendaciones basadas en la robustez y precisión observadas bajo escenarios complejos.

3.3. Metodología

Con el fin de alcanzar los objetivos propuestos y evaluar la eficacia de las redes neuronales recurrentes frente a métodos tradicionales en la predicción del consumo energético en Ecuador, se ha diseñado una metodología estructurada en seis etapas. Cada etapa responde a uno o varios de los objetivos específicos y busca garantizar la rigurosidad del análisis, la calidad de los datos y la validez de las conclusiones. La Figura 10 muestra un diagrama de flujo que representa las diferentes etapas de la metodología, además de algunas de las herramientas a utilizar en dichas etapas. En las siguientes Secciones se describen los detalles de cada etapa con mayor profundidad.




Figura 10. Diagrama de la Metodología por etapas (Fuente: Elaboración propia).

3.3.1. Etapa 1: Recolección y análisis exploratorio de datos

En esta Etapa se busca comprender el comportamiento histórico del consumo energético en Ecuador, recolectando el conjunto de datos históricos desde fuentes oficiales y realizando un

análisis descriptivo con el objetivo de realizar un diagnóstico inicial del consumo energético y detección de anomalías o tendencias significativas, utilizando herramientas como *Python* (*Google Colab*) mediante las librerías como *Pandas*, *Matplotlib*, *Seaborn*.

Tabla 3. Comparativa de herramientas de análisis de datos para la predicción del consumo energético (Fuente: Elaboración propia basada en Chollet (2021), Kelleher et al. (2020)).

Criterio	Python (Google Colab)	R	Matlab
Accesibilidad	Gratuito, basado en la nube, no requiere instalación.	Gratuito, requiere instalación local.	Licencia de pago costosa.
Facilidad de Uso	Interfaz intuitiva tipo notebook, compatible con <i>Markdown</i> y código.	Interfaz basada en scripts, menos visual.	Interfaz amigable pero menos flexible para grandes volúmenes de datos.
Bibliotecas para series temporales	Amplia variedad: <i>pandas</i> , <i>statsmodels</i> , <i>scikit-learn</i> , <i>tslearn</i> , <i>pmdarima</i> , <i>TensorFlow</i> , Etc.	Buen soporte con <i>forecast</i> , <i>tseries</i> , <i>caret</i> , Etc.	Limitado para modelos avanzados de ML; requiere <i>toolboxes</i> adicionales.
Soporte para aprendizaje profundo	Soporte nativo con <i>TensorFlow</i> , <i>Keras</i> y <i>PyTorch</i> , integración fluida.	Menor integración con <i>deep learning</i> .	Limitado, requiere <i>toolbox</i> especializado.
Comunidad y documentación	Muy amplia, actualizaciones frecuentes, fuerte comunidad <i>open source</i> .	Fuerte comunidad académica, especialmente en estadística.	Comunidad más cerrada y centrada en ingeniería.
Colaboración y replicabilidad	Ideal para trabajo colaborativo (Google Drive), notebooks compartibles, ejecución desde navegador.	Requiere instalación de paquetes y entorno local.	Difícil de compartir o colaborar en tiempo real.

En la Tabla 3 se muestra una comparativa de las diferentes herramientas disponibles, se utiliza Python mediante Google Colab como entorno principal de desarrollo por su gratuidad, accesibilidad, facilidad de uso y compatibilidad con bibliotecas avanzadas tanto para

modelado estadístico como para redes neuronales profundas. A diferencia de herramientas como R, Matlab o Excel, Python ofrece una mayor escalabilidad y soporte en tareas de aprendizaje profundo, además de permitir trabajo colaborativo en la nube y una mejor replicabilidad de los experimentos.

3.3.2. Etapa 2: Preprocesamiento y estructuración del Dataset

La Etapa 2 tiene como objetivo asegurar que los datos estén completos y preparados para el uso en modelos predictivos, lo cual se logra mediante acciones como la limpieza de datos nulos, imputación, transformación de variables categóricas, normalización, con ayuda de bibliotecas como *Scikit-learn*, *Tslearn*. Con esto se espera obtener un dataset listo para ser usado en los modelos tradicionales y redes neuronales artificiales.

3.3.3. Etapa 3: Implementación de modelos estadísticos

La implementación de modelos tradicionales pretende establecer un punto de comparación mediante los métodos estadísticos como ARIMA y SARIMA. El modelado se lleva a cabo mediante el diseño del modelo, la elección de los hiperparámetros, validación temporal cruzada, entre otros elementos, los cuales se implementarán con herramientas como *Statsmodels*, *Pmdarima*. En la Etapa 3 se desea obtener los resultados de las métricas de desempeño de los modelos con el objetivo de compararlas posteriormente.

3.3.4. Etapa 4: Desarrollo de modelos de Redes Neuronales Recurrentes

En la Etapa 4 se evalúa la capacidad predictiva de LSTM y BiLSTM en contextos no lineales. Se definen las arquitecturas de las redes, ajuste de hiperparámetros, datos de entrenamiento-validación-test. Se utilizan herramientas como *TensorFlow/Keras* o *PyTorch*, y con ello se buscan obtener las predicciones de las RNN para realizar la comparación directa con los modelos tradicionales. En la Tabla 4 se muestra una comparativa de las herramientas comúnmente utilizadas para redes neuronales, se elige *Keras* (usado junto con *TensorFlow*) debido a que es una de las mejores opciones disponibles para el desarrollo de modelos con redes neuronales recurrentes como LSTM y BiLSTM, especialmente si se busca simplicidad, claridad y documentación sólida. Además, se integra perfectamente con otras herramientas de análisis como *Pandas*, *Scikit-learn* o *Matplotlib*.

3.3.5. Etapa 5: Evaluación comparativa y análisis de robustez

En este punto se busca validar la hipótesis del trabajo y analizar qué modelo tiene mejor rendimiento con series temporales altamente variables, la comparativa se realiza a través de las métricas entre modelos, visualización de errores y validación cruzada, con lo que se puede determinar cuál enfoque predice mejor el consumo energético.

Tabla 4. Comparativa de herramientas para redes neuronales (Fuente: Elaboración propia basada en Chollet (2021), Kelleher et al. (2020)).

Criterio		Keras (TensorFlow)	PyTorch	Theano
Facilidad de uso		Muy alta. API intuitivo, ideal para prototipado rápido.	Alta, aunque más técnica. Requiere más control explícito.	Baja. Sintaxis más compleja y menor soporte.
Popularidad y comunidad	Y	Muy alta. Amplia comunidad, muchos ejemplos y documentación.	Comunidad en crecimiento, especialmente en I+D.	Baja. Proyecto descontinuado desde 2017.
Integración con otras librerías		Excelente (NumPy, Pandas, Scikit-learn, Etc.).	Muy buena.	Limitada
Velocidad de entrenamiento	de	Alta (con soporte GPU mediante TensorFlow).	Alta (mayor flexibilidad para optimización).	Media. Depende mucho del hardware y configuración.
Soporte a LSTM/BiLSTM	a	Sí, directamente disponible y muy fácil de implementar.	Sí, totalmente soportado.	Sí, pero con mayor complejidad en la implementación.
Desarrollo activo		Muy activo (Google).	Muy activo (Meta/Facebook).	No. Proyecto cerrado.

3.3.6. Etapa 6: Recomendaciones para la planificación energética

En esta Etapa se procura traducir los hallazgos de los modelos en lineamientos útiles para políticas energéticas, mediante la discusión de resultados, redacción de conclusiones y recomendaciones técnicas, basadas en el análisis cualitativo con base en los hallazgos cuantitativos, aspirando a generar sugerencias específicas para mejorar la planificación energética en Ecuador.

4. Desarrollo de la contribución

Este Capítulo presenta el desarrollo práctico del trabajo de investigación, siguiendo la metodología planteada previamente. La estructura del Capítulo se organiza en seis etapas consecutivas que corresponden a las fases metodológicas descritas en el Capítulo 3. Cada una de estas etapas refleja una contribución concreta al objetivo general del estudio: evaluar la precisión de las redes neuronales recurrentes frente a los modelos tradicionales para la predicción del consumo energético en Ecuador. En la Sección 4.1 se realiza la recolección y análisis exploratorio de los datos donde se identifican patrones de consumo, en la Sección 4.2 se realiza el preprocesamiento y estructuración del dataset y preparar los datos para las siguientes secciones, la Sección 4.3 desarrolla los modelos estadísticos ARIMA y SARIMA, la Sección 4.4 establece la arquitectura de los modelos de redes neuronales recurrentes mediante LSTM y BiLSTM, la Sección 4.5 evalúa los resultados y métricas de modelos estadísticos y RNN y analiza su robustez en ocasiones poco frecuentes, por último, en la Sección 4.6 se establecen recomendaciones energéticas como consecuencias de los análisis realizados.

A lo largo de este Capítulo se detallan los procedimientos implementados, las herramientas utilizadas, los resultados obtenidos en cada fase del proceso, así como los criterios aplicados para la evaluación de los modelos. El propósito es evidenciar mediante un enfoque sistemático y reproducible, los aportes empíricos y metodológicos que sustentan las conclusiones del estudio, y demostrar la viabilidad del uso de técnicas de aprendizaje profundo en escenarios energéticos con alta variabilidad.

4.1. Etapa 1: Recolección y análisis exploratorio de datos

En esta etapa se recopila el conjunto de datos históricos de consumo energético en Ecuador correspondiente al período 2014–2024, a partir de fuentes oficiales como el Ministerio de Energía y Minas y la Agencia de Regulación y Control de Electricidad (ARCONEL). Esta información se extrae de su plataforma de Reportes de Información Estadística del Sector Eléctrico específicamente de los reportes de Facturación de Clientes Regulados, los datos incluyen información mensual desagregada por provincia, tipo de consumo (residencial, comercial, industrial, alumbrado público), número de clientes, energía facturada (kWh) y

costo promedio por kWh, entre otras características. Además, se agrega información económica y geográfica, como el PIB y la Inflación al dataset.

Una vez recolectados los datos se realiza un análisis exploratorio con el fin de identificar patrones de consumo, anomalías, tendencias estacionales y posibles inconsistencias. Con esto se procede al procesamiento inicial. Para ello se integran los archivos anuales en un único conjunto de datos el cual es transformado en un formato estructurado tipo CSV. Se crea una columna de fecha unificada a partir del año y mes de cada registro permitiendo ordenar cronológicamente la serie temporal.

La estructura final del archivo CSV, así como una muestra representativa de sus registros puede consultarse en el Anexo I. Este incluye campos como la fecha, el grupo de consumo, el consumo energético mensual (en GWh), el número de clientes, las coordenadas geográficas (latitud y longitud), y variables macroeconómicas como el PIB y la inflación.

La fuente de estos datos corresponde a los reportes oficiales de Facturación de Clientes Regulados publicados por la Agencia de Regulación y Control de Electricidad (ARCONEL) y el Ministerio de Energía y Minas del Ecuador.

Además, se corrigen los formatos numéricos como los valores de consumo expresados en kilovatios-hora (kWh) reemplazando comas por puntos decimales en los casos necesarios. Para este análisis se convierte la variable de consumo energético a gigavatios-hora (GWh), con el fin de facilitar la visualización y comprensión de las gráficas y reportes.

El análisis exploratorio se inicia con la agregación del consumo energético mensual total visualizado mediante un gráfico de líneas. La Figura 11 presenta la evolución del consumo energético mensual total en Ecuador expresado en gigavatios-hora (GWh) durante el periodo 2014–2024. Se observan patrones cíclicos consistentes con la estacionalidad típica del consumo eléctrico reflejando variaciones periódicas que podrían estar asociadas a estaciones del año, comportamiento productivo o condiciones climáticas.

Entre los años 2016 y 2019 se mantiene una tendencia creciente moderada. Sin embargo, en 2020 se evidencia una caída abrupta del consumo coherente con la reducción de la actividad económica y la movilidad asociada a la pandemia por COVID-19. Esta disminución es seguida de una recuperación sostenida a partir de 2021.




Figura 11. Consumo energético mensual total en Ecuador 2014-2024 (GWh) (Fuente: Elaboración Propia).

A finales de 2023 e inicios de 2024 se identifican nuevos descensos pronunciados los cuales coinciden con los efectos del fenómeno de El Niño y la crisis energética que afectó al país provocando cortes prolongados de suministro. Esta anomalía es especialmente relevante en el contexto de este trabajo, ya que resalta la necesidad de contar con modelos predictivos robustos capaces de anticipar caídas abruptas en el consumo.

En general, este comportamiento justifica el interés por aplicar metodologías avanzadas de predicción que no solo modelen la estacionalidad sino también identifiquen y anticipen eventos de interrupción energética.

Posteriormente se realiza el análisis mediante los grupos de consumo, la Figura 12 muestra la evolución del consumo energético mensual desagregado por grupo de consumo: residencial, comercial, industrial y alumbrado público. Se aprecia que el sector residencial representa consistentemente el mayor volumen de demanda, lo cual refuerza su importancia en la planificación del sistema eléctrico nacional.

El consumo industrial presenta variaciones más marcadas con picos y caídas que pueden estar asociadas a ciclos económicos, restricciones de producción o políticas energéticas. Por su parte, el sector comercial mantiene un comportamiento más estable con un ligero aumento hacia los años posteriores a 2020, posiblemente vinculado a la reactivación económica tras la pandemia por COVID-19.




Figura 12. Consumo energético mensual por grupo de consumo en Ecuador 2014-2024 (GWh)
(Fuente: Elaboración propia).

El consumo industrial presenta variaciones más marcadas con picos y caídas que pueden estar asociadas a ciclos económicos, restricciones de producción o políticas energéticas. Por su parte, el sector comercial mantiene un comportamiento más estable, con un ligero aumento hacia los años posteriores a 2020, posiblemente vinculado a la reactivación económica tras la pandemia por COVID-19.

Un caso particular es el del alumbrado público, cuyo consumo permanece estable, pero bajo, sin una variación estacional significativa. Esto es esperable dado su patrón de funcionamiento constante. Sin embargo, el descenso provocado por los fenómenos del El Niño y la crisis energética a inicios del 2024 afecta a todos los sectores y esto se ve reflejado en la gráfica, esto impidió el desarrollo normal de las actividades en el país.

Esta desagregación permite observar que, si bien el consumo agregado ofrece una visión general la dinámica interna entre sectores puede responder de forma diferente ante eventos climáticos económicos o sociales lo cual refuerza la necesidad de modelos predictivos flexibles y segmentados que capten estos matices.

Finalmente se aplican técnicas de detección de valores atípicos (outliers) mediante un diagrama de caja (boxplot) y la metodología del Z-score. No se identifican valores anómalos significativos en la serie mensual total, lo que indica una estabilidad relativa en el registro de datos.

Con estos resultados, se concluye que el conjunto de datos se encuentra en condiciones adecuadas para su uso en tareas de predicción mediante modelos de series temporales, y que refleja con fidelidad la evolución del consumo energético en el país durante el período de estudio.

4.2. Etapa 2: Preprocesamiento y estructuración del Dataset

Esta etapa tiene como objetivo garantizar que los datos utilizados en los modelos de predicción estén limpios, organizados y estructurados adecuadamente para su análisis. A partir del conjunto de datos históricos consolidado en la etapa anterior se aplican técnicas de preprocesamiento orientadas a corregir inconsistencias, transformar variables y asegurar la calidad del dataset.

En base a esto, se lleva a cabo un proceso de preprocesamiento y estructuración que garantiza la calidad, consistencia y utilidad del conjunto de datos. Esta etapa es clave para asegurar que los modelos, tanto estadísticos como basados en redes neuronales, operen sobre información limpia y estructurada de forma adecuada.

Inicialmente se necesita una columna que permita organizar cronológicamente los archivos por lo que se construye la columna Fecha con formato de serie temporal (*datetime64[ns]*), la cual es el resultado y reemplaza a las columnas de Año y Mes.

Posteriormente, se realiza una limpieza de datos incluyendo la corrección de formatos numéricos y la identificación de valores nulos. Se detectan ausencias en las variables PIB e Inflación correspondientes a algunos años sin información disponible en las fuentes oficiales. En estos casos, se procede a la imputación manual de los valores faltantes con base en datos estimados o extraídos de fuentes complementarias. Esta corrección permite mantener la coherencia temporal del conjunto sin comprometer la integridad de los datos.

Para mejorar la legibilidad de las variables relacionadas con el consumo se utiliza magnitudes de GWh reemplazando a kWh. Esta unidad resulta más apropiada para su representación visual y para el análisis a escala nacional. Asimismo, se eliminan columnas redundantes o no significativas para el modelado, como Empresa, Provincia, Cantón, Parroquia, entre otras. En su lugar, se incorporan las coordenadas geográficas (latitud y longitud) correspondientes al centroide de cada provincia lo cual permite preservar una referencia espacial numérica sin

necesidad de utilizar variables categóricas nominales. En la Tabla 5 se muestra el conjunto de datos preprocesados

Tabla 5. *DataFrame Final después del preprocesamiento (Fuente: Elaboración Propia).*

index	Grupo_Consumo	Clientes	Facturacion_USD	PIB	Inflacion	Fecha	Energia_GWh	Latitud	Longitud
0	Comercial	1	321.64	4.22	3.67	2014-02-01	0.003	-0.938	-78.614
1	Comercial	5	911.54	4.22	3.67	2014-02-01	0.018	-0.938	-78.614
2	Industrial	1	1918.90	4.22	3.67	2014-02-01	0.046	-0.938	-78.614

Finalmente, se generan dos versiones del dataset final la primera versión conserva los valores originales y será empleado para los modelos estadísticos, mientras que en la segunda versión se aplica la normalización a las variables numéricas clave y se utilizará para modelos de aprendizaje profundo. Esta normalización es esencial para asegurar la estabilidad del entrenamiento y la convergencia de redes neuronales.

Este proceso es fundamental para reducir sesgos, evitar errores en las etapas posteriores y mejorar la precisión de los modelos. Como resultado se obtiene un dataset estructurado y listo para su uso en modelos tradicionales y de redes neuronales recurrentes facilitando una comparación justa y rigurosa entre ambos enfoques.

4.3. Etapa 3: Implementación de modelos estadísticos

Con el fin de establecer una línea base para la comparación con modelos de aprendizaje profundo se implementan modelos estadísticos de series temporales. Para ello, se sigue la metodología clásica de Box-Jenkins (Box et al., 2016), ampliamente utilizada para la modelización y pronóstico de series temporales univariadas mediante modelos ARIMA y sus variantes. Esta metodología contempla cuatro etapas principales: identificación del modelo, estimación de parámetros, validación y pronóstico. La Figura 13 muestra un diagrama de flujo que indica la metodología utilizada en esta etapa.

Esta metodología ha sido aplicada exitosamente en diversos estudios, como los de Alharbi Csala (2022) y Eskandarnia y AlHammad (2021), quienes utilizaron modelos ARIMA y SARIMA para predecir el consumo energético en diferentes contextos. Estos estudios respaldan la aplicabilidad y eficacia de la metodología seleccionada para el análisis de series temporales en el sector energético, además de servir como lineamientos para el desarrollo de los modelos en la Etapa 3.

En esta etapa se implementan modelos estadísticos clásicos para la predicción de series temporales. Específicamente, se aplican los modelos ARIMA y SARIMA siguiendo la metodología de Box y Jenkins.




Figura 13. Metodología Box-Jenkins (Martínez-Álvarez et al, 2015).

4.3.1. Implementación del modelo estadístico ARIMA

Una vez establecida la metodología, se procede a preparar la serie temporal para implementar los modelos estadísticos ARIMA y SARIMA, se construye una serie temporal a partir del conjunto de datos procesado en la etapa anterior. Esta serie representa el consumo energético mensual total en Ecuador, expresado en gigavatios-hora (GWh), y se organiza cronológicamente.

Como primer paso se realiza el filtrado de los registros entre enero de 2014 y diciembre de 2023, debido al análisis en la Etapa 2 se decide realizar dos análisis, el primero excluyendo los datos del 2024 y el segundo con la totalidad de los datos, esta decisión responde a la

naturaleza anómala de los datos del año 2024 debido a los fenómenos climáticos, se desea analizar el comportamiento de los modelos en situaciones poco frecuentes. Además, se eliminan valores de energía negativos que puedan afectar el entendimiento del modelo. Se asegura una frecuencia mensual uniforme agregando el consumo energético total nacional por mes, mediante una agrupación `resample("MS")`.

El conjunto de datos se divide temporalmente en dos subconjuntos para el entrenamiento del primer modelo ARIMA:

- Entrenamiento: desde enero de 2014 hasta diciembre de 2022.
- Test: desde enero hasta diciembre de 2023, para evaluar la capacidad predictiva del modelo.

Luego se realiza la verificación de estacionariedad de la serie temporal utilizando la prueba de Dickey-Fuller aumentada (ADF). En una serie temporal que los datos sean estacionarios significa que las propiedades estadísticas de la serie como la media y la varianza no cambian con el tiempo. Esto implica que los valores de la serie no están influenciados por tendencias o estacionalidades. Esta prueba permite identificar si la serie presenta una media y varianza constantes a lo largo del tiempo, condición necesaria para la correcta aplicación de los modelos ARIMA.

Tabla 6. Resultados de la prueba ADF (Fuente: Elaboración Propia).

Parámetro	Valor
Estadístico ADF	0.25
Valor p	0.97

El resultado de la prueba ADF se muestra en la Tabla 6, aplicada a la serie original arroja un valor p de 0.97, lo que indica que no se puede rechazar la hipótesis nula de que la serie no es estacionaria ($p \leq 0.05 \rightarrow \text{serie estacionaria}$). Por tanto, se procede a realizar una diferenciación de primer orden con el objetivo de estabilizar la media de la serie y eliminar la tendencia.

Una vez diferenciada la serie, se repite la prueba ADF. En esta ocasión el valor p disminuye. Esto valida el uso de un modelo ARIMA con $d = 1$. La Figura 14 muestra el gráfico de la serie temporal diferenciada.




Figura 14. Serie temporal diferenciada (Fuente: Elaboración Propia).

Con la serie estacionaria se aplican los gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF), mostrados en la Figura 15, los cuales ayudan a determinar los valores apropiados de los parámetros p (autorregresivo) y q (media móvil). En este caso, se observan autocorrelaciones significativas en los primeros rezagos.




Figura 15. Gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF) (Fuente: Elaboración Propia).

Una vez verificada la estacionariedad de la serie temporal mediante la prueba ADF y aplicada la diferenciación de primer orden se procede a seleccionar los parámetros del modelo ARIMA. Este modelo se caracteriza por tres componentes principales: el término autorregresivo (p),

el grado de diferenciación (d) y el término de media móvil (q), formando el modelo $ARIMA(p, d, q)$.

Para determinar los valores adecuados de p y q , se analizan los gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF) aplicados a la serie diferenciada. En la Figura 15 se presenta el gráfico respectivo, donde se observa que:

- El gráfico ACF muestra una caída gradual a partir del primer rezago.
- El gráfico PACF presenta un pico significativo en el primer rezago y luego cae abruptamente.

Este comportamiento sugiere que un modelo $ARIMA(1,1,1)$ puede ser apropiado al incluir un componente autorregresivo de orden 1 y un componente de media móvil de orden 1. Estos valores se validan posteriormente mediante el ajuste del modelo y la evaluación de su desempeño.

Se procede a entrenar el modelo $ARIMA(1,1,1)$ sobre la serie temporal mensual del consumo energético total en Ecuador hasta diciembre del 2022 utilizando la librería *statsmodels* en Python. Una vez entrenado, se realiza la predicción directa para los 12 meses del 2023. En la Figura 16 se visualiza los datos de entrenamiento (2014-2022), los datos del consumo real en el 2023 y las predicciones del modelo $ARIMA(1,1,1)$.




Figura 16. Predicción del consumo energético con $ARIMA(1,1,1)$ (Fuente: Elaboración Propia).

Las métricas de evaluación que se utilizarán en todos los modelos debido a su utilidad al comparar diferentes métodos y su amplio uso son: (Martínez-Álvarez et al., 2015).

- Error Absoluto Medio (MAE, Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

- Raíz del Error Cuadrático Medio (RMSE, Root Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

- Error Porcentual Absoluto Medio (MAPE, Mean Absolute Percentage Error)

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| 100 \frac{y_t - \hat{y}_t}{y_t} \right|$$

Los resultados de la Tabla 7 muestra los resultados del modelo ARIMA, aunque el MAPE del 5.43 % podría considerarse razonable en términos relativos, las métricas absolutas (MAE y RMSE superiores a 100 GWh), sugieren que el modelo ARIMA (1,1,1) no captura adecuadamente la dinámica de la serie en el conjunto de prueba.

Además, en la Figura 16 se observa que el modelo no logra captar los picos reales del consumo y a partir de la segunda-tercer predicción del modelo la curva se aplanan lo que resulta en los errores mostrados en las métricas de evaluación.

Tabla 7. Métricas del Modelo ARIMA (Fuente: Elaboración Propia).

Métrica	Valor
RMSE	123.03 GWh
MAE	108.79 GWh
MAPE	5.43 %

Dado estos resultados que sirven de base para el análisis, se realiza un segundo entrenamiento incluyendo los datos del año 2024 para su predicción, los cuales son datos afectados por

Erick Manuel Mendoza Pico
Comparativa del desempeño entre redes neuronales recurrentes y modelos estadísticos en la predicción del consumo energético en Ecuador
fenómenos climáticos extremos. El objetivo es evaluar el modelo en casos pocos frecuentes para analizar su comportamiento.

Los datos correspondientes al año 2024 reflejan una caída abrupta en el consumo energético atribuida principalmente a los efectos del fenómeno de El Niño y a la crisis hidro energética ocurrida en el país. Estos eventos extremos generan un comportamiento atípico que puede distorsionar el entrenamiento de los modelos predictivos afectando su capacidad de generalización.

Con el fin de evaluar el impacto de estos datos anómalos en el rendimiento de los modelos se entrena nuevamente el modelo incluyendo los datos del 2024, se realiza todo el proceso que se desarrolló con el primer modelo y se define que la arquitectura más adecuada se mantiene como un modelo ARIMA (1,1,1). La nueva serie temporal de entrenamiento considera datos desde enero de 2014 hasta diciembre de 2023 y los datos del 2024 son los datos de test para evaluar el modelo.

Como se observa en la Tabla 8, incluir los datos correspondientes al año 2024 empeora el rendimiento del modelo. Las tres métricas de error aumentan lo que indica una menor precisión en la predicción del consumo energético.

Tabla 8. Comparativas de las Métricas de los Modelo ARIMA (Fuente: Elaboración Propia).

Métrica	Datos (2014-2023)	Datos (2014-2024)
RMSE	123.03 GWh	181.99 GWh
MAE	108.79 GWh	157.88 GWh
MAPE	5.43 %	8.63 %

En la Figura 17 se presenta las predicciones del modelo para el 2024. La forma de la curva es parecida al modelo ARIMA anterior, pero al existir picos más pronunciados los valores de las métricas se elevan, el modelo no logra seguir la curva de consumo. Este análisis confirma que los eventos extremos introducen ruido que afecta negativamente la precisión de modelos estadísticos como ARIMA, especialmente cuando se basan en supuestos de linealidad y normalidad. Por tanto, se concluye que, en contextos con alta sensibilidad a eventos

climáticos, es recomendable evaluar el impacto de los datos anómalos en los modelos y considerar versiones ajustadas o segmentadas.




Figura 17. Predicción del consumo energético (2014-2024) con ARIMA (1,1,1) (Fuente: Elaboración Propia).

Sin embargo, el rendimiento de los modelos ARIMA están influenciados por la naturaleza de los datos, los modelos anteriores utilizaron alrededor de 120 datos, 12 datos por año, lo cual para la mayoría de los modelos (en específico modelos de Aprendizaje Profundo) dificulta el aprendizaje de patrones y la correcta predicción energética. Es por lo que, se utilizó una metodología diferente. Con el objetivo de superar la limitación de datos agregados a nivel nacional y explorar mejor las dinámicas locales del consumo eléctrico, se aplicó un enfoque de modelado desagregado mediante la segmentación de la serie temporal en subconjuntos definidos por:

- Grupo de consumo (residencial, comercial, industrial, Etc.),
- Latitud y longitud (ubicación geográfica).

Este procedimiento permitió construir una serie temporal específica para cada combinación (grupo + ubicación) resultando en decenas de subseries con al menos 120 meses de datos. Este enfoque es de suma importancia debido a que es la metodología que se utilizara en las Redes Neuronales Recurrentes debido a que inherentemente el Aprendizaje Profundo necesita una gran cantidad de datos.

Se realiza dos distintos modelos igual que antes, excluyendo los datos del 2024 y otro con los datos completos con el objetivo de realizar una comparativa en igualdad de condiciones. El primer paso es construir una serie mensual por combinación única de grupo de consumo y coordenadas, cada serie se reindexó a una frecuencia mensual (`asfreq("MS")`).

Con el objetivo de utilizar datos consistentes se aplica un filtro en donde se identifican valores faltantes:

- Si una serie tenía más de dos años con más de 2 meses vacíos, fue descartada.
- Las demás series fueron interpoladas linealmente y completadas con ceros si era necesario.

Este filtrado asegura que solo las series con estructura temporal suficientemente consistente fuesen utilizadas para el entrenamiento.

Como se vio anteriormente, los modelos ARIMA necesitan definir los valores de $ARIMA(p, d, q)$ para lo que necesitan un análisis, en este caso en donde existe una gran cantidad de subseries se utiliza la librería de Python `auto_arima` que permite automatizar este proceso y determina cuales son los mejores valores para el modelo. Para cada subserie válida, se utilizó `auto_arima` para determinar automáticamente los hiperparámetros. Luego, se entrenó un modelo ARIMA individualizado por serie, considerando como entrenamiento los periodos definidos anteriormente. Esto resultó en decenas de modelos independientes cada uno especializado en las características particulares del consumo de un sector en una zona geográfica específica.

Una vez generadas las predicciones para cada serie se sumaron todas las predicciones mensuales para obtener una curva nacional predicha, que fue comparada contra la curva real total para el mismo período. Esta estrategia captura heterogeneidad espacial y sectorial, permite una evaluación localizada de errores, hace más robusto el análisis frente a anomalías agregadas.

En la Figura 18 se muestra la gráfica del primer Modelo Desagregado (2014 - 2023), se observa que el modelo logra representar con mayor precisión la evolución de la curva de consumo, sin embargo, esta suaviza los picos y baches del consumo real y predice valores por debajo de estos.




Figura 18. Predicción del consumo energético (2014-2023) con ARIMA Desagregado (Fuente: Elaboración Propia).

En la Tabla 9 se muestra los resultados de las métricas de rendimiento del modelo, se observa una mejora frente a los resultados del modelo ARIMA (1,1,1), en especial la métrica MAE obtuvo una reducción de alrededor de 10 GWh, lo que indica que el modelo desagregado logra una mejor comprensión de los patrones.

Tabla 9. Métricas del Modelo ARIMA Desagregado (Fuente: Elaboración Propia).

Métrica	Valor
RMSE	118.09 GWh
MAE	97.25 GWh
MAPE	4.88 %

A continuación, se realiza el mismo procedimiento con la inclusión del año 2024 con el fin de analizar el modelo desagregado en condiciones climáticas poco frecuentes. El proceso de filtrado y limpieza de datos es igual con la diferencia de que los datos de entrenamiento ahora se presentan desde el 2014 hasta el 2023 y los datos de prueba son del año 2024.

La Figura 19 muestra la curva de predicción del modelo ARIMA desagregado para el año 2024, se logra observar que la curva predicha no captura los patrones de picos y baches de conjunto de datos afectados por los fenómenos climáticos. En la Tabla 10 se muestra la comparativa de

las métricas de los dos modelos desagregados, en ambos casos se observan mejoras frente a los modelos (1,1,1), sin embargo, se logra observar que los modelos suavizan las curvas o simplemente no captan patrones lógicos del consumo energético.




Figura 19. Predicción del consumo energético (2014-2024) con ARIMA Desagregado (Fuente: Elaboración Propia).

Dado que los modelos ARIMA agregados presentan limitaciones frente a variaciones espaciales y climáticas, y que el enfoque desagregado mostró mejores métricas de error, a partir de esta etapa se continuará el análisis únicamente con modelos desagregados.

Tabla 10. Comparativas de las Métricas de los Modelo ARIMA Desagregado (Fuente: Elaboración Propia).

Métrica	Modelo Desagregado (2014-2023)	Modelo Desagregado (2014-2024)
RMSE	118.09 GWh	177.86 GWh
MAE	97.25 GWh	155.22 GWh
MAPE	4.88 %	8.38 %

Debido a que los modelos ARIMA desagregados aún presentan ciertas restricciones derivadas de su carácter lineal y su incapacidad para modelar relaciones estacionales de manera

explícita, en la siguiente etapa se introduce el modelo SARIMA (Seasonal ARIMA), que extiende la formulación de ARIMA mediante la incorporación de componentes estacionales. Esta característica es especialmente relevante en el caso del consumo energético, ya que muchos patrones de consumo están influenciados por ciclos mensuales, variaciones estacionales y comportamientos repetitivos que no pueden ser capturados completamente por modelos sin estructura estacional.

Al igual que en el análisis anterior, se mantendrá el enfoque desagregado por grupo de consumo y coordenadas geográficas, aplicando SARIMA a cada subserie válida del conjunto de datos. Además, se conservará la estructura de evaluación en dos fases: un primer modelo entrenado con datos entre 2014 y 2022 (evaluado sobre 2023), y un segundo modelo entrenado hasta 2023 (evaluado sobre 2024, año afectado por condiciones anómalas). Esto permitirá valorar la capacidad de los modelos estacionales para mejorar la precisión predictiva y su robustez ante eventos extremos.

4.3.2. Implementación del modelo estadístico SARIMA

A continuación, se presenta la implementación del modelo estadístico SARIMA (Seasonal ARIMA), el cual extiende la formulación del modelo ARIMA mediante la inclusión de componentes estacionales. Este modelo es adecuado para series temporales con patrones cíclicos regulares, como es el caso del consumo energético mensual, que puede verse influenciado por factores climáticos, calendarios o comportamientos repetitivos asociados a estaciones del año.

El modelo SARIMA permite incorporar tanto componentes de tendencia como de estacionalidad, definiendo la estructura $(p,d,q)(P,D,Q,s)$, donde los parámetros estacionales capturan la dependencia entre observaciones separadas por un período fijo. Esta capacidad lo convierte en una herramienta más flexible para modelar el comportamiento energético mensual que los modelos ARIMA estándar.

Siguiendo la metodología establecida en secciones anteriores, se aplicará el modelo SARIMA de forma desagregada, entrenando un modelo por cada subserie identificada (grupo de consumo + ubicación geográfica). Se mantendrá la misma estructura de evaluación utilizada previamente: un primer conjunto de modelos entrenados con datos hasta diciembre de 2022 (evaluados para el año 2023), y un segundo conjunto entrenado hasta diciembre de 2023

(evaluados para el año 2024). Esto permitirá comparar la capacidad del modelo para anticiparse a contextos normales y a situaciones atípicas generadas por fenómenos extremos. El objetivo de esta etapa es evaluar si la incorporación explícita de la estacionalidad mejora la capacidad predictiva respecto a los modelos ARIMA previamente implementados.

El proceso de entrenamiento se realiza mediante la herramienta `auto_arima` para la definición de los hiperparámetros del método SARIMA, los datos se dividen igual que en el modelo ARIMA y se analizan sus resultados.




Figura 20. Predicción del consumo energético (2014-2023) con SARIMA Desagregado (Fuente: Elaboración Propia).

En la Figura 20 se muestra la curva predicha del año 2023 por el modelo, se observa que la curva logra captar con más precisión los picos del consumo real, sin embargo, el valor predicho está por debajo de los valores reales, esto suele suceder en los métodos estadísticos cuando la primera predicción cae en un pico, el modelo no logra realizar una primera predicción cercana a los valores reales y las siguientes predicciones arrastran ese error. Esto es típico en modelos estadísticos con alta inercia que no reaccionan bien a cambios bruscos o picos recientes. SARIMA detecta patrones estacionales suaves, pero cuando el primer dato que debe predecir cae justo sobre un pico (como enero 2023), y no tiene suficiente recurrencia del mismo patrón, no tiene forma de aprenderlo bien.

La Tabla 11 muestra las métricas de rendimiento del modelo, a pesar de incorporar estacionalidad y que la curva predicha asemeja más a un comportamiento energético, el

modelo SARIMA no mejora los resultados del modelo ARIMA desagregado. Esto puede deberse a la aparición de un pico en el primer mes de predicción (enero de 2023) y por tanto no puede ser anticipado correctamente por un modelo basado únicamente en componentes internos de la serie.

Tabla 11. Métricas del Modelo SARIMA Desagregado (Fuente: Elaboración Propia).

Métrica	Valor
RMSE	179.17 GWh
MAE	168.15 GWh
MAPE	8.46 %

A continuación, se modela SARIMA incluyendo los datos del 2024 para analizar su comportamiento en situaciones poco frecuentes, la Figura 21 muestra la curva predicha por el modelo, se observa que nuevamente el modelo es incapaz de seguir el comportamiento anómalo debido a los fenómenos climáticos, sin embargo, existe una mejor comprensión de los patrones frente al modelo ARIMA.




Figura 21. Predicción del consumo energético (2014-2024) con SARIMA Desagregado (Fuente: Elaboración Propia).

La Tabla 12 muestra la comparativa de los modelos SARIMA excluyendo los datos del 2024 y con los datos en su totalidad, el Modelo Desagregado SARIMA (2014-2023) no mejora los

datos frente al modelo ARIMA debido a la mencionado anteriormente, sin embargo, en condiciones anómalas el Modelo Desagregado SARIMA (2014-2024) presenta mejores métricas, lo que demuestra que el modelo SARIMA en este contexto se adapta mejor al comportamiento energético del país.

Esto reafirma que, en series con eventos extremos o cambios recientes no estacionales los modelos ARIMA pueden ser competitivos e incluso superar a SARIMA en ciertos contextos. No obstante, ante patrones anómalos persistentes como los del 2024, SARIMA ofrece una mayor capacidad de adaptación.

Dado que tanto ARIMA como SARIMA son modelos estadísticos lineales, en la siguiente etapa se explorarán modelos de aprendizaje profundo basados en redes neuronales recurrentes (LSTM), con el objetivo de capturar de forma más efectiva la dinámica no lineal y las dependencias temporales complejas del consumo energético nacional.

Tabla 12. Comparativas de las Métricas de los Modelo SARIMA Desagregado (Fuente: Elaboración Propia).

Métrica	Modelo Desagregado (2014-2023)	Modelo Desagregado (2014-2024)
RMSE	179.17 GWh	159.20 GWh
MAE	168.15 GWh	140.44 GWh
MAPE	8.46 %	7.56 %

Cabe señalar que, se consideró inicialmente la inclusión del modelo SARIMAX, una extensión de SARIMA que permite incorporar variables exógenas, no fue incluido en el estudio final. La razón principal radica en que las variables externas disponibles, como el Producto Interno Bruto (PIB) y la Inflación, presentaban únicamente variaciones anuales, mientras que el modelo opera a una escala temporal mensual.

Esta desalineación temporal limitó su capacidad para aportar mejoras significativas en las predicciones mensuales. De hecho, en los intentos realizados, la incorporación de estas variables no generó un valor predictivo adicional y, en algunos casos, incluso deterioró el

rendimiento del modelo. Por tanto, se optó por centrar el análisis en modelos puramente univariantes.

4.4. Etapa 4: Desarrollo de modelos de Redes Neuronales Recurrentes

Tras evaluar los modelos estadísticos ARIMA y SARIMA, se identificaron limitaciones en su capacidad para capturar patrones no lineales y adaptarse a comportamientos anómalos en los datos de consumo energético. Para superar estas restricciones, se exploraron modelos de aprendizaje profundo, específicamente las Redes Neuronales Recurrentes (RNN), que son adecuadas para procesar datos secuenciales y modelar dependencias temporales.

Dentro de las RNN, se implementaron dos arquitecturas: *Long Short-Term Memory* (LSTM) y *Bidirectional LSTM* (BiLSTM). Las LSTM están diseñadas para aprender dependencias a largo plazo en secuencias temporales mientras que las BiLSTM procesan la información en ambas direcciones temporales lo que permite capturar contextos pasados y futuros simultáneamente. Estas características hacen que ambas arquitecturas sean especialmente útiles para modelar series temporales complejas, como las de consumo energético, que pueden presentar patrones estacionales y tendencias no lineales.

El desarrollo de estos modelos se basó en metodologías establecidas en la literatura, adaptadas al contexto específico del estudio. Se siguieron prácticas comunes en la implementación de modelos LSTM para series temporales incluyendo la preparación adecuada de los datos, la selección de hiperparámetros y la evaluación del rendimiento del modelo. Estas metodologías han sido ampliamente documentadas y validadas en estudios previos, lo que proporciona una base sólida para su aplicación en este trabajo.

4.4.1. Implementación del modelo Long Short-Term Memory (LSTM)

Las redes LSTM (*Long Short-Term Memory*) son una arquitectura especializada dentro de las redes neuronales recurrentes (RNN), diseñada para capturar dependencias de largo plazo en secuencias temporales. A diferencia de las RNN tradicionales, las LSTM incorporan mecanismos de compuertas (puertas de entrada, olvido y salida) que permiten preservar información relevante durante múltiples pasos temporales y mitigar problemas de desvanecimiento del gradiente.

En esta etapa, se implementa un modelo LSTM para predecir el consumo energético mensual a nivel nacional utilizando series históricas desagregadas por grupo de consumo y ubicación

geográfica. El modelo se entrena con ventanas móviles de datos secuenciales, codificando también la estacionalidad mediante funciones seno y coseno, y el grupo de consumo mediante embeddings.

Este enfoque busca capturar tanto patrones temporales como características contextuales que influyen en la demanda energética. Cabe destacar que el modelo LSTM implementado se entrena únicamente con variables endógenas, es decir, aquellas que pertenecen a la propia serie temporal (consumo energético, coordenadas y estacionalidad). No se incorporan variables exógenas como el PIB, inflación ya que estas no presentan variación mensual consistente ni suficiente granularidad temporal para ser utilizadas como entradas efectivas.

La metodología sigue la misma forma de tratamiento de los datos que en la Etapa 3, primero los datos son filtrados y se eliminan los valores negativos los cuales pueden causar errores en los modelos, luego se identifican las combinaciones de grupo de consumo + coordenadas geográficas que tienen al menos 119 meses de datos (casi 10 años), garantizando una longitud mínima para el entrenamiento de redes neuronales. El DataFrame se agrupa por mes, grupo de consumo y coordenadas, y se suma el consumo energético para tener una serie por cada combinación. Se añaden componentes estacionales usando funciones seno y coseno para capturar la ciclicidad anual. Además, se codifican los grupos de consumo mediante `LabelEncoder` para poder introducirlos como variable categórica embebida en la red. Las variables que se utilizan en el modelo son:

- `Energia_GWh`: Es la variable principal que se desea predecir.
- `Mes_sin` `Mes_cos`: Codifican la estacionalidad mensual mediante transformaciones trigonométricas (una técnica común para redes neuronales).
- `Latitud`, `Longitud`: Representan la ubicación geográfica.
- `Grupo_Consumo_Cod`: Codifica de forma numérica el tipo de grupo de consumo (`Residencial`, `Comercial`, Etc.), y se usa mediante capa de Embedding.

Las redes LSTM trabajan con secuencias temporales como entrada. Por eso, se construyen ventanas deslizantes de datos (también llamadas *sliding windows*) para que el modelo aprenda patrones a lo largo del tiempo. Se define el tamaño de la ventana de entrada, 12 pasos anteriores (meses) se usarán para predecir el siguiente. El proceso de generación de las series se da para cada serie única definida por el Grupo de Consumo + Coordenadas, en primer

lugar, se ordenan por fecha, se toma una secuencia de 12 meses, la cual contiene 5 columnas en donde el objetivo es el valor de energía del siguiente mes. Este proceso resulta en:

- Un tensor 3D con todas las secuencias de entrada.
- Un vector con los valores reales a predecir.
- Un vector con el código del grupo de consumo (para el *embedding*).
- Un vector con las fechas correspondientes a los valores reales.
- Tuplas que identifican la serie (*latitud*, *longitud*, *grupo_cod*)

Luego, con el fin de comparar los modelos en igualdad de condiciones, se separan las muestras de entrenamiento y prueba por tiempo como se realiza en la Etapa 3. Esto se realiza porque se desea simular una predicción futura, asegurándonos de que el modelo no vea ningún dato de prueba durante el entrenamiento. Esto permite una evaluación justa con las métricas en el conjunto de prueba.

Para esta etapa, se diseñó un modelo LSTM enriquecido que va más allá de la arquitectura secuencial básica. La propuesta integra múltiples fuentes de información para mejorar la capacidad predictiva del modelo sobre series temporales complejas y heterogéneas como el consumo energético mensual. Además de la variable principal (energía consumida en GWh), se incorporaron variables estacionales (seno y coseno del mes) y coordenadas geográficas (latitud y longitud) como características adicionales. Asimismo, se utilizó una capa de *embedding* para representar el grupo de consumo como un vector denso aprendido durante el entrenamiento, lo cual permite capturar diferencias estructurales entre categorías de usuarios. Esta representación fue fusionada tempranamente con la secuencia principal mediante concatenación, permitiendo que la red neuronal recurrente integre el contexto desde las primeras etapas del procesamiento. La arquitectura contempla dos capas LSTM apiladas con regularización mediante dropout, seguidas de capas densas para la predicción final. Esta configuración busca capturar tanto los patrones temporales como las influencias estructurales y estacionales presentes en los datos.

Una vez estructurada la arquitectura del modelo LSTM, se predice el primer conjunto de datos excluyendo los datos anómalos del 2024, la Figura 22 muestra los valores predichos por el modelo, se logra observar que el modelo logra capturar los picos naturales de la curva

energética, el modelo captura la tendencia creciente hacia mitad de año, sin embargo, en algunos picos y valles, como julio y diciembre, el modelo subestima o sobreestima el consumo.




Figura 22. Predicción del consumo energético (2014-2023) con LSTM Desagregado (Fuente: Elaboración Propia).

En la Tabla 13 se muestran los resultados de las métricas del modelo LSTM, en promedio, el modelo se equivoca por 51 GWh mensuales, el error relativo medio es menor al 3 % respecto al consumo real. El modelo LSTM desagregado logra un ajuste bastante bueno a nivel mensual, pero tiende a suavizar los extremos. Esto concuerda con los buenos valores de MAE/MAPE, aunque no alcanza a modelar bien la variabilidad interna.

Tabla 13. Métricas del Modelo LSTM Desagregado (Fuente: Elaboración Propia).

Métrica	Valor
RMSE	68.00 GWh
MAE	51.01 GWh
MAPE	2.65 %

El modelo LSTM desagregado implementado presenta un muy buen rendimiento en términos de error absoluto y porcentual, superando claramente a los modelos estadísticos ARIMA y SARIMA utilizados previamente. Este escenario prometedor permite incluir el análisis del modelo en situaciones poco frecuentes como las del 2024.

La Figura 23 muestra la curva predicha del modelo LSTM frente a fenómenos climáticos para el año 2024, el modelo captura el pico inicial de enero-marzo, y luego acompaña la tendencia decreciente, aunque con menos pendiente que la curva real, la zona más difícil de predecir (junio–diciembre) es donde el modelo comete mayores errores, pero mantiene una forma lógica y consistente, a diferencia de ARIMA y SARIMA, la LSTM ajusta mejor la dinámica general, aunque suaviza extremos.




Figura 23. Predicción del consumo energético (2014-2024) con LSTM Desagregado (Fuente: Elaboración Propia).

La Tabla 14 muestra la comparativa de los resultados obtenidos por los dos modelos frente a situaciones diferentes, el error absoluto medio mensual sube respecto al año anterior (2023), lo cual es esperable dada la alta variabilidad del 2024, a pesar de los cambios abruptos en 2024, el error relativo es inferior al 8 %, lo cual sigue siendo aceptable en contextos energéticos.

El modelo LSTM desagregado logra un rendimiento notablemente más robusto que los modelos estadísticos (ARIMA, SARIMA) ante el comportamiento anómalo del año 2024. Aunque sus métricas empeoran respecto al 2023, esto es completamente esperable en presencia de eventos exógenos no incluidos como variables del modelo, y las gráficas de las curvas demuestran que el modelo logra captar el entendimiento de los fenómenos.

La implementación del modelo *Long Short-Term Memory* (LSTM) aplicado de forma desagregada por grupo de consumo y coordenadas geográficas ha demostrado una mejora

significativa en la capacidad predictiva frente a los modelos estadísticos evaluados anteriormente (ARIMA y SARIMA). A través de un tratamiento exhaustivo de los datos y la generación de secuencias temporales con información contextual (latitud, longitud y estacionalidad), el modelo logra captar patrones energéticos complejos a nivel nacional.

Tabla 14. Comparativas de las Métricas de los Modelo LSTM Desagregado (Fuente: Elaboración Propia).

Métrica	Modelo LSTM Desagregado (2014-2023)	Modelo LSTM Desagregado (2014-2024)
RMSE	68.00 GWh	158.18 GWh
MAE	51.01 GWh	143.16 GWh
MAPE	2.65 %	7.80 %

Durante el periodo de evaluación para el año 2023, el modelo LSTM presentó errores absolutos y relativos considerablemente inferiores a los modelos clásicos. Frente a un escenario anómalo como el del año 2024, el modelo mantuvo una estructura coherente en sus predicciones, aunque sus errores aumentaron con respecto al 2023, el modelo denota un entendimiento del comportamiento del consumo eléctrico.

En resumen, el modelo LSTM desagregado constituye una base sólida para la predicción del consumo energético, al integrar información contextual y estacional con arquitectura secuencial avanzada. No obstante, su diseño puede enriquecerse aún más mediante arquitecturas bidireccionales que capturen patrones pasados y futuros simultáneamente, como las redes BiLSTM, que serán exploradas en la siguiente Sección.

4.4.2. Implementación del modelo Bidirectional LSTM (BiLSTM)

Las redes BiLSTM (*Bidirectional Long Short-Term Memory*) son una extensión de las redes LSTM convencionales que permiten procesar la información secuencial en dos direcciones: hacia adelante (pasado a futuro) y hacia atrás (futuro a pasado). Esta arquitectura resulta especialmente útil en contextos donde el conocimiento de lo que ocurre antes y después de un determinado punto temporal puede enriquecer la capacidad predictiva del modelo. En el

caso del consumo energético mensual, donde pueden existir patrones estacionales, retardos o dependencias estructurales tanto anteriores como posteriores a un punto de predicción, el uso de BiLSTM puede ofrecer una representación más completa de la dinámica subyacente.

En esta Etapa se desarrolla un modelo BiLSTM basado en la misma metodología de preprocesamiento y estructura de datos utilizada en la etapa anterior (LSTM). El objetivo es evaluar si el uso de esta arquitectura bidireccional mejora el ajuste del modelo, especialmente en series energéticas con alta variabilidad o influencias no lineales más complejas.

En esta Etapa se mantiene el mismo flujo de preprocesamiento, generación de secuencias y partición temporal de datos descrito previamente en la Etapa 4.4.1. El objetivo es asegurar la comparabilidad directa entre modelos. La principal diferencia radica en la arquitectura de red neuronal implementada, que en este caso incorpora una estructura Bidirectional LSTM (BiLSTM) para mejorar la captura de patrones temporales complejos.

A nivel de arquitectura, se mantuvieron las mismas variables de entrada utilizadas en el modelo LSTM anterior: la energía consumida, los componentes estacionales (seno y coseno del mes), las coordenadas geográficas (latitud y longitud) y una codificación del grupo de consumo mediante embeddings. Sin embargo, en este modelo se introducen dos innovaciones principales:

- Capas bidireccionales (Bidirectional LSTM): se apilan dos capas LSTM envueltas en capas Bidirectional, permitiendo a la red procesar las secuencias de entrada en ambos sentidos temporales. Esto mejora su capacidad de capturar patrones más complejos y simétricos en la evolución del consumo energético.
- Capas densas con activación LeakyReLU: en lugar de la función de activación ReLU estándar, se optó por LeakyReLU, que permite un pequeño gradiente incluso cuando la neurona no se activa. Esto ayuda a evitar el problema de “muerte de neuronas” y mejora la capacidad de aprendizaje del modelo.

En la Figura 24 se muestra la curva predicha para el 2023 del modelo BiLSTM, aunque el modelo BiLSTM incorpora mayor capacidad para capturar dependencias en ambas direcciones temporales, no aporta mejoras significativas frente a la arquitectura LSTM estándar en este conjunto de datos y ventana de predicción.




Figura 24. Predicción del consumo energético (2014-2023) con BiLSTM Desagregado (Fuente: Elaboración Propia).

La Tabla 15 muestra las métricas del modelo BiLSTM, en general no se encuentra mejoría frente al modelo LSTM, de hecho, el desempeño es comparable e incluso ligeramente inferior en algunos indicadores clave. Esto puede deberse a motivos como que el consumo energético tiene una tendencia fuertemente direccional (del pasado hacia el futuro), lo que hace que las dependencias hacia atrás (BiLSTM) no aporten demasiada información adicional o la arquitectura LSTM original ya es suficientemente expresiva para este tipo de series desagregadas.

Tabla 15. Métricas del Modelo BiLSTM Desagregado (Fuente: Elaboración Propia).

Métrica	Valor
RMSE	64.92 GWh
MAE	58.23 GWh
MAPE	2.96 %

Para los valores del año 2024, la Figura 25 muestra los valores predichos, mientras que las comparativas de las métricas se muestran en la Tabla 16, en general no se observa una mejora significativa en las métricas de los resultados del modelo BiLSTM frente a el modelo LSTM.




Figura 25. Predicción del consumo energético (2014-2024) con BiLSTM Desagregado (Fuente: Elaboración Propia).

Tras la implementación y evaluación del modelo Bidireccional LSTM (BiLSTM) para la predicción del consumo energético mensual en Ecuador, se observó que esta arquitectura no aporta mejoras significativas respecto al modelo LSTM tradicional previamente implementado. Si bien el BiLSTM permite procesar la secuencia temporal en ambas direcciones capturando potencialmente información del pasado y del futuro cercano en cada punto de la secuencia, los resultados no reflejan una ventaja clara.

Tabla 16. Comparativas de las Métricas de los Modelo BiLSTM Desagregado (Fuente: Elaboración Propia).

Métrica	Modelo BiLSTM Desagregado (2014-2023)	Modelo BiLSTM Desagregado (2014-2024)
RMSE	64.92 GWh	156.30 GWh
MAE	58.23 GWh	143.10 GWh
MAPE	2.96 %	7.75 %

Estos resultados sugieren que, en el contexto específico del consumo energético en Ecuador, la incorporación de la bidireccionalidad no ofrece un valor añadido significativo. Este resultado

no invalida el uso de arquitecturas más complejas, pero resalta que, en ciertos contextos como este, la simplicidad estructural puede ofrecer resultados más robustos y eficientes en comparación con modelos más sofisticados. Sin olvidar que, pese a no ofrecer una mejora sustancial en rendimiento, el modelo BiLSTM implica un mayor costo computacional debido a la duplicación de parámetros en las capas bidireccionales.

La implementación de modelos de redes neuronales recurrentes, tanto LSTM como BiLSTM, ha demostrado una mejora significativa en la capacidad predictiva respecto a los enfoques estadísticos ARIMA y SARIMA. En particular, el modelo LSTM desagregado logra los mejores resultados en términos de error absoluto y relativo para el año 2023, capturando con precisión las tendencias generales y los picos energéticos.

Por su parte, el modelo BiLSTM no evidenció una mejora sustancial frente a su contraparte unidireccional, lo cual sugiere que en este contexto el consumo energético responde mayoritariamente a patrones temporales causales donde la bidireccionalidad no aporta un valor predictivo adicional. No obstante, la exploración de BiLSTM permitió validar empíricamente esta hipótesis y fortalecer la robustez metodológica del estudio.

Esta etapa consolida el uso de LSTM como base efectiva para la predicción del consumo energético mensual en Ecuador, estableciendo un punto de partida sólido para futuras mejoras, como el uso de arquitecturas híbridas, mecanismos de atención o incorporación de variables exógenas más frecuentes.

4.5. Etapa 5: Evaluación comparativa y análisis de robustez

Luego de la implementación de los modelos estadísticos y de aprendizaje profundo en las etapas anteriores, esta Sección tiene como propósito realizar una evaluación sistemática de su rendimiento comparando sus capacidades predictivas bajo dos escenarios distintos: un periodo regular sin anomalías (año 2023) y un periodo con comportamiento energético atípico debido a eventos climáticos extremos (año 2024).

La evaluación busca determinar cuál de los enfoques desarrollados ofrece mejores resultados en términos de precisión y estabilidad, permitiendo validar empíricamente la hipótesis central del estudio: que los modelos basados en redes neuronales recurrentes superan en rendimiento a los enfoques tradicionales para la predicción del consumo energético mensual en Ecuador.

Para ello, se estructura la presente etapa en dos secciones principales. La primera se enfoca en la comparación directa de las métricas de error obtenidas por cada modelo en el año 2023 considerado como un año de condiciones normales. La segunda examina el comportamiento de los modelos ante un contexto adverso y no recurrente como el del 2024 evaluando su capacidad de adaptación y robustez frente a datos disruptivos, tales como los generados por el fenómeno de El Niño y la crisis energética nacional.

Mediante este análisis se busca no solo identificar el modelo más preciso, sino también comprender sus limitaciones, sensibilidad ante cambios inesperados y consistencia en diferentes condiciones del sistema eléctrico. Este enfoque comparativo es esencial para proponer soluciones predictivas confiables en escenarios reales donde la incertidumbre es inherente.

4.5.1. Comparación de Modelos

En esta Sección se presenta una comparación cuantitativa del desempeño de los modelos implementados para la predicción del consumo energético mensual en Ecuador, evaluados exclusivamente sobre el conjunto de prueba correspondiente al año 2023. Este periodo representa un escenario sin eventos climáticos extremos, permitiendo una evaluación bajo condiciones normales de comportamiento energético.

Se incluyen los siguientes modelos:

- ARIMA (1,1,1): modelo estadístico clásico aplicado a la serie nacional agregada.
- ARIMA Desagregado: modelos ARIMA individuales por serie (grupo de consumo + coordenadas).
- SARIMA Desagregado: modelos SARIMA individuales con componentes estacionales.
- LSTM Desagregado: red neuronal recurrente unidireccional con codificación contextual.
- BiLSTM Desagregado: red neuronal bidireccional con arquitectura expandida.

Los resultados de la Tabla 17, demuestran que el modelo LSTM desagregado obtuvo el mejor desempeño global en 2023, alcanzando los valores más bajos en las tres métricas. Este modelo logra un RMSE de 68.00 GWh y un MAPE de 2.65 %, lo cual representa una mejora significativa frente a los modelos estadísticos.

Tabla 17. Comparación de modelos predictivos del Año 2023 (Fuente: Elaboración Propia).

Modelo	RMSE (GWh)	MAE (GWh)	MAPE (%)
ARIMA (1,1,1)	123.03	108.79	5.43
ARIMA Desagregado	118.09	97.25	4.88
SARIMA Desagregado	179.17	168.15	8.46
LSTM Desagregado	68.00	51.01	2.65
BiLSTM Desagregado	64.92	58.23	2.96

Aunque el modelo BiLSTM desagregado mostró un RMSE ligeramente menor (64.92 GWh), su MAE fue superior al del modelo LSTM lo que indica mayor variabilidad en sus errores. Además, su implementación conlleva una mayor complejidad computacional, sin representar una ventaja significativa en precisión.

En cambio, los modelos estadísticos desagregados (ARIMA y SARIMA) lograron mejorar ligeramente los resultados respecto al primer modelo ARIMA desarrollado lo cual confirma que la desagregación permite capturar mejor la heterogeneidad espacial y sectorial del consumo energético. Sin embargo, su capacidad de modelar dinámicas no lineales fue inferior frente a las redes neuronales, reflejándose en métricas de error más altas.

En resumen, los modelos basados en redes neuronales recurrentes, y en particular la arquitectura LSTM, ofrecieron un mejor ajuste a los patrones energéticos observados durante el 2023, confirmando su idoneidad para tareas de predicción bajo condiciones normales del sistema eléctrico ecuatoriano.

4.5.2. Análisis de robustez ante eventos anómalos

El año 2024 representó un escenario energético atípico en Ecuador, marcado por la influencia del fenómeno de El Niño y una profunda crisis hidroeléctrica que afectó la oferta y demanda del sistema eléctrico nacional. Estas condiciones generaron caídas abruptas en el consumo energético mensual interrumpiendo patrones estacionales previamente observados. Este contexto se convierte en una oportunidad para evaluar la robustez de los modelos

Erick Manuel Mendoza Pico
Comparativa del desempeño entre redes neuronales recurrentes y modelos estadísticos en la predicción del consumo energético en Ecuador
implementados, entendida como su capacidad de mantener un rendimiento aceptable ante cambios extremos o no anticipados en la serie temporal.

Para ello, se replicó el proceso de entrenamiento de cada modelo esta vez incluyendo los datos hasta diciembre de 2023 y utilizando el año 2024 como conjunto de prueba. La Tabla 18 muestra las métricas de desempeño obtenidas por cada modelo bajo estas condiciones.

Tabla 18. Comparación de modelos predictivos del Año 2024 (Fuente: Elaboración Propia).

Modelo	RMSE (GWh)	MAE (GWh)	MAPE (%)
ARIMA (1,1,1)	181.99	157.88	8.63
ARIMA Desagregado	177.86	155.22	8.38
SARIMA Desagregado	159.20	140.44	7.56
LSTM Desagregado	158.18	143.16	7.80
BiLSTM Desagregado	156.30	143.10	7.75

Los resultados muestran que todos los modelos experimentaron un deterioro en su rendimiento respecto al año anterior, lo cual es esperable dado el comportamiento anómalo del 2024. Sin embargo, se observan diferencias importantes en la capacidad de cada enfoque para adaptarse a este nuevo contexto.

En primer lugar, el modelo SARIMA desagregado logra los mejores resultados en términos de RMSE y MAPE. Su capacidad para modelar patrones estacionales permitió una mejor adaptación al cambio, aunque con errores absolutos aún elevados. Este comportamiento sugiere que SARIMA, pese a sus limitaciones estructurales, puede ofrecer cierto nivel de amortiguación ante eventos repetitivos que aún conservan alguna estacionalidad interna.

Los modelos LSTM y BiLSTM desagregados, si bien no superaron a SARIMA en este escenario, lograron mantener una curva de predicción coherente y estructurada sin los colapsos observados en ARIMA. Sus errores absolutos se mantuvieron en niveles aceptables considerando la magnitud de las anomalías, y sus gráficas evidencian una mejor captación de la tendencia decreciente frente a modelos puramente lineales.

Finalmente, los modelos ARIMA (agregado y desagregado) fueron los más afectados, con errores cercanos a los 180 GWh en RMSE lo que evidencia poca capacidad para reaccionar ante rupturas de patrón o eventos fuera de la media histórica. Esto refleja su sensibilidad al ruido y su dependencia de la linealidad de la serie.

En resumen, ante condiciones adversas, los modelos estadísticos tradicionales se vieron superados por modelos con componentes estacionales (SARIMA) y, en menor medida, por redes neuronales recurrentes. Aunque estas últimas no lograron replicar la precisión alcanzada en 2023, demostraron una mayor estabilidad estructural en sus predicciones, lo que las posiciona como herramientas más robustas para contextos energéticos altamente variables.

4.5.3. Conclusiones de la Evaluación

El análisis comparativo realizado entre modelos estadísticos tradicionales (ARIMA, SARIMA) y modelos de redes neuronales recurrentes (LSTM, BiLSTM) permite extraer conclusiones sólidas sobre el rendimiento y la aplicabilidad de cada enfoque en el contexto del consumo energético mensual en Ecuador.

En primer lugar, los resultados obtenidos en el año 2023 evidencian que los modelos basados en aprendizaje profundo, en particular el modelo LSTM desagregado ofrecen una mejor capacidad de predicción frente a los métodos estadísticos. Este modelo logra los menores errores absolutos y relativos (RMSE: 68 GWh, MAPE: 2.65 %), capturando con mayor precisión la dinámica del consumo energético bajo condiciones normales. La arquitectura LSTM permitió modelar no solo las tendencias generales, sino también los picos y valles asociados a patrones estacionales y comportamientos regionales.

En segundo lugar, el análisis de robustez ante eventos anómalos durante el año 2024 reveló que, si bien todos los modelos sufrieron una pérdida de precisión los enfoques con mayor estructura contextual (SARIMA y LSTM) mantuvieron un comportamiento más estable y coherente. En este escenario, el modelo SARIMA desagregado obtuvo las mejores métricas absolutas. Por su parte, el modelo LSTM demostró mayor consistencia en la forma general de la curva predicha. Esto sugiere que, si bien los modelos estadísticos con estacionalidad logran ajustarse parcialmente a condiciones inusuales, las redes neuronales presentan una mayor flexibilidad para adaptarse a dinámicas no lineales complejas.

Asimismo, se confirmó que la desagregación por grupo de consumo y coordenadas geográficas mejora de manera sistemática el rendimiento predictivo independientemente del tipo de modelo utilizado. Este enfoque permitió capturar patrones locales, evitar el efecto de promedios nacionales y fortalecer la capacidad de generalización de los modelos ante comportamientos heterogéneos.

Finalmente, la comparación entre LSTM y BiLSTM mostró que, en este caso particular, la bidireccionalidad no aporta mejoras sustanciales. Esto refuerza la idea de que el consumo energético en Ecuador responde principalmente a dinámicas causales unidireccionales (del pasado hacia el futuro), en las cuales el conocimiento del “futuro” no aporta mayor valor predictivo en arquitecturas recurrentes.

En conjunto, los resultados validan la hipótesis planteada al inicio del estudio: los modelos de redes neuronales recurrentes, y en particular LSTM, superan en precisión a los modelos tradicionales para la predicción del consumo energético mensual, y ofrecen una mayor robustez ante escenarios de alta variabilidad.

4.6. Recomendaciones para la planificación energética

La última etapa de este Capítulo tiene como propósito traducir los hallazgos técnicos y experimentales obtenidos en las etapas anteriores en recomendaciones aplicables al ámbito de la planificación energética nacional. Considerando la evidencia empírica generada mediante la comparación entre modelos estadísticos y de aprendizaje profundo, esta Sección identifica los beneficios, limitaciones y aplicaciones potenciales de los modelos predictivos desarrollados en escenarios reales del sistema eléctrico ecuatoriano.

Se parte del reconocimiento de que la precisión en la estimación de la demanda energética mensual es un componente fundamental para la toma de decisiones estratégicas, tanto en el corto como en el mediano plazo. La planificación de generación, distribución, mantenimiento de redes y gestión de contingencias depende directamente de la calidad de las proyecciones disponibles. En este sentido, disponer de modelos robustos y adaptables que anticipen cambios en el comportamiento del consumo es crucial para fortalecer la seguridad energética del país.

A continuación, se presentan una serie de recomendaciones orientadas a los organismos de regulación, operadores del sistema eléctrico y actores involucrados en la planificación energética, basadas en los resultados obtenidos a lo largo del estudio.

4.6.1. Recomendaciones técnicas

- Adoptar modelos basados en redes neuronales recurrentes como LSTM para la predicción mensual del consumo energético, dado que han demostrado superar en precisión a los modelos estadísticos tradicionales en escenarios normales y anómalos.
- Incluir variables estacionales y geográficas (como mes, latitud, longitud) y codificar atributos categóricos (como el grupo de consumo) mediante embeddings, lo cual mejora la capacidad del modelo para representar patrones complejos.
- Incluir variables climatológicas, debido a la dependencia hidroeléctrica del país, proporcionar variables que permitan al modelo comprender la importancia del clima en el consumo contribuiría a un modelo más robusto.
- Mantener actualizada la base de datos energética mensual, con control de calidad y consistencia, para asegurar que los modelos se entrenen con información completa y confiable.

4.6.2. Recomendaciones operativas

- Integrar los modelos predictivos en los sistemas de monitoreo y planificación del Operador Nacional de Electricidad, para anticipar cambios en la demanda energética con al menos 12 meses de proyección.
- Automatizar el flujo de trabajo de predicción mensual, incorporando la actualización periódica de datos y el reentrenamiento del modelo, de forma que las estimaciones se ajusten a nuevos patrones de consumo en tiempo real.
- Utilizar visualizaciones interactivas del consumo proyectado por región y grupo de consumo, que faciliten la interpretación de resultados para técnicos y tomadores de decisión del sector eléctrico.
- Capacitar al personal técnico en el uso e interpretación de modelos de inteligencia artificial, con énfasis en sus ventajas, limitaciones y requerimientos de datos.

4.6.3. Recomendaciones estratégicas

- Incorporar estos modelos en los procesos de planificación energética nacional, tanto para escenarios de oferta-demanda como para la toma de decisiones sobre expansión de infraestructura.
- Fortalecer la resiliencia del sistema eléctrico mediante la simulación de escenarios extremos (El Niño, crisis hídrica) usando modelos como LSTM, que han demostrado mayor estabilidad estructural ante eventos inesperados.
- Fomentar una cultura de análisis predictivo en las instituciones públicas y privadas del sector eléctrico, integrando técnicas de inteligencia artificial como herramientas de apoyo a la política energética.
- Establecer alianzas entre centros de investigación, universidades y entidades energéticas, para continuar desarrollando modelos híbridos y de mayor complejidad que incorporen variables exógenas relevantes (clima, economía, movilidad).

5. Conclusiones y Trabajo a Futuro

Este Capítulo presenta las principales conclusiones del estudio, estableciendo el grado de cumplimiento de los objetivos planteados y destacando los hallazgos más relevantes en cuanto al desempeño comparativo entre modelos estadísticos y redes neuronales recurrentes para la predicción del consumo energético en Ecuador. En la Sección 5.1 se resumen los resultados obtenidos y se valida la hipótesis de investigación. Posteriormente, en la Sección 5.2, se plantean líneas futuras de investigación orientadas a mejorar la precisión y aplicabilidad de los modelos desarrollados, así como a superar las limitaciones detectadas durante el desarrollo del trabajo.

5.1. Conclusiones

El presente estudio logra cumplir con el objetivo general planteado, evaluando la precisión de las redes neuronales recurrentes frente a los modelos estadísticos tradicionales en la predicción del consumo energético mensual en Ecuador. Los resultados demuestran que los modelos basados en inteligencia artificial, particularmente el modelo LSTM desagregado, superan ampliamente a los modelos ARIMA y SARIMA, tanto en condiciones normales como en escenarios anómalos. Este modelo alcanza los mejores resultados con un RMSE de 68 GWh, un MAE de 51 GWh y un MAPE de 2.65 % para el año 2023. Estas métricas evidencian una mejora sustancial frente a los modelos estadísticos, cuyos errores fueron superiores a los 100 GWh en RMSE y más del 5 % en MAPE. La implementación del LSTM desagregado podría contribuir directamente a mitigar los efectos de eventos meteorológicos extremos como los registrados en 2024 y aumentar la resiliencia del sistema eléctrico nacional.

En relación con el *Objetivo Específico 1 (OE1): Analizar la problemática existente del consumo energético en Ecuador entre 2014 y 2024, considerando la influencia de la variabilidad climática y sus implicaciones en la construcción de modelos predictivos precisos y robustos*, en la Sección 2.1 se identifica que la alta dependencia del Ecuador en fuentes hidroeléctricas (69 % en 2023) lo expone a una marcada vulnerabilidad frente a fenómenos climáticos como El Niño. Esta situación genera escenarios de inestabilidad energética y justifica la necesidad de utilizar herramientas predictivas más precisas y adaptables que permitan anticipar crisis y planificar con mayor eficacia.

En cuanto al *Objetivo Específico 2 (OE2): Estudiar el estado del arte de los métodos tradicionales y de inteligencia artificial aplicados a la predicción del consumo eléctrico, con énfasis en metodologías con características altamente variables*, el análisis realizado en la Sección 2.2 evidencia un notable rezago en la aplicación de técnicas de inteligencia artificial en el sector energético ecuatoriano, en contraste con el avance registrado en otros países. Este trabajo contribuye a reducir dicha brecha, acercando al contexto nacional modelos predictivos avanzados que demuestran efectividad a nivel internacional.

Respecto al *Objetivo Específico 3 (OE3): Preparar y estructurar el conjunto de datos para su uso en modelos de predicción, garantizando su calidad mediante técnicas de limpieza, transformación y selección de variables*, en las Secciones 4.1 y 4.2 se construye una base de datos robusta a partir de fuentes oficiales gubernamentales, con un riguroso proceso de preprocesamiento, normalización y estructuración. Esta calidad permite evaluar los modelos de forma justa y comparable, asegurando que los resultados reflejen con fidelidad el comportamiento real del consumo energético en Ecuador durante el período 2014–2024.

Con relación al *Objetivo Específico 4 (OE4): Implementar y comparar modelos tradicionales (ARIMA y SARIMA) y modelos basados en redes neuronales recurrentes (LSTM y BiLSTM), evaluando su rendimiento mediante métricas como RMSE, MAE y MAPE*, en las Secciones 4.3, 4.4 y 4.5 se implementan y comparan diversos modelos. El modelo LSTM desagregado obtiene la mayor precisión en condiciones normales (2023), mientras que BiLSTM, a pesar de su arquitectura más compleja, no mejora significativamente los resultados. En escenarios extremos como el año 2024, los modelos estadísticos experimentan un mayor deterioro en sus métricas (RMSE > 170 GWh en ARIMA), mientras que LSTM mantiene un RMSE de 158 GWh y un MAPE aceptable de 7.8 %, lo cual evidencia mayor capacidad de adaptación a cambios inesperados.

Finalmente, en el marco del *Objetivo Específico 5 (OE5): Evaluar la aplicabilidad de los modelos desarrollados para la planificación energética ecuatoriana, formulando recomendaciones basadas en la robustez y precisión observadas bajo escenarios complejos*, en la Sección 4.6 se formulan recomendaciones técnicas, operativas y estratégicas dirigidas a los organismos de regulación y planificación energética. Estas incluyen la incorporación de modelos LSTM en la planificación, el uso de variables geográficas y estacionales, y la capacitación institucional en inteligencia artificial para el sector eléctrico.

5.2. Líneas Futuras

Con base en las limitaciones encontradas y las oportunidades detectadas durante el desarrollo del presente trabajo, se proponen las siguientes líneas futuras de investigación, con el fin de mejorar la precisión de los modelos y fortalecer la planificación energética mediante inteligencia artificial:

1. Incorporación de variables meteorológicas y exógenas

Una de las principales oportunidades de mejora consiste en integrar variables climáticas relevantes como temperatura, precipitación, radiación solar o humedad relativa, las cuales inciden directamente en el consumo energético, especialmente en contextos altamente dependientes de la generación hidroeléctrica como el ecuatoriano (Deb et al., 2017). La incorporación de variables exógenas permite capturar con mayor precisión la influencia de eventos climáticos extremos como El Niño, aumentando la capacidad de los modelos para anticiparse a escenarios de crisis (Elias et al., 2011). Asimismo, se sugiere incluir variables macroeconómicas, como el PIB, el índice de producción industrial o indicadores de actividad comercial, puede mejorar el ajuste de los modelos en condiciones donde la variabilidad climática no explica completamente los cambios en la demanda energética (Dong et al., 2025).

2. Aplicación de modelos híbridos y arquitecturas modernas

Otra línea de investigación consiste en explorar modelos híbridos, como la combinación de ARIMA con redes LSTM, que aprovechan tanto la capacidad de modelado lineal como la no lineal de las series temporales (G. P. Zhang, 2003). Asimismo, arquitecturas modernas como los Transformers y las Redes Convolucionales Temporales (TCN) han demostrado gran potencial en la predicción de series con patrones complejos y alta variabilidad (Li et al., 2020). Estos modelos no solo mejoran la precisión, sino también la capacidad de generalización ante datos ruidosos o incompletos, lo cual resulta crucial en entornos reales con incertidumbre y limitaciones de infraestructura (Koh et al., 2021).

3. Mejora en la calidad y resolución del dataset energético

Una limitación estructural en este trabajo, compartida por muchos estudios en el campo, es la disponibilidad y resolución de los datos energéticos. En este caso, los registros disponibles

se presentan a nivel mensual y con desagregación geográfica limitada (provincia, cantón y parroquia), lo que reduce la granularidad temporal y espacial de la información (Mystakidis et al., 2024). Disponer de series con mayor frecuencia (diaria o semanal) y estructura coherente facilitaría la construcción de modelos más precisos y sensibles a cambios abruptos. En este sentido, se destaca la necesidad urgente de que los organismos públicos y las entidades del sector energético prioricen la recolección, estandarización y publicación de datos de calidad. La disponibilidad de datasets abiertos, actualizados y bien documentados representa un pilar fundamental para el desarrollo de soluciones basadas en inteligencia artificial que generen valor real tanto para la investigación como para la planificación energética estratégica (Faria y Vale, 2023).

Referencias bibliográficas

- Abbasimehr, H., Shabani, M., & Yousefi, M. (2020). An optimized model using LSTM network for demand forecasting. *Computers & Industrial Engineering*, 143, 106435. <https://doi.org/10.1016/j.cie.2020.106435>
- Alamaniotis, M., Bargiotas, D., & Tsoukalas, L. H. (2016). Towards smart energy systems: Application of kernel machine regression for medium term electricity load forecasting. *SpringerPlus*, 5(1), 58. <https://doi.org/10.1186/s40064-016-1665-z>
- Alharbi, F. R., & Csala, D. (2022). A Seasonal Autoregressive Integrated Moving Average with Exogenous Factors (SARIMAX) Forecasting Model-Based Time Series Approach. *Inventions*, 7(4), 94. <https://doi.org/10.3390/inventions7040094>
- Alizadegan, H., Rashidi Malki, B., Radmehr, A., Karimi, H., & Ilani, M. A. (2025). Comparative study of long short-term memory (LSTM), bidirectional LSTM, and traditional machine learning approaches for energy consumption prediction. *Energy Exploration & Exploitation*, 43(1), 281-301. <https://doi.org/10.1177/01445987241269496>
- Al-Shammari, E. T., Keivani, A., Shamshirband, S., Mostafaeipour, A., Yee, P. L., Petković, D., & Ch, S. (2016). Prediction of heat load in district heating systems by Support Vector Machine with Firefly searching algorithm. *Energy*, 95, 266-273. <https://doi.org/10.1016/j.energy.2015.11.079>
- ARCONEL. (2023). *Reporte anual del sector eléctrico ecuatoriano*.
- Aristizábal, D. S. O. (2024). *Comparación de modelos de series temporales ARIMA, SARIMAX y LSTM para la predicción del índice COLCAP*. EAFIT.

- Azadeh, A., Ghaderi, S. F., & Sohrabkhani, S. (2008). A simulated-based neural network algorithm for forecasting electrical energy consumption in Iran. *Energy Policy*, 36(7), 2637-2644. <https://doi.org/10.1016/j.enpol.2008.02.035>
- Bai, L., Li, F., Cui, H., Jiang, T., Sun, H., & Zhu, J. (2016). Interval optimization based operating strategy for gas-electricity integrated energy systems considering demand response and wind uncertainty. *Applied Energy*, 167, 270-279. <https://doi.org/10.1016/j.apenergy.2015.10.119>
- Bai, W., Zhu, J., Zhao, J., Cai, W., & Li, K. (2022). An Unsupervised Multi-Dimensional Representation Learning Model for Short-Term Electrical Load Forecasting. *Symmetry*, 14(10), 1999. <https://doi.org/10.3390/sym14101999>
- Barak, S., & Sadegh, S. S. (2016). Forecasting energy consumption using ensemble ARIMA–ANFIS hybrid algorithm. *International Journal of Electrical Power & Energy Systems*, 82, 92-104. <https://doi.org/10.1016/j.ijepes.2016.03.012>
- Bedi, J., & Toshniwal, D. (2019). Deep learning framework to forecast electricity demand. *Applied Energy*, 238, 1312-1326. <https://doi.org/10.1016/j.apenergy.2019.01.113>
- Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2016). *Time series analysis: Forecasting and control* (Fifth edition). John Wiley & Sons, Inc.
- Brownlee, J. (2016). *Master Machine Learning Algorithms—Discover How They Work and Implement Them From Scratch*.
- Camara, A., Feixing, W., & Xiuqin, L. (2016). Energy Consumption Forecasting Using Seasonal ARIMA with Artificial Neural Networks Models. *International Journal of Business and Management*, 11(5), 231. <https://doi.org/10.5539/ijbm.v11n5p231>

- Carpio Suarez, G., & Daga Lopez, P. (2019). *Aplicación de una red neuronal a un sistema eléctrico de distribución mediante el análisis de comportamiento de su carga en bajo voltaje* [Universidad Politécnica Salesiana].
<https://dspace.ups.edu.ec/bitstream/123456789/17859/1/UPS-CT008456.pdf>
- CEPAL. (2023). *Estudio económico de América Latina y el Caribe: El financiamiento de una transición sostenible : inversión para crecer y enfrentar el cambio climático*. Naciones Unidas, Comisión Económica para América Latina y el Caribe (CEPAL).
- Chicaiza Yugcha, O. F., Martínez Guaman, C. J., Orozco Manobanda, I. A., & Arellano Castro, Á. D. (2024). Previsión del consumo eléctrico en el cantón Salcedo mediante técnicas de aprendizaje automático. *REVISTA ODIGOS*, 5(1), 9-24.
<https://doi.org/10.35290/ro.v5n1.2024.1134>
- Chollet, F. (2021). *Deep learning with Python* (Second edition). Manning Publications.
- Chong, M., & Aguilar, R. (2016). *Proyección de Series de Tiempo para el Consumo de la Energía Eléctrica a Clientes Residenciales en Ecuador*. 29(1), 56-76.
- Chuan, L., & Ukil, A. (2015). Modeling and Validation of Electrical Load Profiling in Residential Buildings in Singapore. *IEEE Transactions on Power Systems*, 30(5), 2800-2809.
<https://doi.org/10.1109/TPWRS.2014.2367509>
- Contreras, J., Espinola, R., Nogales, F. J., & Conejo, A. J. (2003). ARIMA models to predict next-day electricity prices. *IEEE Transactions on Power Systems*, 18(3), 1014-1020.
<https://doi.org/10.1109/tpwrs.2002.804943>

Da Silva, D. G., & Meneses, A. A. D. M. (2023). Comparing Long Short-Term Memory (LSTM)

and bidirectional LSTM deep neural networks for power consumption prediction.

Energy Reports, 10, 3315-3334. <https://doi.org/10.1016/j.egyr.2023.09.175>

Deb, C., Zhang, F., Yang, J., Lee, S. E., & Shah, K. W. (2017). A review on time series forecasting

techniques for building energy consumption. *Renewable and Sustainable Energy*

Reviews, 74, 902-924. <https://doi.org/10.1016/j.rser.2017.02.085>

Debnath, K. B., & Mourshed, M. (2018). Forecasting methods in energy planning models.

Renewable and Sustainable Energy Reviews, 88, 297-325.

<https://doi.org/10.1016/j.rser.2018.02.002>

Dong, Q., Huang, R., Cui, C., Towey, D., Zhou, L., Tian, J., & Wang, J. (2025). Short-Term

Electricity-Load Forecasting by Deep Learning: A Comprehensive Survey. *Engineering*

Applications of Artificial Intelligence, 154, 110980.

<https://doi.org/10.1016/j.engappai.2025.110980>

Elias, R. S., Fang, L., & Wahab, M. I. M. (2011). Electricity load forecasting based on weather

variables and seasonalities: A neural network approach. *ICSSSM11*, 1-6.

<https://doi.org/10.1109/icsssm.2011.5959472>

Ember. (2024). *Global Electricity Review*. [https://ember-energy.org/latest-insights/global-](https://ember-energy.org/latest-insights/global-electricity-review-2024/)

[electricity-review-2024/](https://ember-energy.org/latest-insights/global-electricity-review-2024/)

Eskandarnia, E., & AlHammad, M. (2021). Predication of future energy consumption using

SARIMAX. *IET Conference Proceedings*, 2020(6), 657-662.

<https://doi.org/10.1049/icp.2021.0853>

- Fallah, S., Deo, R., Shojafar, M., Conti, M., & Shamshirband, S. (2018). Computational Intelligence Approaches for Energy Load Forecasting in Smart Energy Management Grids: State of the Art, Future Challenges, and Research Directions. *Energies*, 11(3), 596. <https://doi.org/10.3390/en11030596>
- Faria, P., & Vale, Z. (2023). Demand Response in Smart Grids. *Energies*, 16(2), 863. <https://doi.org/10.3390/en16020863>
- Fikru, M. G., & Gautier, L. (2015). The impact of weather variation on energy consumption in residential houses. *Applied Energy*, 144, 19-30. <https://doi.org/10.1016/j.apenergy.2015.01.040>
- Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, 270(2), 654-669. <https://doi.org/10.1016/j.ejor.2017.11.054>
- Gao, T., Niu, D., Ji, Z., & Sun, L. (2022). Mid-term electricity demand forecasting using improved variational mode decomposition and extreme learning machine optimized by sparrow search algorithm. *Energy*, 261, 125328. <https://doi.org/10.1016/j.energy.2022.125328>
- García, J. F. R. (2021). *ANÁLISIS DE PREDICCIÓN Y AGRUPACIÓN DE CONSUMO ELÉCTRICO EN LA PROVINCIA DE IMBABURA – ECUADOR PARA LA OPTIMIZACIÓN DE RECURSOS ENERGÉTICOS*. UNIVERSIDAD INTERNACIONAL SEK.
- Guamán, W., Benalcazar, P., Cordova-Garcia, J., & Torres, M. (2025). Machine Learning-Based Projections of Long-Term Electricity Consumption: The Case Study of Ecuador. En T. Guarda, F. Portela, & M. F. Augusto (Eds.), *Advanced Research in Technologies, Information, Innovation and Sustainability* (Vol. 2349, pp. 174-187). Springer Nature Switzerland. https://doi.org/10.1007/978-3-031-83432-5_12

- Günay, M. E. (2016). Forecasting annual gross electricity demand by artificial neural networks using predicted values of socio-economic indicators and climatic conditions: Case of Turkey. *Energy Policy*, 90, 92-101. <https://doi.org/10.1016/j.enpol.2015.12.019>
- Gundu, V., & Simon, S. P. (2021). PSO–LSTM for short term forecast of heterogeneous time series electricity price signals. *Journal of Ambient Intelligence and Humanized Computing*, 12(2), 2375-2385. <https://doi.org/10.1007/s12652-020-02353-9>
- Hajek, P., Godo, L., & Esteva, F. (2013). *Fuzzy Logic and Probability* (No. arXiv:1302.4953). arXiv. <https://doi.org/10.48550/arXiv.1302.4953>
- Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Hong, T., & Fan, S. (2016). Probabilistic electric load forecasting: A tutorial review. *International Journal of Forecasting*, 32(3), 914-938. <https://doi.org/10.1016/j.ijforecast.2015.11.011>
- Huang, Y., Yuan, Y., Chen, H., Wang, J., Guo, Y., & Ahmad, T. (2019). A novel energy demand prediction strategy for residential buildings based on ensemble learning. *Energy Procedia*, 158, 3411-3416. <https://doi.org/10.1016/j.egypro.2019.01.935>
- IEA. (2022). *World Energy Outlook 2022*. <https://www.iea.org/reports/world-energy-outlook-2022?language=es>
- International Energy Agency (IEA). (2022). *Electricity generation sources, Central & South America*. <https://www.iea.org/regions/central-south-america/electricity>
- Jaramillo, M., & Carrión, D. (2022). An Adaptive Strategy for Medium-Term Electricity Consumption Forecasting for Highly Unpredictable Scenarios: Case Study Quito,

<https://doi.org/10.3390/en15228380>

Jaramillo, M., Tipán, L., & Muñoz, J. (2022). A novel methodology for optimal location of reactive compensation through deep neural networks. *Heliyon*, 8(10), e11097.

<https://doi.org/10.1016/j.heliyon.2022.e11097>

Jason, C., & Erick, M. (2025). ESTUDIO DE LA CRISIS ENERGÉTICA EN EL ECUADOR POR LA DEPENDENCIA EN LA GENERACIÓN DE ENERGÍA HIDRÁULICA. *Revista Científica*, 8.

Kang, J., & Reiner, D. M. (2022). What is the effect of weather on household electricity consumption? Empirical evidence from Ireland. *Energy Economics*, 111, 106023.

<https://doi.org/10.1016/j.eneco.2022.106023>

Kelleher, J. D., Mac Namee, B., & D'Arcy, A. (2020). *Fundamentals of machine learning for predictive data analytics: Algorithms, worked examples, and case studies* (Second edition). The MIT Press.

Kelleher, J. D., MacNamee, B., & D'Arcy, A. (2015). *Fundamentals of machine learning for predictive data analytics: Algorithms, worked examples, and case studies*. The MIT Press.

Kobiela, D., Krefta, D., Król, W., & Weichbroth, P. (2022). ARIMA vs LSTM on NASDAQ stock exchange data. *Procedia Computer Science*, 207, 3836-3845.

<https://doi.org/10.1016/j.procs.2022.09.445>

Koh, B. H. D., Lim, C. L. P., Rahimi, H., Woo, W. L., & Gao, B. (2021). Deep Temporal Convolution Network for Time Series Classification. *Sensors*, 21(2), 603.

<https://doi.org/10.3390/s21020603>

- Kong, W., Dong, Z. Y., Jia, Y., Hill, D. J., Xu, Y., & Zhang, Y. (2019). Short-Term Residential Load Forecasting Based on LSTM Recurrent Neural Network. *IEEE Transactions on Smart Grid*, 10(1), 841-851. <https://doi.org/10.1109/tsg.2017.2753802>
- Kulshrestha, A., Krishnaswamy, V., & Sharma, M. (2020). Bayesian BILSTM approach for tourism demand forecasting. *Annals of Tourism Research*, 83, 102925. <https://doi.org/10.1016/j.annals.2020.102925>
- Law, R., Li, G., Fong, D. K. C., & Han, X. (2019). Tourism demand forecasting: A deep learning approach. *Annals of Tourism Research*, 75, 410-423. <https://doi.org/10.1016/j.annals.2019.01.014>
- Li, S., Jin, X., Xuan, Y., Zhou, X., Chen, W., Wang, Y.-X., & Yan, X. (2020). *Enhancing the Locality and Breaking the Memory Bottleneck of Transformer on Time Series Forecasting* (No. arXiv:1907.00235). arXiv. <https://doi.org/10.48550/arXiv.1907.00235>
- Lopion, P., Markewitz, P., Robinius, M., & Stolten, D. (2018). A review of current challenges and trends in energy systems modeling. *Renewable and Sustainable Energy Reviews*, 96, 156-166. <https://doi.org/10.1016/j.rser.2018.07.045>
- Mañay Chochos, E. D., Chiliquinga Malliquinga, M. D., Taco Bonilla, H. S., & Moreno Corrales, M. M. (2022). Internet of things system for ultraviolet index monitoring in the community of Chirinche Bajo. *REVISTA ODIGOS*, 3(2), 9-25. <https://doi.org/10.35290/ro.v3n2.2022.595>
- Martínez-Álvarez, F., Troncoso, A., Asencio-Cortés, G., & Riquelme, J. (2015). A Survey on Data Mining Techniques Applied to Electricity-Related Time Series Forecasting. *Energies*, 8(11), 13162-13193. <https://doi.org/10.3390/en8112361>

- Marwala, L., & Twala, B. (2014). Forecasting electricity consumption in South Africa: ARMA, neural networks and neuro-fuzzy systems. *2014 International Joint Conference on Neural Networks (IJCNN)*, 3049-3055. <https://doi.org/10.1109/IJCNN.2014.6889898>
- McKenna, E., & Thomson, M. (2016). High-resolution stochastic integrated thermal–electrical domestic demand model. *Applied Energy*, 165, 445-461. <https://doi.org/10.1016/j.apenergy.2015.12.089>
- Menacho Chiok, C. H. (2014). Comparación de los métodos de series de tiempo y redes neuronales. *Anales Científicos*, 75(2), 245. <https://doi.org/10.21704/ac.v75i2.960>
- Ministerio de Energía y Minas. (2024). *Boletín de gestión de crisis energética*. <https://www.rekursosyenergia.gob.ec/ministerio-de-energia-y-minas-aborda-crisis-energetica-con-medidas-estrategicas/>
- Mir, A. A., Alghassab, M., Ullah, K., Khan, Z. A., Lu, Y., & Imran, M. (2020). A Review of Electricity Demand Forecasting in Low and Middle Income Countries: The Demand Determinants and Horizons. *Sustainability*, 12(15), 5931. <https://doi.org/10.3390/su12155931>
- Mpawenimana, I., Pegatoquet, A., Roy, V., Rodriguez, L., & Belleudy, C. (2020). A comparative study of LSTM and ARIMA for energy load prediction with enhanced data preprocessing. *2020 IEEE Sensors Applications Symposium (SAS)*, 1-6. <https://doi.org/10.1109/SAS48726.2020.9220021>
- Mystakidis, A., Koukaras, P., Tsalikidis, N., Ioannidis, D., & Tjortjis, C. (2024). Energy Forecasting: A Comprehensive Review of Techniques and Technologies. *Energies*, 17(7), 1662. <https://doi.org/10.3390/en17071662>

- Nouvel, R., Zirak, M., Coors, V., & Eicker, U. (2017). The influence of data quality on urban heating demand modeling using 3D city models. *Computers, Environment and Urban Systems*, 64, 68-80. <https://doi.org/10.1016/j.compenvurbsys.2016.12.005>
- Operador Nacional de Electricidad CENACE. (2023). *Producción bruta energética anual porcentual*. <https://www.cenace.gob.ec/wp-content/uploads/downloads/2024/04/Parte-1-Informe-Anual-CENACE-2023.pdf>
- Panklib, K., Prakasvudhisarn, C., & Khummongkol, D. (2015). Electricity Consumption Forecasting in Thailand Using an Artificial Neural Network and Multiple Linear Regression. *Energy Sources, Part B: Economics, Planning, and Policy*, 10(4), 427-434. <https://doi.org/10.1080/15567249.2011.559520>
- Pappas, S. Sp., Ekonomou, L., Karamousantas, D. Ch., Chatzarakis, G. E., Katsikas, S. K., & Liatsis, P. (2008). Electricity demand loads modeling using AutoRegressive Moving Average (ARMA) models. *Energy*, 33(9), 1353-1360. <https://doi.org/10.1016/j.energy.2008.05.008>
- Pierre, A. A., Akim, S. A., Semenyó, A. K., & Babiga, B. (2023). Peak Electrical Energy Consumption Prediction by ARIMA, LSTM, GRU, ARIMA-LSTM and ARIMA-GRU Approaches. *Energies*, 16(12), 4739. <https://doi.org/10.3390/en16124739>
- Rafiq, H., Manandhar, P., Rodríguez-Ubinas, E., Barbosa, J. D., & Qureshi, O. A. (2023). Analysis of residential electricity consumption patterns utilizing smart-meter data: Dubai as a case study. *Energy and Buildings*, 291, 113103. <https://doi.org/10.1016/j.enbuild.2023.113103>

- Rehfeldt, M., Fleiter, T., & Toro, F. (2018). A bottom-up estimation of the heating and cooling demand in European industry. *Energy Efficiency*, 11(5), 1057-1082. <https://doi.org/10.1007/s12053-017-9571-y>
- Runge, J., & Zmeureanu, R. (2021). A Review of Deep Learning Techniques for Forecasting Energy Use in Buildings. *Energies*, 14(3), 608. <https://doi.org/10.3390/en14030608>
- Sachin, M. M., Paily Baby, M., & Sudharson Ponraj, A. (2020). Analysis of energy consumption using RNN-LSTM and ARIMA Model. *Journal of Physics: Conference Series*, 1716(1), 012048. <https://doi.org/10.1088/1742-6596/1716/1/012048>
- Sancho-Tomás, A., Sumner, M., & Robinson, D. (2017). A generalised model of electrical energy demand from small household appliances. *Energy and Buildings*, 135, 350-366. <https://doi.org/10.1016/j.enbuild.2016.10.044>
- SENPLADES. (2021). *Plan Nacional de Desarrollo 2021–2025*.
- Shaffer, D. W., Bhowmick, I., Rheingold, A. L., Tsay, C., Livesay, B. N., Shores, M. P., & Yang, J. Y. (2016). Spin-state diversity in a series of Co(ii) PNP pincer bromide complexes. *Dalton Transactions (Cambridge, England: 2003)*, 45(44), 17910-17917. <https://doi.org/10.1039/c6dt03461f>
- Siami-Namini, S., Tavakoli, N., & Namin, A. S. (2019). *A Comparative Analysis of Forecasting Financial Time Series Using ARIMA, LSTM, and BiLSTM* (Versión 1). arXiv. <https://doi.org/10.48550/ARXIV.1911.09512>
- Singla, P., Duhan, M., & Saroha, S. (2023). An integrated framework of robust local mean decomposition and bidirectional long short-term memory to forecast solar irradiance.

- Song, Z., Niu, D., Dai, S., Xiao, X., & Wang, Y. (2017). Incorporating the influence of China's industrial capacity elimination policies in electricity demand forecasting. *Utilities Policy*, 47, 1-11. <https://doi.org/10.1016/j.jup.2017.05.004>
- Tien, T.-L. (2009). A new grey prediction model FGM(1, 1). *Mathematical and Computer Modelling*, 49(7-8), 1416-1426. <https://doi.org/10.1016/j.mcm.2008.11.015>
- Verwiebe, P. A., Seim, S., Burges, S., Schulz, L., & Müller-Kirchenbauer, J. (2021). Modeling Energy Demand—A Systematic Literature Review. *Energies*, 14(23), 7859. <https://doi.org/10.3390/en14237859>
- Wei, N., Li, C., Peng, X., Zeng, F., & Lu, X. (2019). Conventional models and artificial intelligence-based models for energy consumption forecasting: A review. *Journal of Petroleum Science and Engineering*, 181, 106187. <https://doi.org/10.1016/j.petrol.2019.106187>
- Ye, C., Ding, Y., Wang, P., & Lin, Z. (2019). A Data-Driven Bottom-Up Approach for Spatial and Temporal Electric Load Forecasting. *IEEE Transactions on Power Systems*, 34(3), 1966-1979. <https://doi.org/10.1109/TPWRS.2018.2889995>
- Yu, S., Wang, K., & Wei, Y.-M. (2015). A hybrid self-adaptive Particle Swarm Optimization–Genetic Algorithm–Radial Basis Function model for annual electricity demand prediction. *Energy Conversion and Management*, 91, 176-185. <https://doi.org/10.1016/j.enconman.2014.11.059>

- Zalakeviciute, R., Diaz, V., & Rybarczyk, Y. (2024). Impact of City-Wide Diesel Generator Use on Air Quality in Quito, Ecuador, during a Nationwide Electricity Crisis. *Atmosphere*, 15(10), 1192. <https://doi.org/10.3390/atmos15101192>
- Zhang, G., Eddy Patuwo, B., & Y. Hu, M. (1998). Forecasting with artificial neural networks: *International Journal of Forecasting*, 14(1), 35-62. [https://doi.org/10.1016/s0169-2070\(97\)00044-7](https://doi.org/10.1016/s0169-2070(97)00044-7)
- Zhang, G. P. (2003). Time series forecasting using a hybrid ARIMA and neural network model. *Neurocomputing*, 50, 159-175. [https://doi.org/10.1016/s0925-2312\(01\)00702-0](https://doi.org/10.1016/s0925-2312(01)00702-0)
- Zhuang, Z., Zheng, X., Chen, Z., Jin, T., & Li, Z. (2022). Load Forecast of Electric Vehicle Charging Station Considering Multi-Source Information and User Decision Modification. *Energies*, 15(19), 7021. <https://doi.org/10.3390/en15197021>
- Zimmermann, H.-J. (2012). *Fuzzy Set Theory and Its Applications*. Springer Netherlands.

Anexo I. Estructura del dataset energético consolidado

La siguiente tabla muestra un extracto del archivo consolidado utilizado como base para el análisis predictivo. Este dataset contiene información mensual desagregada por grupo de consumo, ubicación geográfica (provincia, cantón, parroquia), número de clientes, energía facturada en kWh, facturación eléctrica (USD), así como datos macroeconómicos como el PIB e inflación.

Anexo I. Tabla parcial del archivo CSV original con los datos mensuales de consumo energético (Fuente: Elaboración propia a partir de ARCONEL y Ministerio de Energía y Minas).

Año	Mes	Empresa	Grupo Consumo	Provincia	Cantón	Parroquia	Numero Clientes	Energía Facturada (kWh)	Facturación Servicio Eléctrico (USD)	PIB %	Inflacion %
2014	Feb	CNEL-Guayas Los Ríos	Comercial	COTOPAXI	LA MANÁ	EL CARMEN	1	3974	321,640741	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Comercial	COTOPAXI	LA MANÁ	LA MANÁ	5	18785	911,546281	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Industrial	COTOPAXI	LA MANÁ	LA MANÁ	1	46145	1918,908433	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Residencial	COTOPAXI	LA MANÁ	LA MANÁ	2	1334342	79,125341	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Otros	COTOPAXI	LA MANÁ	EL TRIUNFO	1	0	0	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Comercial	COTOPAXI	LA MANÁ	LA MANÁ, CABECERA CANTONAL	7	24380	1994,531915	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Otros	COTOPAXI	LA MANÁ	LA MANÁ, CABECERA CANTONAL	1	6573	480,218508	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Residencial	COTOPAXI	LA MANÁ	LA MANÁ, CABECERA CANTONAL	1	139	13,323228	4,226065204	
2014	Feb	CNEL-Guayas Los Ríos	Alumbrado Público	GUAYAS	GUAYAQUIL	*PASCUALES	1	7972	3893,197047	4,226065204	

Anexo II. Listado de Código

A continuación, se presenta el código completo utilizado para el desarrollo del trabajo, organizado por bloques: preprocesamiento de datos, implementación de modelos estadísticos, desarrollo de redes neuronales y evaluación de resultados. El código fue desarrollado en Python utilizando Google Colab, empleando bibliotecas como pandas, numpy, statsmodels, keras, entre otras.

El código completo desarrollado para este trabajo está disponible públicamente en el siguiente repositorio:

Mendoza, E. (2025). *Código fuente del Trabajo de Fin de Máster: Predicción del consumo energético mensual en Ecuador mediante modelos estadísticos y redes neuronales recurrentes*. Repositorio GitHub.

Disponible en: <https://github.com/ErickMendoza0/TFM-Prediccion-Consumo-Energetico>

A. Carga y Procesamiento de los Datos

```
# =====
# BLOQUE 1: CARGA Y PREPROCESAMIENTO DE DATOS
# =====

# Cargar el Dataset
import pandas as pd
df = pd.read_csv('/content/Datos_Energeticos_Ecuador_2014_2024.csv',
                  encoding='latin-1',
                  sep=';',
                  decimal=',')

# Ver las primeras filas:
df.head()

#Cambiar de nombre a las filas:
df.rename(columns={
    'Anio': 'Año',
    'Mes': 'Mes',
    'Empresa': 'Empresa',
    'Grupo Consumo': 'Grupo_Consumo',
    'Provincia': 'Provincia',
    'Canton': 'Canton',
    'Parroquia': 'Parroquia',
    'Numero Clientes': 'Clientes',
    'Energia Facturada (kWh)': 'Energia_kWh',
    'Facturacion Servicio Electrico (USD)': 'Facturacion_USD',
    'PIB %': 'PIB',
```

```

        'Inflacion %': 'Inflacion'
    }, inplace=True)

#Ver las primeras filas:
df.head()
#Ver la información general del DataFrame:
df.info()
#Estadísticas descriptivas para las columnas numéricas:
df.describe()
#Revisar valores nulos:
df.isnull().sum()
#Revisar si hay valores duplicados:
df.duplicated().sum()

# Crear columna de fecha a partir de Año y Mes con nombres abreviados

# Diccionario para convertir nombres de meses a números
meses_dict = {
    'Ene': '01', 'Feb': '02', 'Mar': '03', 'Abr': '04',
    'May': '05', 'Jun': '06', 'Jul': '07', 'Ago': '08',
    'Sep': '09', 'Oct': '10', 'Nov': '11', 'Dic': '12'
}

# Convertir los nombres de mes a número
df['Mes_Num'] = df['Mes'].map(meses_dict)

# Crear columna de fecha en formato datetime
df['Fecha'] = pd.to_datetime(df['Año'].astype(str) + '-' + df['Mes_Num'], format='%Y-%m')

# Verificar que la columna fue creada correctamente
df[['Año', 'Mes', 'Mes_Num', 'Fecha']].head()

#Visualización del consumo energético mensual total

import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib.ticker as ticker

# Crear columna en GWh
df['Energia_GWh'] = df['Energia_kWh'] / 1_000_000 # 1 GWh = 1,000,000 kWh

# Agrupar por mes
df_mensual = df.groupby('Fecha')['Energia_GWh'].sum().reset_index()

# Graficar
plt.figure(figsize=(14,6))

```

```

sns.lineplot(data=df_mensual, x='Fecha', y='Energia_GWh', marker='o')

plt.title('Consumo energético mensual total en Ecuador (GWh)', fontsize=16)
plt.xlabel('Fecha')
plt.ylabel('Consumo energético (GWh)')
plt.xticks(rotation=45)

# Función personalizada para usar espacio como separador de miles
espaciador = ticker.FuncFormatter(lambda x, _: f'{int(x):,}'.replace(',', ' '))

# Aplicar en el eje Y
plt.gca().yaxis.set_major_formatter(espaciador)

plt.grid(True)
plt.tight_layout()

# Guardar la nueva imagen
plt.savefig('consumo_mensual_total_gwh.png', dpi=300)

# Mostrar gráfico
plt.show()

#Consumo mensual por grupo de consumo (residencial, industrial, Etc.)

import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib.ticker as ticker

# Convertir a GWh
df['Energia_GWh'] = df['Energia_kWh'] / 1_000_000 # 1 GWh = 1,000,000 kWh

# Agrupar por fecha y grupo de consumo
df_grupo = df.groupby(['Fecha', 'Grupo_Consumo'])['Energia_GWh'].sum().reset_index()

# Graficar
plt.figure(figsize=(14,7))
sns.lineplot(data=df_grupo, x='Fecha', y='Energia_GWh', hue='Grupo_Consumo', marker='o')

plt.title('Consumo energético mensual por grupo de consumo (GWh)', fontsize=16)
plt.xlabel('Fecha')
plt.ylabel('Consumo energético (GWh)')
plt.xticks(rotation=45)

# Función personalizada para usar espacio como separador de miles
espaciador = ticker.FuncFormatter(lambda x, _: f'{int(x):,}'.replace(',', ' '))

# Aplicar en el eje Y

```

```

plt.gca().yaxis.set_major_formatter(espaciador)

plt.legend(title='Grupo de Consumo')
plt.grid(True)
plt.tight_layout()

# Guardar imagen
plt.savefig('consumo_por_grupo_gwh.png', dpi=300)

# Mostrar gráfico
plt.show()

#Detección de outliers (boxplot o z-score)
import matplotlib.pyplot as plt
import seaborn as sns

# Agrupar consumo total por mes
df_mensual = df.groupby('Fecha')['Energia_GWh'].sum().reset_index()

# Gráfico de caja
plt.figure(figsize=(10,6))
sns.boxplot(y=df_mensual['Energia_GWh'])

plt.title('Detección de outliers en el consumo mensual de energía (GWh)')
plt.ylabel('Consumo energético (GWh)')
plt.grid(True)
plt.tight_layout()

# Guardar imagen
plt.savefig('deteccion_de_outliers.png', dpi=300)

# Mostrar gráfico
plt.show()

#Conversión de tipos de datos, Añadir la Fecha como datetime64

# Verificar tipos de datos
print(df.dtypes)

#Conversión de kWh a GWh

# Crear nueva columna con valores en GWh
df['Energia_GWh'] = df['Energia_kWh'] / 1_000_000

# Mostrar las primeras filas para verificar
df[['Energia_kWh', 'Energia_GWh']].head()

```

```

#Detección y tratamiento de datos nulos

# Ver cuántos valores nulos hay por columna
df.isnull().sum()

#Agregar los valores faltantes

df.loc[df['Año'] == 2024, 'PIB'] = -2.0
df.loc[df['Año'] == 2014, 'Inflacion'] = 3.67
df.loc[df['Año'] == 2024, 'Inflacion'] = 0.53

#Comprobamos valores nulos hay por columna
df.isnull().sum()

#Eliminación de columnas irrelevantes o redundantes
# Mostrar columnas actuales
print(df.columns.tolist())

#Copia del df original
df_original = df.copy()

#Ubicar en alguna provincias las Zonas de Estudio
# Diccionario: clave = nombre del cantón, valor = provincia correcta
correcciones_provincia = {
    'EL PIEDRERO': 'GUAYAS',
    'JUVAL': 'CHIMBORAZO',
    'MATILDE ESTHER': 'GUAYAS',
    'SANTA ROSA DE AGUA CLARA': 'CAÑAR',
    'ZONA NO LIMITADA': 'CHIMBORAZO',
}

# Aplicar corrección: para cada cantón, cambiar la provincia si coincide
for canton, nueva_provincia in correcciones_provincia.items():
    df.loc[df['Canton'].str.upper() == canton, 'Provincia'] = nueva_provincia

#Agregar coordenadas a las provincias
coords = {
    'AZUAY': (-2.9006, -79.0045),
    'BOLÍVAR': (-1.6167, -79.0000),
    'CAÑAR': (-2.5489, -78.9382),
    'CARCHI': (0.5022, -77.8857),
    'CHIMBORAZO': (-1.6708, -78.6569),
    'COTOPAXI': (-0.9381, -78.6140),
    'EL ORO': (-3.2596, -79.9585),

```

```

'ESMERALDAS': (0.9682, -79.6517),
'GALÁPAGOS': (-0.9538, -90.9656),
'GUAYAS': (-2.1709, -79.9224),
'IMBABURA': (0.3517, -78.1223),
'LOJA': (-3.9931, -79.2042),
'LOS RÍOS': (-1.7946, -79.5342),
'MANABÍ': (-0.9676, -80.7089),
'MORONA SANTIAGO': (-2.3930, -78.1105),
'NAPO': (-1.0515, -77.7320),
'ORELLANA': (-0.6743, -76.9864),
'PASTAZA': (-1.4910, -77.9916),
'PICHINCHA': (-0.2295, -78.5243),
'SANTA ELENA': (-2.2301, -80.8599),
'SANTO DOMINGO DE LOS TSÁCHILAS': (-0.2511, -79.1717),
'SUCUMBÍOS': (0.0870, -76.8881),
'TUNGURAHUA': (-1.2543, -78.6220),
'ZAMORA CHINCHIPE': (-4.0655, -78.9542)
}
df['Latitud'] = df['Provincia'].map(lambda x: coords.get(x, (None, None))[0])
df['Longitud'] = df['Provincia'].map(lambda x: coords.get(x, (None, None))[1])

df.head()

#Comprobamos valores nulos
df.isnull().sum()

#Eliminar columnas
df = df.drop(columns=['Año', 'Mes', 'Empresa', 'Provincia', 'Canton', 'Parroquia', 'Energia_kWh',
'Mes_Num'])
"""
Se eliminan las columnas Año, Mes y Mes_Num debido a que la columna Fecha ya contiene esa información
en formato unificado y ordenable para series temporales.

Se elimina Empresa por no aportar valor diferencial en el modelado, al tratarse de distribuidoras
regionales que se solapan con la información geográfica ya presente.

Se eliminan Provincia, Cantón y Parroquia dado que el enfoque de este trabajo es temporal y no
espacial.
En su lugar, se incorporan coordenadas geográficas (latitud y longitud) del centroide de cada
provincia
como referencia numérica más adecuada para modelos predictivos.
"""
df.head()

# Mostrar una muestra representativa del dataset preprocesado
df.head(5)

```

```

#Guardar df para metodos estadisticos

df_estadistico = df.copy()

# Crear una copia para modelos de redes neuronales
df_nn = df.copy()

#Guardado por seguridad
# Guardar df_estadistico (no escalado)
df_estadistico.to_csv('/content/df_estadistico.csv', index=False)

# Guardar df_nn
df_nn.to_csv('/content/df_nn.csv', index=False)

# =====
# BLOQUE 2: MODELOS ESTADISTICOS
# =====

```

B. Modelo ARIMA (1,1,1)

```

# =====MODELO ARIMA (1,1,1) 2014-2023=====

!pip install numpy==1.23.5 # Versión estable compatible
!pip install pmdarima==2.0.3

# === LIBRERÍAS ===
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import warnings
warnings.filterwarnings("ignore")

# === CARGAR Y LIMPIAR DATOS ===
df = pd.read_csv("df_estadistico.csv", parse_dates=["Fecha"])
df = df[(df["Fecha"] >= "2014-01-01") & (df["Fecha"] <= "2023-12-31")]
df = df[df["Energia_GWh"] >= 0]
df.set_index("Fecha", inplace=True)
df_mensual = df["Energia_GWh"].resample("MS").sum().reset_index()

```

```

# === DIVIDIR TRAIN Y TEST (test = 2023) ===
cutoff_date = "2022-12-01"
train = df_mensual[df_mensual["Fecha"] <= cutoff_date].copy()
test = df_mensual[df_mensual["Fecha"] > cutoff_date].copy()
train.set_index("Fecha", inplace=True)

# === TEST ADF PARA EVALUAR ESTACIONARIEDAD ===
resultado_adf = adfuller(train["Energia_GWh"])
print(" Prueba ADF")
print(f"→ ADF Statistic: {resultado_adf[0]:.4f}")
print(f"→ p-value: {resultado_adf[1]:.4f}")
# Si p > 0.05 ⇒ no estacionaria ⇒ aplicar diferenciación

# === DIFERENCIACIÓN Y GRÁFICOS ACF / PACF ===
serie_diferenciada = train["Energia_GWh"].diff().dropna()

# ACF (sugiere q), PACF (sugiere p)
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(serie_diferenciada, ax=axes[0], lags=24)
plot_pacf(serie_diferenciada, ax=axes[1], lags=24, method="ywm")
axes[0].set_title("ACF - Diferenciada (para q)")
axes[1].set_title("PACF - Diferenciada (para p)")
plt.tight_layout()
plt.savefig("acf_pacf_arma_manual.png")
plt.show()

# Basado en ADF + gráficos
p, d, q = 1, 1, 1
print(f" Parámetros seleccionados manualmente: ARIMA({p},{d},{q})")

# === ENTRENAR MODELO ARIMA MANUAL ===
modelo = ARIMA(train["Energia_GWh"], order=(p, d, q))
modelo_fit = modelo.fit()

# === PREDICCIONES PARA 2023 ===
pred = modelo_fit.forecast(steps=12)
df_pred = test.copy()
df_pred["Prediccion_GWh"] = pred.values

# === MÉTRICAS DE EVALUACIÓN ===
mae = mean_absolute_error(df_pred["Energia_GWh"], df_pred["Prediccion_GWh"])
rmse = np.sqrt(mean_squared_error(df_pred["Energia_GWh"], df_pred["Prediccion_GWh"]))
mape = np.mean(np.abs((df_pred["Energia_GWh"] - df_pred["Prediccion_GWh"]) / df_pred["Energia_GWh"]))
* 100

print(" MÉTRICAS ARIMA - MANUAL - PREDICCIÓN 2023")

```

```

print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

# === GRÁFICO FINAL ===
plt.figure(figsize=(10,5))
plt.plot(train.index, train["Energia_GWh"], label="Entrenamiento (2014-2022)", color="black")
plt.plot(df_pred["Fecha"], df_pred["Energia_GWh"], label="Consumo Real 2023", marker='o',
color="red")
plt.plot(df_pred["Fecha"], df_pred["Prediccion_GWh"], label="Predicción ARIMA", marker='x',
color="blue")
plt.title("Predicción del Consumo Energético Nacional - ARIMA (2014 - 2023)")
plt.xlabel("Fecha")
plt.ylabel("Consumo (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.savefig("prediccion_arima_manual_2023.png")
plt.show()

# ===== MODELO ARIMA (1,1,1) 2014-2024 =====

# === LIBRERÍAS ===
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import adfuller
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import warnings
warnings.filterwarnings("ignore")

# === CARGAR Y LIMPIAR DATOS ===
df = pd.read_csv("df_estadistico.csv", parse_dates=["Fecha"])
df = df[(df["Fecha"] >= "2014-01-01") & (df["Fecha"] <= "2024-12-31")]
df = df[df["Energia_GWh"] >= 0]
df.set_index("Fecha", inplace=True)
df_mensual = df["Energia_GWh"].resample("MS").sum().reset_index()

# === DIVIDIR TRAIN Y TEST (test = 2024) ===
cutoff_date = "2023-12-01"
train = df_mensual[df_mensual["Fecha"] <= cutoff_date].copy()
test = df_mensual[df_mensual["Fecha"] > cutoff_date].copy()
train.set_index("Fecha", inplace=True)

```

```

# === TEST ADF PARA EVALUAR ESTACIONARIEDAD ===
resultado_adf = adfuller(train["Energia_GWh"])
print(" Prueba ADF")
print(f"→ ADF Statistic: {resultado_adf[0]:.4f}")
print(f"→ p-value: {resultado_adf[1]:.4f}")
# Si p > 0.05 ⇒ no estacionaria ⇒ aplicar diferenciación

# === DIFERENCIACIÓN Y GRÁFICOS ACF / PACF ===
serie_diferenciada = train["Energia_GWh"].diff().dropna()

# ACF (sugiere q), PACF (sugiere p)
fig, axes = plt.subplots(1, 2, figsize=(12, 4))
plot_acf(serie_diferenciada, ax=axes[0], lags=24)
plot_pacf(serie_diferenciada, ax=axes[1], lags=24, method="ywm")
axes[0].set_title("ACF - Diferenciada (para q)")
axes[1].set_title("PACF - Diferenciada (para p)")
plt.tight_layout()
plt.savefig("acf_pacf_arima_manual.png")
plt.show()

# Basado en ADF + gráficos
p, d, q = 1, 1, 1
print(f" Parámetros seleccionados manualmente: ARIMA({p},{d},{q})")

# === ENTRENAR MODELO ARIMA MANUAL ===
modelo = ARIMA(train["Energia_GWh"], order=(p, d, q))
modelo_fit = modelo.fit()

# === PREDICCIONES PARA 2023 ===
pred = modelo_fit.forecast(steps=12)
df_pred = test.copy()
df_pred["Prediccion_GWh"] = pred.values

# === MÉTRICAS DE EVALUACIÓN ===
mae = mean_absolute_error(df_pred["Energia_GWh"], df_pred["Prediccion_GWh"])
rmse = np.sqrt(mean_squared_error(df_pred["Energia_GWh"], df_pred["Prediccion_GWh"]))
mape = np.mean(np.abs((df_pred["Energia_GWh"] - df_pred["Prediccion_GWh"]) / df_pred["Energia_GWh"]))
* 100

print(" MÉTRICAS ARIMA - MANUAL - PREDICCIÓN 2024")
print(f" MAE : {mae:.2f} GWh")
print(f" RMSE : {rmse:.2f} GWh")
print(f" MAPE : {mape:.2f} %")

# === GRÁFICO FINAL ===

```

```

plt.figure(figsize=(10,5))
plt.plot(train.index, train["Energia_GWh"], label="Entrenamiento (2014-2023)", color="black")
plt.plot(df_pred["Fecha"], df_pred["Energia_GWh"], label="Consumo Real 2024", marker='o',
color="red")
plt.plot(df_pred["Fecha"], df_pred["Prediccion_GWh"], label="Predicción ARIMA", marker='x',
color="blue")
plt.title("Predicción del Consumo Energético Nacional - ARIMA (2014 - 2024)")
plt.xlabel("Fecha")
plt.ylabel("Consumo (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.savefig("prediccion_arima_manual_2023.png")
plt.show()

```

C. Modelo auto ARIMA

```

# ====MODELO ARIMA DESAGREGADO ====
# 2014-2023

!pip install numpy==1.23.5 # Versión estable compatible
!pip install pmdarima==2.0.3

import pandas as pd
df_estadistico = pd.read_csv('/content/df_estadistico.csv',
                             encoding='latin-1',
                             sep=',',
                             decimal='.')

from collections import defaultdict

fechas_completas = pd.date_range(start='2014-01-01', end='2023-12-01', freq='MS')
n_total_meses = len(fechas_completas)

series_dict = {}
series_faltantes = {}
series_descartadas = {}

# Recalcular agrupado limpio
df_agrupado = df_estadistico.groupby(['Fecha', 'Grupo_Consumo', 'Latitud',
'Longitud'])['Energia_GWh'].sum().reset_index()

for key, grupo in df_agrupado.groupby(['Grupo_Consumo', 'Latitud', 'Longitud']):
    serie = grupo[['Fecha', 'Energia_GWh']].copy()
    serie['Fecha'] = pd.to_datetime(serie['Fecha'])

```

```

serie = serie.drop_duplicates(subset='Fecha')
serie = serie.set_index('Fecha').sort_index()
serie = serie[~serie.index.duplicated(keep='first')]
serie = serie.asfreq('MS')
serie = serie.reindex(fechas_completas)

# Detectar fechas faltantes originales
fechas_faltantes = serie[serie['Energia_GWh'].isna()].index
series_faltantes[key] = fechas_faltantes

# Analizar por año
faltantes_por_anio = defaultdict(int)
for fecha in fechas_faltantes:
    faltantes_por_anio[fecha.year] += 1

# Contar cuántos años tienen > 2 meses faltantes
años_invalidos = sum(1 for f in faltantes_por_anio.values() if f > 2)

if años_invalidos > 2:
    series_descartadas[key] = fechas_faltantes
    continue # Descartar esta serie

# Mantener: interpolar
serie = serie.interpolate(method='linear')
serie = serie.fillna(0)
series_dict[key] = serie

print(f" Series descartadas por tener >2 años con más del 20 % de valores faltantes:
{len(series_descartadas)}")
for i, (clave, fechas) in enumerate(series_descartadas.items()):
    grupo, lat, lon = clave
    print(f"{i+1}. {grupo} - ({lat}, {lon}) → {len(fechas)} fechas faltantes")
    if i >= 4: break

n_total_series = len(series_dict) + len(series_descartadas)

print(" RESUMEN DE PROCESAMIENTO DE SERIES")
print("_____")
print(f" Total de series analizadas:      {n_total_series}")
print(f" Series conservadas (interpoladas): {len(series_dict)}")
print(f" Series descartadas (>2 años incompletos): {len(series_descartadas)}")
print("_____")

#Utilizar AutoArima para determinar los parametros de los modelos

from pmdarima import auto_arima

```

```

def obtener_parametros_arma(serie):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()

    y = serie['Energia_GWh']

    modelo = auto_arma(y,
                        start_p=0, start_q=0,
                        max_p=3, max_q=3,
                        d=None,
                        seasonal=False,
                        stepwise=True,
                        suppress_warnings=True,
                        error_action="ignore")

    orden = modelo.order
    print(f"→ ARIMA{orden}")
    return orden

import warnings
warnings.filterwarnings("ignore", category=FutureWarning)

parametros_por_serie = {}

for clave, serie in series_dict.items():

    try:
        print(f" Analizando {clave}")
        orden = obtener_parametros_arma(serie)
        parametros_por_serie[clave] = orden
    except Exception as e:
        print(f" Error en {clave}: {e}")

from statsmodels.tsa.arma.model import ARIMA
from sklearn.metrics import mean_squared_error, mean_absolute_error
import numpy as np

def ajustar_y_predecir_arma(serie, orden):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()

    # Cortar por fecha explícita
    train = serie.loc['2022-12-01']
    test = serie.loc['2023-01-01':'2023-12-01']

    modelo = ARIMA(train, order=orden)

```

```

resultado = modelo.fit()

pred = resultado.forecast(steps=len(test))
fechas = test.index

df_pred = pd.DataFrame({
    'Fecha': fechas,
    'Prediccion_GWh': pred.values,
    'Real_GWh': test['Energia_GWh'].values
})

# Métricas
denominador = test['Energia_GWh'].replace(0, np.nan)
mae = mean_absolute_error(test['Energia_GWh'], pred)
rmse = np.sqrt(mean_squared_error(test['Energia_GWh'], pred))
mape = np.mean(np.abs((test['Energia_GWh'] - pred) / denominador)) * 100

print(f"ARIMA{orden} | MAE: {mae:.4f} | RMSE: {rmse:.4f} | MAPE: {mape:.2f}%")
return df_pred

#Entrenar todos los modelos, para luego volver a unirlos en una sola prediccion

todas_las_predicciones = []
warnings.filterwarnings("ignore", category=FutureWarning)
for clave, serie in series_dict.items():
    if clave in parametros_por_serie:
        orden = parametros_por_serie[clave]
        grupo, lat, lon = clave
        try:
            print(f" Procesando {grupo} - ({lat}, {lon}) con ARIMA{orden}")
            df_pred = ajustar_y_predecir_arima(serie, orden=orden)
            df_pred['Grupo_Consumo'] = grupo
            df_pred['Latitud'] = lat
            df_pred['Longitud'] = lon
            todas_las_predicciones.append(df_pred)
        except Exception as e:
            print(f" Error en {clave}: {e}")

if 'todas_las_predicciones' in locals():
    df_total_pred = pd.concat(todas_las_predicciones, ignore_index=True)
else:
    print(" La variable 'todas_las_predicciones' no está definida.")

df_total_pred = pd.concat(todas_las_predicciones, ignore_index=True)

# Sumar todas las predicciones mensuales para obtener la curva nacional
df_nacional_predicho = df_total_pred.groupby('Fecha')['Prediccion_GWh'].sum().reset_index()

```

```

# Calcular la curva nacional real (suma de todas las series por mes)
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()

# Asegurar tipo datetime para ambas columnas 'Fecha'
df_nacional_predicho["Fecha"] = pd.to_datetime(df_nacional_predicho["Fecha"])
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])

#Unir ambas curvas
df_comparacion = pd.merge(df_nacional_predicho, df_nacional_real, on='Fecha', how='inner')
df_comparacion.columns = ['Fecha', 'Prediccion_GWh', 'Real_GWh']

# Asegurar tener toda la curva real desde 2014
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()

#Convertir fechas a datetime si no lo están
df_nacional_predicho["Fecha"] = pd.to_datetime(df_nacional_predicho["Fecha"])
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])

#Unir predicción con la curva real
df_comparacion = pd.merge(df_nacional_real, df_nacional_predicho, on="Fecha", how="left")
df_comparacion.columns = ["Fecha", "Real_GWh", "Prediccion_GWh"]

#Separar fases
df_entrenamiento = df_comparacion[df_comparacion["Fecha"].dt.year < 2023]
df_test_real = df_comparacion[df_comparacion["Fecha"].dt.year == 2023]
df_test_pred = df_test_real.dropna(subset=["Prediccion_GWh"]) # asegurar solo fechas con predicción

#Gráfico
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 6))

plt.plot(df_entrenamiento["Fecha"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2022)", color="black", linewidth=2)

plt.plot(df_test_real["Fecha"], df_test_real["Real_GWh"],
         label="Consumo Real 2023", color="red", marker="o", linewidth=2)

plt.plot(df_test_pred["Fecha"], df_test_pred["Prediccion_GWh"],
         label="Predicción ARIMA ", color="blue", linestyle="--", marker="x", linewidth=2)

plt.title("Predicción del Consumo Energético Nacional - Modelado Desagregado (2014-2023)")

```

```

plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# Filtrar los datos de test: solo 2023
df_test_2023 = df_comparacion[df_comparacion['Fecha'].dt.year == 2023].copy()

# Extraer reales y predichos
y_real = df_test_2023['Real_GWh']
y_pred = df_test_2023['Prediccion_GWh']

# Calcular métricas
mae = mean_absolute_error(y_real, y_pred)
rmse = np.sqrt(mean_squared_error(y_real, y_pred))
mape = np.mean(np.abs((y_real - y_pred) / y_real.replace(0, np.nan))) * 100 # evitar división por
cero

#Mostrar resultados
print(" MÉTRICAS DE ERROR - ARIMA (2023)")
print("-----")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

# 2014-2024

import pandas as pd
df_estadistico = pd.read_csv('/content/df_estadistico.csv',
                              encoding='latin-1',
                              sep=',',
                              decimal='.')
from collections import defaultdict

fechas_completas = pd.date_range(start='2014-01-01', end='2024-12-01', freq='MS')
n_total_meses = len(fechas_completas)

series_dict = {}
series_faltantes = {}
series_descartadas = {}

```

```

# Recalcular agrupado limpio
df_agrupado = df_estadistico.groupby(['Fecha', 'Grupo_Consumo', 'Latitud',
'Longitud'])['Energia_GWh'].sum().reset_index()

for key, grupo in df_agrupado.groupby(['Grupo_Consumo', 'Latitud', 'Longitud']):
    serie = grupo[['Fecha', 'Energia_GWh']].copy()
    serie['Fecha'] = pd.to_datetime(serie['Fecha'])
    serie = serie.drop_duplicates(subset='Fecha')
    serie = serie.set_index('Fecha').sort_index()
    serie = serie[~serie.index.duplicated(keep='first')]
    serie = serie.asfreq('MS')
    serie = serie.reindex(fechas_completas)

# Detectar fechas faltantes originales
fechas_faltantes = serie[serie['Energia_GWh'].isna()].index
series_faltantes[key] = fechas_faltantes

# Analizar por año
faltantes_por_anio = defaultdict(int)
for fecha in fechas_faltantes:
    faltantes_por_anio[fecha.year] += 1

# Contar cuántos años tienen > 2 meses faltantes
años_invalidos = sum(1 for f in faltantes_por_anio.values() if f > 2)

if años_invalidos > 2:
    series_descartadas[key] = fechas_faltantes
    continue # Descartar esta serie

# Mantener: interpolar
serie = serie.interpolate(method='linear')
serie = serie.fillna(0)
series_dict[key] = serie

print(f" Series descartadas por tener >2 años con más del 20 % de valores faltantes:
{len(series_descartadas)}")
for i, (clave, fechas) in enumerate(series_descartadas.items()):
    grupo, lat, lon = clave
    print(f"{i+1}. {grupo} - ({lat}, {lon}) → {len(fechas)} fechas faltantes")
    if i >= 4: break

n_total_series = len(series_dict) + len(series_descartadas)

print(" RESUMEN DE PROCESAMIENTO DE SERIES")
print("_____")
print(f" Total de series analizadas:      {n_total_series}")
print(f" Series conservadas (interpoladas): {len(series_dict)}")

```

```
print(f" Series descartadas (>2 años incompletos): {len(series_descartadas)}")
print("_____")
```

```
from pmdarima import auto_arima
```

```
def obtener_parametros_arima(serie):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()

    y = serie['Energia_GWh']

    modelo = auto_arima(y,
                        start_p=0, start_q=0,
                        max_p=3, max_q=3,
                        d=None,
                        seasonal=False,
                        stepwise=True,
                        suppress_warnings=True,
                        error_action="ignore")

    orden = modelo.order
    print(f"→ ARIMA{orden}")
    return orden
```

```
import warnings
warnings.filterwarnings("ignore", category=FutureWarning)
```

```
parametros_por_serie = {}
```

```
for clave, serie in series_dict.items():
```

```
    try:
        print(f" Analizando {clave}")
        orden = obtener_parametros_arima(serie)
        parametros_por_serie[clave] = orden
    except Exception as e:
        print(f" Error en {clave}: {e}")
```

```
        from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_squared_error, mean_absolute_error
import numpy as np
```

```
def ajustar_y_predecir_arima(serie, orden):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()
```

```
# Cortar por fecha explícita
```

```

train = serie.loc[:'2023-12-01']
test = serie.loc['2024-01-01':'2024-12-01']

modelo = ARIMA(train, order=orden)
resultado = modelo.fit()

pred = resultado.forecast(steps=len(test))
fechas = test.index

df_pred = pd.DataFrame({
    'Fecha': fechas,
    'Prediccion_GWh': pred.values,
    'Real_GWh': test['Energia_GWh'].values
})

# Métricas
denominador = test['Energia_GWh'].replace(0, np.nan)
mae = mean_absolute_error(test['Energia_GWh'], pred)
rmse = np.sqrt(mean_squared_error(test['Energia_GWh'], pred))
mape = np.mean(np.abs((test['Energia_GWh'] - pred) / denominador)) * 100

print(f"ARIMA{orden} | MAE: {mae:.4f} | RMSE: {rmse:.4f} | MAPE: {mape:.2f}%")
return df_pred

todas_las_predicciones = []
warnings.filterwarnings("ignore", category=FutureWarning)
for clave, serie in series_dict.items():
    if clave in parametros_por_serie:
        orden = parametros_por_serie[clave]
        grupo, lat, lon = clave
        try:
            print(f" Procesando {grupo} - ({lat}, {lon}) con ARIMA{orden}")
            df_pred = ajustar_y_predecir_arima(serie, orden=orden)
            df_pred['Grupo_Consumo'] = grupo
            df_pred['Latitud'] = lat
            df_pred['Longitud'] = lon
            todas_las_predicciones.append(df_pred)
        except Exception as e:
            print(f" Error en {clave}: {e}")

if 'todas_las_predicciones' in locals():
    df_total_pred = pd.concat(todas_las_predicciones, ignore_index=True)
else:
    print(" La variable 'todas_las_predicciones' no está definida.")

df_total_pred = pd.concat(todas_las_predicciones, ignore_index=True)

```

```

# Sumar todas las predicciones mensuales para obtener la curva nacional
df_nacional_predicho = df_total_pred.groupby('Fecha')['Prediccion_GWh'].sum().reset_index()

# Calcular la curva nacional real (suma de todas las series por mes)
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()
# Asegurar tipo datetime para ambas columnas 'Fecha'
df_nacional_predicho['Fecha'] = pd.to_datetime(df_nacional_predicho['Fecha'])
df_nacional_real['Fecha'] = pd.to_datetime(df_nacional_real['Fecha'])

# unir ambas curvas
df_comparacion = pd.merge(df_nacional_predicho, df_nacional_real, on='Fecha', how='inner')
df_comparacion.columns = ['Fecha', 'Prediccion_GWh', 'Real_GWh']

# Asegurar tener toda la curva real desde 2014
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()

# Convertir fechas a datetime si no lo están
df_nacional_predicho["Fecha"] = pd.to_datetime(df_nacional_predicho["Fecha"])
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])

# Unir predicción con la curva real
df_comparacion = pd.merge(df_nacional_real, df_nacional_predicho, on="Fecha", how="left")
df_comparacion.columns = ["Fecha", "Real_GWh", "Prediccion_GWh"]

# Separar fases
df_entrenamiento = df_comparacion[df_comparacion["Fecha"].dt.year < 2024]
df_test_real = df_comparacion[df_comparacion["Fecha"].dt.year == 2024]
df_test_pred = df_test_real.dropna(subset=["Prediccion_GWh"]) # asegurar solo fechas con predicción

# Gráfico
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 6))

plt.plot(df_entrenamiento["Fecha"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2023)", color="black", linewidth=2)

plt.plot(df_test_real["Fecha"], df_test_real["Real_GWh"],
         label="Consumo Real 2024", color="red", marker="o", linewidth=2)

plt.plot(df_test_pred["Fecha"], df_test_pred["Prediccion_GWh"],
         label="Predicción ARIMA ", color="blue", linestyle="--", marker="x", linewidth=2)

```

```

plt.title("Predicción del Consumo Energético Nacional - Modelado Desagregado (2014-2024)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# Filtrar los datos de test: solo 2024
df_test_2023 = df_comparacion[df_comparacion['Fecha'].dt.year == 2024].copy()

# Extraer reales y predichos
y_real = df_test_2023['Real_GWh']
y_pred = df_test_2023['Prediccion_GWh']

# Calcular métricas
mae = mean_absolute_error(y_real, y_pred)
rmse = np.sqrt(mean_squared_error(y_real, y_pred))
mape = np.mean(np.abs((y_real - y_pred) / y_real.replace(0, np.nan))) * 100 # evitar división por
cero

# Mostrar resultados
print(" MÉTRICAS DE ERROR - ARIMA (2024)")
print("-----")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

```

D. Modelo auto SARIMA

```

# ====MODELO SARIMA DESAGREGADO ====
# 2014-2023

!pip install numpy==1.23.5 # Versión estable compatible
!pip install pmdarima==2.0.3

import pandas as pd
df_estadistico = pd.read_csv('/content/df_estadistico.csv',
                             encoding='latin-1',
                             sep=',',
                             decimal='.')

from collections import defaultdict

```

```

fechas_completas = pd.date_range(start='2014-01-01', end='2023-12-01', freq='MS')
n_total_meses = len(fechas_completas)

series_dict = {}
series_faltantes = {}
series_descartadas = {}

# Recalcular agrupado limpio
df_agrupado = df_estadistico.groupby(['Fecha', 'Grupo_Consumo', 'Latitud',
'Longitud'])['Energia_GWh'].sum().reset_index()

for key, grupo in df_agrupado.groupby(['Grupo_Consumo', 'Latitud', 'Longitud']):
    serie = grupo[['Fecha', 'Energia_GWh']].copy()
    serie['Fecha'] = pd.to_datetime(serie['Fecha'])
    serie = serie.drop_duplicates(subset='Fecha')
    serie = serie.set_index('Fecha').sort_index()
    serie = serie[~serie.index.duplicated(keep='first')]
    serie = serie.asfreq('MS')
    serie = serie.reindex(fechas_completas)

    # Detectar fechas faltantes originales
    fechas_faltantes = serie[serie['Energia_GWh'].isna()].index
    series_faltantes[key] = fechas_faltantes

    # Analizar por año
    faltantes_por_anio = defaultdict(int)
    for fecha in fechas_faltantes:
        faltantes_por_anio[fecha.year] += 1

    # Contar cuántos años tienen > 2 meses faltantes
    años_invalidos = sum(1 for f in faltantes_por_anio.values() if f > 2)

    if años_invalidos > 2:
        series_descartadas[key] = fechas_faltantes
        continue # Descartar esta serie

    # Mantener: interpolar
    serie = serie.interpolate(method='linear')
    serie = serie.fillna(0)
    series_dict[key] = serie

print(f" Series descartadas por tener >2 años con más del 20 % de valores faltantes:
{len(series_descartadas)}")
for i, (clave, fechas) in enumerate(series_descartadas.items()):
    grupo, lat, lon = clave

```

```

    print(f"{i+1}. {grupo} - ({lat}, {lon}) → {len(fechas)} fechas faltantes")
    if i >= 4: break

n_total_series = len(series_dict) + len(series_descartadas)

print(" RESUMEN DE PROCESAMIENTO DE SERIES")
print("_____")
print(f" Total de series analizadas:      {n_total_series}")
print(f" Series conservadas (interpoladas): {len(series_dict)}")
print(f" Series descartadas (>2 años incompletos): {len(series_descartadas)}")
print("_____")

from pmdarima import auto_arima

def obtener_parametros_sarima(serie):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()
    y = serie['Energia_GWh']

    modelo = auto_arima(y,
                        start_p=0, start_q=0,
                        max_p=3, max_q=3,
                        d=None,
                        seasonal=True,      # SARIMA
                        m=12,               # Periodo estacional mensual
                        start_P=0, start_Q=0,
                        max_P=2, max_Q=2,
                        D=None,
                        trace=True,
                        stepwise=True,
                        suppress_warnings=True,
                        error_action="ignore")

    orden = modelo.order          # (p, d, q)
    orden_seasonal = modelo.seasonal_order # (P, D, Q, s)
    print(f"→ SARIMA{orden} x {orden_seasonal}")
    return orden, orden_seasonal

import warnings
warnings.filterwarnings("ignore", category=FutureWarning)

parametros_por_serie = {}

for clave, serie in series_dict.items():
    try:
        print(f" Analizando {clave}")
        orden, orden_seasonal = obtener_parametros_sarima(serie)

```

```

        parametros_por_serie[clave] = (orden, orden_seasonal)
    except Exception as e:
        print(f" Error en {clave}: {e}")

from statsmodels.tsa.statespace.sarimax import SARIMAX
import numpy as np
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score,
mean_absolute_percentage_error

def ajustar_y_predecir_sarima(serie, orden, orden_seasonal):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()

    train = serie.loc[:'2022-12-01']
    test = serie.loc['2023-01-01':'2023-12-01']

    modelo = SARIMAX(train,
                      order=orden,
                      seasonal_order=orden_seasonal,
                      enforce_stationarity=False,
                      enforce_invertibility=False)

    resultado = modelo.fit(dispatch=False)
    pred = resultado.forecast(steps=len(test))

    fechas = test.index
    df_pred = pd.DataFrame({
        'Fecha': fechas,
        'Prediccion_GWh': pred.values,
        'Real_GWh': test['Energia_GWh'].values
    })

    # Métricas
    denominador = test['Energia_GWh'].replace(0, np.nan)
    mae = mean_absolute_error(test['Energia_GWh'], pred)
    rmse = np.sqrt(mean_squared_error(test['Energia_GWh'], pred))
    mape = np.mean(np.abs((test['Energia_GWh'] - pred) / denominador)) * 100

    print(f"SARIMA{orden} x {orden_seasonal} | MAE: {mae:.2f} | RMSE: {rmse:.2f} | MAPE:
{mape:.2f}%")
    return df_pred

import numpy as np

todas_las_predicciones = []

```

```

warnings.filterwarnings("ignore", category=FutureWarning)

for clave, serie in series_dict.items():
    if clave in parametros_por_serie:
        orden, orden_seasonal = parametros_por_serie[clave]
        grupo, lat, lon = clave
        try:
            print(f" Procesando {grupo} - ({lat}, {lon}) con SARIMA{orden} x {orden_seasonal}")
            df_pred = ajustar_y_predecir_sarima(serie, orden=orden, orden_seasonal=orden_seasonal)
            df_pred['Grupo_Consumo'] = grupo
            df_pred['Latitud'] = lat
            df_pred['Longitud'] = lon
            todas_las_predicciones.append(df_pred)
        except Exception as e:
            print(f" Error en {clave}: {e}")

print(f" Total de subseries procesadas exitosamente: {len(todas_las_predicciones)}")

df_total_pred = pd.concat(todas_las_predicciones, ignore_index=True)

# Sumar todas las predicciones mensuales para obtener la curva nacional
df_nacional_predicho = df_total_pred.groupby('Fecha')['Prediccion_GWh'].sum().reset_index()
# Calcular la curva nacional real (suma de todas las series por mes)
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()
# Asegurar tipo datetime para ambas columnas 'Fecha'
df_nacional_predicho['Fecha'] = pd.to_datetime(df_nacional_predicho['Fecha'])
df_nacional_real['Fecha'] = pd.to_datetime(df_nacional_real['Fecha'])

#unir ambas curvas
df_comparacion = pd.merge(df_nacional_predicho, df_nacional_real, on='Fecha', how='inner')
df_comparacion.columns = ['Fecha', 'Prediccion_GWh', 'Real_GWh']

# Asegurar de tener toda la curva real desde 2014
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()

# Convertir fechas a datetime si no lo están
df_nacional_predicho["Fecha"] = pd.to_datetime(df_nacional_predicho["Fecha"])
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])

# Unir predicción con la curva real
df_comparacion = pd.merge(df_nacional_real, df_nacional_predicho, on="Fecha", how="left")
df_comparacion.columns = ["Fecha", "Real_GWh", "Prediccion_GWh"]

```

```

# Separar fases
df_entrenamiento = df_comparacion[df_comparacion["Fecha"].dt.year < 2023]
df_test_real = df_comparacion[df_comparacion["Fecha"].dt.year == 2023]
df_test_pred = df_test_real.dropna(subset=["Prediccion_GWh"]) # asegurar solo fechas con predicción

# Gráfico
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 6))

plt.plot(df_entrenamiento["Fecha"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2022)", color="black", linewidth=2)

plt.plot(df_test_real["Fecha"], df_test_real["Real_GWh"],
         label="Consumo Real 2023", color="red", marker="o", linewidth=2)

plt.plot(df_test_pred["Fecha"], df_test_pred["Prediccion_GWh"],
         label="Predicción SARIMA ", color="blue", linestyle="--", marker="x", linewidth=2)

plt.title("Predicción del Consumo Energético Nacional - Modelado SARIMA Desagregado (2014-2023)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# Filtrar los datos de test: solo 2023
df_test_2023 = df_comparacion[df_comparacion['Fecha'].dt.year == 2023].copy()

# Extraer reales y predichos
y_real = df_test_2023['Real_GWh']
y_pred = df_test_2023['Prediccion_GWh']

# Calcular métricas
mae = mean_absolute_error(y_real, y_pred)
rmse = np.sqrt(mean_squared_error(y_real, y_pred))
mape = np.mean(np.abs((y_real - y_pred) / y_real.replace(0, np.nan))) * 100 # evitar división por
cero

# 4. Mostrar resultados
print(" MÉTRICAS DE ERROR - SARIMA (2023)")

```

```

print("_____")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

#SARIMA (2014-2024)

import pandas as pd
df_estadistico = pd.read_csv('/content/df_estadistico.csv',
                             encoding='latin-1',
                             sep=',',
                             decimal='.')

from collections import defaultdict

fechas_completas = pd.date_range(start='2014-01-01', end='2024-12-01', freq='MS')
n_total_meses = len(fechas_completas)

series_dict = {}
series_faltantes = {}
series_descartadas = {}

# Recalcular agrupado limpio
df_agrupado = df_estadistico.groupby(['Fecha', 'Grupo_Consumo', 'Latitud',
                                     'Longitud'])['Energia_GWh'].sum().reset_index()

for key, grupo in df_agrupado.groupby(['Grupo_Consumo', 'Latitud', 'Longitud']):
    serie = grupo[['Fecha', 'Energia_GWh']].copy()
    serie['Fecha'] = pd.to_datetime(serie['Fecha'])
    serie = serie.drop_duplicates(subset='Fecha')
    serie = serie.set_index('Fecha').sort_index()
    serie = serie[~serie.index.duplicated(keep='first')]
    serie = serie.asfreq('MS')
    serie = serie.reindex(fechas_completas)

    # Detectar fechas faltantes originales
    fechas_faltantes = serie[serie['Energia_GWh'].isna()].index
    series_faltantes[key] = fechas_faltantes

    # Analizar por año
    faltantes_por_anio = defaultdict(int)
    for fecha in fechas_faltantes:
        faltantes_por_anio[fecha.year] += 1

    # Contar cuántos años tienen > 2 meses faltantes
    años_invalidos = sum(1 for f in faltantes_por_anio.values() if f > 2)

```

```

if años_invalidos > 2:
    series_descartadas[key] = fechas_faltantes
    continue # Descartar esta serie

# Mantener: interpolar
serie = serie.interpolate(method='linear')
serie = serie.fillna(0)
series_dict[key] = serie

print(f" Series descartadas por tener >2 años con más del 20 % de valores faltantes:
{len(series_descartadas)}")
for i, (clave, fechas) in enumerate(series_descartadas.items()):
    grupo, lat, lon = clave
    print(f"{i+1}. {grupo} - ({lat}, {lon}) → {len(fechas)} fechas faltantes")
    if i >= 4: break

n_total_series = len(series_dict) + len(series_descartadas)

print(" RESUMEN DE PROCESAMIENTO DE SERIES")
print("-----")
print(f" Total de series analizadas:      {n_total_series}")
print(f" Series conservadas (interpoladas): {len(series_dict)}")
print(f" Series descartadas (>2 años incompletos): {len(series_descartadas)}")
print("-----")

from pmdarima import auto_arima

def obtener_parametros_sarima(serie):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()
    y = serie['Energia_GWh']

    modelo = auto_arima(y,
                        start_p=0, start_q=0,
                        max_p=3, max_q=3,
                        d=None,
                        seasonal=True,      # SARIMA
                        m=12,               # Periodo estacional mensual
                        start_P=0, start_Q=0,
                        max_P=2, max_Q=2,
                        D=None,
                        trace=True,
                        stepwise=True,
                        suppress_warnings=True,
                        error_action="ignore")

    orden = modelo.order                  # (p, d, q)

```

```

orden_seasonal = modelo.seasonal_order # (P, D, Q, s)
print(f"→ SARIMA{orden} x {orden_seasonal}")
return orden, orden_seasonal

import warnings
warnings.filterwarnings("ignore", category=FutureWarning)

parametros_por_serie = {}

for clave, serie in series_dict.items():
    try:
        print(f" Analizando {clave}")
        orden, orden_seasonal = obtener_parametros_sarima(serie)
        parametros_por_serie[clave] = (orden, orden_seasonal)
    except Exception as e:
        print(f" Error en {clave}: {e}")

from statsmodels.tsa.statespace.sarimax import SARIMAX
import numpy as np
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score,
mean_absolute_percentage_error

def ajustar_y_predecir_sarima(serie, orden, orden_seasonal):
    serie = serie.sort_index().asfreq('MS')
    serie = serie.interpolate()

    train = serie.loc[:'2023-12-01']
    test = serie.loc['2024-01-01':'2024-12-01']

    modelo = SARIMAX(train,
                      order=orden,
                      seasonal_order=orden_seasonal,
                      enforce_stationarity=False,
                      enforce_invertibility=False)

    resultado = modelo.fit(dispatch=False)
    pred = resultado.forecast(steps=len(test))

    fechas = test.index
    df_pred = pd.DataFrame({
        'Fecha': fechas,
        'Prediccion_GWh': pred.values,
        'Real_GWh': test['Energia_GWh'].values
    })

    # Métricas
    denominador = test['Energia_GWh'].replace(0, np.nan)

```

```

mae = mean_absolute_error(test['Energia_GWh'], pred)
rmse = np.sqrt(mean_squared_error(test['Energia_GWh'], pred))
mape = np.mean(np.abs((test['Energia_GWh'] - pred) / denominador)) * 100

print(f"SARIMA{orden} x {orden_seasonal} | MAE: {mae:.2f} | RMSE: {rmse:.2f} | MAPE:
{mape:.2f}%")
return df_pred

todas_las_predicciones = []
warnings.filterwarnings("ignore", category=FutureWarning)

for clave, serie in series_dict.items():
    if clave in parametros_por_serie:
        orden, orden_seasonal = parametros_por_serie[clave]
        grupo, lat, lon = clave
        try:
            print(f"Procesando {grupo} - ({lat}, {lon}) con SARIMA{orden} x {orden_seasonal}")
            df_pred = ajustar_y_predecir_sarima(serie, orden=orden, orden_seasonal=orden_seasonal)
            df_pred['Grupo_Consumo'] = grupo
            df_pred['Latitud'] = lat
            df_pred['Longitud'] = lon
            todas_las_predicciones.append(df_pred)
        except Exception as e:
            print(f"Error en {clave}: {e}")

print(f"Total de subseries procesadas exitosamente: {len(todas_las_predicciones)}")

df_total_pred = pd.concat(todas_las_predicciones, ignore_index=True)

# Sumar todas las predicciones mensuales para obtener la curva nacional
df_nacional_predicho = df_total_pred.groupby('Fecha')['Prediccion_GWh'].sum().reset_index()
# Calcular la curva nacional real (suma de todas las series por mes)
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])
df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()
# Asegurar tipo datetime para ambas columnas 'Fecha'
df_nacional_predicho['Fecha'] = pd.to_datetime(df_nacional_predicho['Fecha'])
df_nacional_real['Fecha'] = pd.to_datetime(df_nacional_real['Fecha'])

# unir ambas curvas
df_comparacion = pd.merge(df_nacional_predicho, df_nacional_real, on='Fecha', how='inner')
df_comparacion.columns = ['Fecha', 'Prediccion_GWh', 'Real_GWh']

#Asegurar de tener toda la curva real desde 2014
df_nacional_real = df_estadistico.copy()
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])

```

```

df_nacional_real = df_nacional_real.groupby("Fecha")["Energia_GWh"].sum().reset_index()

# Convertir fechas a datetime si no lo están
df_nacional_predicho["Fecha"] = pd.to_datetime(df_nacional_predicho["Fecha"])
df_nacional_real["Fecha"] = pd.to_datetime(df_nacional_real["Fecha"])

# Unir predicción con la curva real
df_comparacion = pd.merge(df_nacional_real, df_nacional_predicho, on="Fecha", how="left")
df_comparacion.columns = ["Fecha", "Real_GWh", "Prediccion_GWh"]

# Separar fases
df_entrenamiento = df_comparacion[df_comparacion["Fecha"].dt.year < 2024]
df_test_real = df_comparacion[df_comparacion["Fecha"].dt.year == 2024]
df_test_pred = df_test_real.dropna(subset=["Prediccion_GWh"]) # asegurar solo fechas con predicción

# Gráfico
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 6))

plt.plot(df_entrenamiento["Fecha"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2023)", color="black", linewidth=2)

plt.plot(df_test_real["Fecha"], df_test_real["Real_GWh"],
         label="Consumo Real 2024", color="red", marker="o", linewidth=2)

plt.plot(df_test_pred["Fecha"], df_test_pred["Prediccion_GWh"],
         label="Predicción SARIMA ", color="blue", linestyle="--", marker="x", linewidth=2)

plt.title("Predicción del Consumo Energético Nacional - Modelado SARIMA Desagregado (2014-2024)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# Filtrar los datos de test: solo 2024
df_test_2023 = df_comparacion[df_comparacion["Fecha"].dt.year == 2024].copy()

# Extraer reales y predichos
y_real = df_test_2023['Real_GWh']
y_pred = df_test_2023['Prediccion_GWh']

```

```
# Calcular métricas
mae = mean_absolute_error(y_real, y_pred)
rmse = np.sqrt(mean_squared_error(y_real, y_pred))
mape = np.mean(np.abs((y_real - y_pred) / y_real.replace(0, np.nan))) * 100 # evitar división por
cero
```

```
# 4. Mostrar resultados
print(" MÉTRICAS DE ERROR - SARIMA (2024)")
print("-----")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")
```

```
# =====
# BLOQUE 3: MODELOS RNN
# =====
```

E. Modelo RNN LSTM

```
#LSTM (2014-2023)

import pandas as pd
import numpy as np
from sklearn.preprocessing import LabelEncoder

# === Cargar el CSV ===
df = pd.read_csv("df_nn.csv", parse_dates=["Fecha"])

# === Filtrar fechas válidas ===
df2024=df.copy()
df = df[(df["Fecha"] >= "2014-01-01") & (df["Fecha"] <= "2023-12-31")].copy()

# === Eliminar valores negativos
df = df[df["Energia_GWh"] >= 0]

# === Crear columna Mes
df["Mes"] = df["Fecha"].dt.to_period("M").dt.to_timestamp()

# === Identificar series válidas (>=119 meses)
series = df.groupby(["Latitud", "Longitud", "Grupo_Consumo"])["Mes"].nunique().reset_index()
series.columns = ["Lat", "Lon", "Grupo", "Meses_disponibles"]
series_validas = series[series["Meses_disponibles"] >= 119]
```

```

# === Filtrar DataFrame a solo series válidas
df = df.merge(series_validas, how="inner", left_on=["Latitud", "Longitud", "Grupo_Consumo"],
              right_on=["Lat", "Lon", "Grupo"])
df = df.drop(columns=["Meses_disponibles", "Lat", "Lon", "Grupo"])

# === Agrupar por provincia + grupo + mes
df_grouped = df.groupby(["Mes", "Grupo_Consumo", "Latitud", "Longitud"],
                        as_index=False)["Energia_GWh"].sum()

# === Agregar estacionalidad
df_grouped["Mes_num"] = df_grouped["Mes"].dt.month
df_grouped["Mes_sin"] = np.sin(2 * np.pi * df_grouped["Mes_num"] / 12)
df_grouped["Mes_cos"] = np.cos(2 * np.pi * df_grouped["Mes_num"] / 12)

# === Codificar grupo de consumo
le_grupo = LabelEncoder()
df_grouped["Grupo_Consumo_Cod"] = le_grupo.fit_transform(df_grouped["Grupo_Consumo"])

# === Verificar
print(df_grouped.head())
print("Series válidas:", df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"]).ngroups)

from tqdm import tqdm
import numpy as np

# === Inicialización ===
n_steps = 12
X_total, y_total = [], []
grupo_input_total = []
fechas_total = []
serie_clave_total = []

# === Generar secuencias por serie ===
grupos = df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"])

for (lat, lon, grupo_cod), group in tqdm(grupos, desc="Procesando series"):
    group = group.sort_values("Mes").reset_index(drop=True)

    if len(group) < n_steps + 1:
        continue

    for i in range(len(group) - n_steps):
        ventana = group.iloc[i:i + n_steps]
        target = group.iloc[i + n_steps]["Energia_GWh"]
        fecha_target = group.iloc[i + n_steps]["Mes"]

        secuencia = ventana[["Energia_GWh", "Mes_sin", "Mes_cos", "Latitud", "Longitud"]].values

```

```

X_total.append(sequencia)
y_total.append(target)
grupo_input_total.append(grupo_cod)
fechas_total.append(fecha_target)
serie_clave_total.append((lat, lon, grupo_cod))

# === Convertir a arrays ===
X_total = np.array(X_total)
y_total = np.array(y_total)
grupo_input_total = np.array(grupo_input_total)
fechas_total = np.array(fechas_total)
serie_clave_total = np.array(serie_clave_total)

# === Dividir por fecha (test = desde 2023-01-01) ===
fechas_total_ts = pd.to_datetime(fechas_total)
fecha_corte = pd.Timestamp("2023-01-01")

mask_train = fechas_total_ts < fecha_corte
mask_test = fechas_total_ts >= fecha_corte

X_train = X_total[mask_train]
y_train = y_total[mask_train]
grupo_train = grupo_input_total[mask_train]
fechas_train = fechas_total[mask_train]
clave_train = serie_clave_total[mask_train]

X_test = X_total[mask_test]
y_test = y_total[mask_test]
grupo_test = grupo_input_total[mask_test]
fechas_test = fechas_total[mask_test]
clave_test = serie_clave_total[mask_test]

# === Verificar ===
print(" División por fecha aplicada correctamente:")
print("Entrenamiento:", fechas_train.min(), "→", fechas_train.max())
print("Test:", fechas_test.min(), "→", fechas_test.max())
print("X_train:", X_train.shape, " | X_test:", X_test.shape)

import matplotlib.pyplot as plt
import pandas as pd

# === Crear DataFrame para entrenamiento
df_train_plot = pd.DataFrame({
    "Fecha": fechas_train,
    "Energia_GWh": y_train,
    "Tipo": "Entrenamiento"
})

```

```

}))

# === Crear DataFrame para test
df_test_plot = pd.DataFrame({
    "Fecha": fechas_test,
    "Energia_GWh": y_test,
    "Tipo": "Test"
})

# === Unir ambos DataFrames
df_plot = pd.concat([df_train_plot, df_test_plot])
df_plot["Mes"] = pd.to_datetime(df_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes y tipo
df_mes = df_plot.groupby(["Mes", "Tipo"])["Energia_GWh"].sum().reset_index()

# === Graficar
plt.figure(figsize=(12, 5))
for tipo in df_mes["Tipo"].unique():
    datos = df_mes[df_mes["Tipo"] == tipo]
    plt.plot(datos["Mes"], datos["Energia_GWh"], label=f"{tipo}", marker="o")

plt.title("Distribución mensual de consumo energético - Train vs Test")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, LSTM, Dense, Dropout, Embedding, Concatenate,
RepeatVector, Flatten
from tensorflow.keras.callbacks import EarlyStopping

# === Definir entradas ===
input_seq_shape = (X_train.shape[1], X_train.shape[2]) # (12, 5)
num_grupos = len(np.unique(grupo_input_total)) # códigos únicos
embedding_dim = 4

# === Capas de entrada
seq_input = Input(shape=input_seq_shape, name="seq_input")
grupo_input = Input(shape=(1,), name="grupo_input")

# === Embedding para grupo
grupo_embedding = Embedding(input_dim=num_grupos, output_dim=embedding_dim)(grupo_input)
grupo_embedding_flat = Flatten()(grupo_embedding)

```

```

grupo_embedding_repeated = RepeatVector(input_seq_shape[0])(grupo_embedding_flat)

# === Combinar secuencia + embedding
merged = Concatenate()([seq_input, grupo_embedding_repeated])

# === Red LSTM
x = LSTM(128, return_sequences=True)(merged)
x = Dropout(0.2)(x)
x = LSTM(64)(x)
x = Dense(32, activation="relu")(x)
output = Dense(1, activation="linear")(x)

# === Definición y compilación
model = Model(inputs=[seq_input, grupo_input], outputs=output)
model.compile(optimizer="adam", loss="mse", metrics=["mae"])

# === Entrenamiento
early_stop = EarlyStopping(monitor="val_loss", patience=15, restore_best_weights=True)

history = model.fit(
    {"seq_input": X_train, "grupo_input": grupo_train},
    y_train,
    validation_split=0.1,
    epochs=50,
    batch_size=64,
    callbacks=[early_stop],
    verbose=1
)

from sklearn.metrics import mean_absolute_error, mean_absolute_percentage_error, r2_score,
mean_squared_error
import matplotlib.pyplot as plt
import pandas as pd

# === Predicción sobre test ===
y_pred_test = model.predict({"seq_input": X_test, "grupo_input": grupo_test}).flatten()

# === DataFrame con resultados
df_test_resultados = pd.DataFrame({
    "Fecha": fechas_test,
    "Real": y_test,
    "Pred": y_pred_test
})
df_test_resultados["Mes"] =
pd.to_datetime(df_test_resultados["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes a nivel nacional

```

```

df_test_mensual = df_test_resultados.groupby("Mes")[["Real", "Pred"]].sum()

# === Métricas
mae = mean_absolute_error(df_test_mensual["Real"], df_test_mensual["Pred"])
rmse = np.sqrt(mean_squared_error(df_test_mensual["Real"], df_test_mensual["Pred"]))
mape = mean_absolute_percentage_error(df_test_mensual["Real"], df_test_mensual["Pred"]) * 100

print(" MÉTRICAS TEST - 2023:")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

# === 5. Gráfica
plt.figure(figsize=(12, 5))
plt.plot(df_test_mensual.index, df_test_mensual["Real"], label="Consumo real (2023)", marker="o")
plt.plot(df_test_mensual.index, df_test_mensual["Pred"], label="Predicción LSTM (2023)", marker="x",
linestyle="--")
plt.title("Predicción LSTM del consumo energético nacional (enero-diciembre 2023)")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

import matplotlib.pyplot as plt
import pandas as pd

# === Agrupar entrenamiento por mes
df_train_plot = pd.DataFrame({
    "Fecha": fechas_train,
    "Energia_GWh": y_train
})
df_train_plot["Mes"] = pd.to_datetime(df_train_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()
df_train_mensual = df_train_plot.groupby("Mes")["Energia_GWh"].sum().reset_index()
df_train_mensual.columns = ["Mes", "Real_GWh"]

# === Preparar test con predicción
df_test_mensual = df_test_resultados.groupby("Mes")[["Real", "Pred"]].sum().reset_index()
df_test_mensual.columns = ["Mes", "Real_GWh", "Prediccion_GWh"]

# === Unir ambas fases
df_entrenamiento = df_train_mensual.copy()
df_test_real = df_test_mensual[["Mes", "Real_GWh"]]
df_test_pred = df_test_mensual[["Mes", "Prediccion_GWh"]]

```

```

# === Graficar
plt.figure(figsize=(12, 6))

# Real entrenamiento (2014-2022)
plt.plot(df_entrenamiento["Mes"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2022)", color="black", linewidth=2)

# Real test (2023)
plt.plot(df_test_real["Mes"], df_test_real["Real_GWh"],
         label="Consumo Real 2023", color="red", marker="o", linewidth=2)

# Predicción LSTM
plt.plot(df_test_pred["Mes"], df_test_pred["Prediccion_GWh"],
         label="Predicción LSTM 2023", color="blue", linestyle="--", marker="x", linewidth=2)

# Estética
plt.title("Predicción del Consumo Energético Nacional - LSTM Desagregado (2014-2023)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

#LSTM (2014-2024)

import pandas as pd
import numpy as np
from sklearn.preprocessing import LabelEncoder

# === Cargar el CSV ===
df = pd.read_csv("df_nn.csv", parse_dates=["Fecha"])

# === Filtrar fechas válidas ===
df2024=df.copy()
df = df[(df["Fecha"] >= "2014-01-01") & (df["Fecha"] <= "2024-12-31")].copy()

# === Eliminar valores negativos
df = df[df["Energia_GWh"] >= 0]

# === Crear columna Mes
df["Mes"] = df["Fecha"].dt.to_period("M").dt.to_timestamp()

# === Identificar series válidas (>=119 meses)
series = df.groupby(["Latitud", "Longitud", "Grupo_Consumo"])["Mes"].nunique().reset_index()

```

```

series.columns = ["Lat", "Lon", "Grupo", "Meses_disponibles"]
series_validas = series[series["Meses_disponibles"] >= 119]

# === Filtrar DataFrame a solo series válidas
df = df.merge(series_validas, how="inner", left_on=["Latitud", "Longitud", "Grupo_Consumo"],
              right_on=["Lat", "Lon", "Grupo"])
df = df.drop(columns=["Meses_disponibles", "Lat", "Lon", "Grupo"])

# === Agrupar por provincia + grupo + mes
df_grouped = df.groupby(["Mes", "Grupo_Consumo", "Latitud", "Longitud"],
                        as_index=False)["Energia_GWh"].sum()

# === Agregar estacionalidad
df_grouped["Mes_num"] = df_grouped["Mes"].dt.month
df_grouped["Mes_sin"] = np.sin(2 * np.pi * df_grouped["Mes_num"] / 12)
df_grouped["Mes_cos"] = np.cos(2 * np.pi * df_grouped["Mes_num"] / 12)

# === Codificar grupo de consumo
le_grupo = LabelEncoder()
df_grouped["Grupo_Consumo_Cod"] = le_grupo.fit_transform(df_grouped["Grupo_Consumo"])

# === Verificar
print(df_grouped.head())
print("Series válidas:", df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"]).ngroups)

from tqdm import tqdm
import numpy as np

# === Inicialización ===
n_steps = 12
X_total, y_total = [], []
grupo_input_total = []
fechas_total = []
serie_clave_total = []

# === Generar secuencias por serie ===
grupos = df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"])

for (lat, lon, grupo_cod), group in tqdm(grupos, desc="Procesando series"):
    group = group.sort_values("Mes").reset_index(drop=True)

    if len(group) < n_steps + 1:
        continue

    for i in range(len(group) - n_steps):
        ventana = group.iloc[i:i + n_steps]
        target = group.iloc[i + n_steps]["Energia_GWh"]

```

```

fecha_target = group.iloc[i + n_steps]["Mes"]

secuencia = ventana[["Energia_GWh", "Mes_sin", "Mes_cos", "Latitud", "Longitud"]].values

X_total.append(secuencia)
y_total.append(target)
grupo_input_total.append(grupo_cod)
fechas_total.append(fecha_target)
serie_clave_total.append((lat, lon, grupo_cod))

# === Convertir a arrays ===
X_total = np.array(X_total)
y_total = np.array(y_total)
grupo_input_total = np.array(grupo_input_total)
fechas_total = np.array(fechas_total)
serie_clave_total = np.array(serie_clave_total)

# === Dividir por fecha (test = desde 2024-01-01) ===
fechas_total_ts = pd.to_datetime(fechas_total)
fecha_corte = pd.Timestamp("2024-01-01")

mask_train = fechas_total_ts < fecha_corte
mask_test = fechas_total_ts >= fecha_corte

X_train = X_total[mask_train]
y_train = y_total[mask_train]
grupo_train = grupo_input_total[mask_train]
fechas_train = fechas_total[mask_train]
clave_train = serie_clave_total[mask_train]

X_test = X_total[mask_test]
y_test = y_total[mask_test]
grupo_test = grupo_input_total[mask_test]
fechas_test = fechas_total[mask_test]
clave_test = serie_clave_total[mask_test]

# === Verificar ===
print(" División por fecha aplicada correctamente:")
print("Entrenamiento:", fechas_train.min(), "→", fechas_train.max())
print("Test:", fechas_test.min(), "→", fechas_test.max())
print("X_train:", X_train.shape, " | X_test:", X_test.shape)

import matplotlib.pyplot as plt
import pandas as pd

# === Crear DataFrame para entrenamiento
df_train_plot = pd.DataFrame({

```

```

        "Fecha": fechas_train,
        "Energia_GWh": y_train,
        "Tipo": "Entrenamiento"
    })

# === Crear DataFrame para test
df_test_plot = pd.DataFrame({
    "Fecha": fechas_test,
    "Energia_GWh": y_test,
    "Tipo": "Test"
})

# === Unir ambos DataFrames
df_plot = pd.concat([df_train_plot, df_test_plot])
df_plot["Mes"] = pd.to_datetime(df_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes y tipo
df_mes = df_plot.groupby(["Mes", "Tipo"])["Energia_GWh"].sum().reset_index()

# === Graficar
plt.figure(figsize=(12, 5))
for tipo in df_mes["Tipo"].unique():
    datos = df_mes[df_mes["Tipo"] == tipo]
    plt.plot(datos["Mes"], datos["Energia_GWh"], label=f"{tipo}", marker="o")

plt.title("Distribución mensual de consumo energético - Train vs Test")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, LSTM, Dense, Dropout, Embedding, Concatenate,
RepeatVector, Flatten
from tensorflow.keras.callbacks import EarlyStopping

# === Definir entradas ===
input_seq_shape = (X_train.shape[1], X_train.shape[2]) # (12, 5)
num_grupos = len(np.unique(grupo_input_total)) # códigos únicos
embedding_dim = 4

# === Capas de entrada
seq_input = Input(shape=input_seq_shape, name="seq_input")

```

```

grupo_input = Input(shape=(1,), name="grupo_input")

# === Embedding para grupo
grupo_embedding = Embedding(input_dim=num_grupos, output_dim=embedding_dim)(grupo_input)
grupo_embedding_flat = Flatten()(grupo_embedding)
grupo_embedding_repeated = RepeatVector(input_seq_shape[0])(grupo_embedding_flat)

# === Combinar secuencia + embedding
merged = Concatenate()([seq_input, grupo_embedding_repeated])

# === Red LSTM
x = LSTM(128, return_sequences=True)(merged)
x = Dropout(0.2)(x)
x = LSTM(64)(x)
x = Dense(32, activation="relu")(x)
output = Dense(1, activation="linear")(x)

# === Definición y compilación
model = Model(inputs=[seq_input, grupo_input], outputs=output)
model.compile(optimizer="adam", loss="mse", metrics=["mae"])

# === Entrenamiento
early_stop = EarlyStopping(monitor="val_loss", patience=15, restore_best_weights=True)

history = model.fit(
    {"seq_input": X_train, "grupo_input": grupo_train},
    y_train,
    validation_split=0.1,
    epochs=50,
    batch_size=64,
    callbacks=[early_stop],
    verbose=1
)

from sklearn.metrics import mean_absolute_error, mean_absolute_percentage_error, r2_score,
mean_squared_error
import matplotlib.pyplot as plt
import pandas as pd

# === Predicción sobre test ===
y_pred_test = model.predict({"seq_input": X_test, "grupo_input": grupo_test}).flatten()

# === DataFrame con resultados
df_test_resultados = pd.DataFrame({
    "Fecha": fechas_test,
    "Real": y_test,
    "Pred": y_pred_test
})

```

```

}))
df_test_resultados["Mes"] =
pd.to_datetime(df_test_resultados["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes a nivel nacional
df_test_mensual = df_test_resultados.groupby("Mes")[["Real", "Pred"]].sum()

# === Métricas
mae = mean_absolute_error(df_test_mensual["Real"], df_test_mensual["Pred"])
rmse = np.sqrt(mean_squared_error(df_test_mensual["Real"], df_test_mensual["Pred"]))
mape = mean_absolute_percentage_error(df_test_mensual["Real"], df_test_mensual["Pred"]) * 100

print(" MÉTRICAS TEST - SOLO 2024:")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

# === Gráfica
plt.figure(figsize=(12, 5))
plt.plot(df_test_mensual.index, df_test_mensual["Real"], label="Consumo real (2024)", marker="o")
plt.plot(df_test_mensual.index, df_test_mensual["Pred"], label="Predicción LSTM (2024)", marker="x",
linestyle="--")
plt.title("Predicción LSTM del consumo energético nacional (enero-diciembre 2024)")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

import matplotlib.pyplot as plt
import pandas as pd

# === Agrupar entrenamiento por mes
df_train_plot = pd.DataFrame({
    "Fecha": fechas_train,
    "Energia_GWh": y_train
})
df_train_plot["Mes"] = pd.to_datetime(df_train_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()
df_train_mensual = df_train_plot.groupby("Mes")["Energia_GWh"].sum().reset_index()
df_train_mensual.columns = ["Mes", "Real_GWh"]

# === Preparar test con predicción
df_test_mensual = df_test_resultados.groupby("Mes")[["Real", "Pred"]].sum().reset_index()
df_test_mensual.columns = ["Mes", "Real_GWh", "Prediccion_GWh"]

```

```

# === Unir ambas fases
df_entrenamiento = df_train_mensual.copy()
df_test_real = df_test_mensual[["Mes", "Real_GWh"]]
df_test_pred = df_test_mensual[["Mes", "Prediccion_GWh"]]

# === Graficar
plt.figure(figsize=(12, 6))

# Real entrenamiento (2014-2023)
plt.plot(df_entrenamiento["Mes"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2023)", color="black", linewidth=2)

# Real test (2024)
plt.plot(df_test_real["Mes"], df_test_real["Real_GWh"],
         label="Consumo Real 2024", color="red", marker="o", linewidth=2)

# Predicción LSTM
plt.plot(df_test_pred["Mes"], df_test_pred["Prediccion_GWh"],
         label="Predicción LSTM 2024", color="blue", linestyle="--", marker="x", linewidth=2)

# Estética
plt.title("Predicción del Consumo Energético Nacional - LSTM Desagregado (2014-2024)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

```

F. Modelo RNN BiLSTM

```

#BiLSTM (2014-2023)

import pandas as pd
import numpy as np
from sklearn.preprocessing import LabelEncoder

# === Cargar el CSV ===
df = pd.read_csv("df_nn.csv", parse_dates=["Fecha"])

# === Filtrar fechas válidas ===
df2024=df.copy()
df = df[(df["Fecha"] >= "2014-01-01") & (df["Fecha"] <= "2023-12-31")].copy()

```

```

# === Eliminar valores negativos
df = df[df["Energia_GWh"] >= 0]

# === Crear columna Mes
df["Mes"] = df["Fecha"].dt.to_period("M").dt.to_timestamp()

# === Identificar series válidas (>=119 meses)
series = df.groupby(["Latitud", "Longitud", "Grupo_Consumo"])[["Mes"]].nunique().reset_index()
series.columns = ["Lat", "Lon", "Grupo", "Meses_disponibles"]
series_validas = series[series["Meses_disponibles"] >= 119]

# === Filtrar DataFrame a solo series válidas
df = df.merge(series_validas, how="inner", left_on=["Latitud", "Longitud", "Grupo_Consumo"],
              right_on=["Lat", "Lon", "Grupo"])
df = df.drop(columns=["Meses_disponibles", "Lat", "Lon", "Grupo"])

# === Agrupar por provincia + grupo + mes
df_grouped = df.groupby(["Mes", "Grupo_Consumo", "Latitud", "Longitud"],
                        as_index=False)[["Energia_GWh"]].sum()

# === Agregar estacionalidad
df_grouped["Mes_num"] = df_grouped["Mes"].dt.month
df_grouped["Mes_sin"] = np.sin(2 * np.pi * df_grouped["Mes_num"] / 12)
df_grouped["Mes_cos"] = np.cos(2 * np.pi * df_grouped["Mes_num"] / 12)

# === Codificar grupo de consumo
le_grupo = LabelEncoder()
df_grouped["Grupo_Consumo_Cod"] = le_grupo.fit_transform(df_grouped["Grupo_Consumo"])

# === Verificar
print(df_grouped.head())
print("Series válidas:", df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"]).ngroups)

from tqdm import tqdm
import numpy as np

# === Inicialización ===
n_steps = 12
X_total, y_total = [], []
grupo_input_total = []
fechas_total = []
serie_clave_total = []

# === Generar secuencias por serie ===
grupos = df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"])

```

```

for (lat, lon, grupo_cod), group in tqdm(grupos, desc="Procesando series"):
    group = group.sort_values("Mes").reset_index(drop=True)

    if len(group) < n_steps + 1:
        continue

    for i in range(len(group) - n_steps):
        ventana = group.iloc[i:i + n_steps]
        target = group.iloc[i + n_steps]["Energia_GWh"]
        fecha_target = group.iloc[i + n_steps]["Mes"]

        secuencia = ventana[["Energia_GWh", "Mes_sin", "Mes_cos", "Latitud", "Longitud"]].values

        X_total.append(secuencia)
        y_total.append(target)
        grupo_input_total.append(grupo_cod)
        fechas_total.append(fecha_target)
        serie_clave_total.append((lat, lon, grupo_cod))

# === Convertir a arrays ===
X_total = np.array(X_total)
y_total = np.array(y_total)
grupo_input_total = np.array(grupo_input_total)
fechas_total = np.array(fechas_total)
serie_clave_total = np.array(serie_clave_total)

# === Dividir por fecha (test = desde 2023-01-01) ===
fechas_total_ts = pd.to_datetime(fechas_total)
fecha_corte = pd.Timestamp("2023-01-01")

mask_train = fechas_total_ts < fecha_corte
mask_test = fechas_total_ts >= fecha_corte

X_train = X_total[mask_train]
y_train = y_total[mask_train]
grupo_train = grupo_input_total[mask_train]
fechas_train = fechas_total[mask_train]
clave_train = serie_clave_total[mask_train]

X_test = X_total[mask_test]
y_test = y_total[mask_test]
grupo_test = grupo_input_total[mask_test]
fechas_test = fechas_total[mask_test]
clave_test = serie_clave_total[mask_test]

# === Verificar ===
print(" División por fecha aplicada correctamente:")

```

```

print("Entrenamiento:", fechas_train.min(), "→", fechas_train.max())
print("Test:", fechas_test.min(), "→", fechas_test.max())
print("X_train:", X_train.shape, " | X_test:", X_test.shape)

import matplotlib.pyplot as plt
import pandas as pd

# === Crear DataFrame para entrenamiento
df_train_plot = pd.DataFrame({
    "Fecha": fechas_train,
    "Energia_GWh": y_train,
    "Tipo": "Entrenamiento"
})

# === Crear DataFrame para test
df_test_plot = pd.DataFrame({
    "Fecha": fechas_test,
    "Energia_GWh": y_test,
    "Tipo": "Test"
})

# === Unir ambos DataFrames
df_plot = pd.concat([df_train_plot, df_test_plot])
df_plot["Mes"] = pd.to_datetime(df_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes y tipo
df_mes = df_plot.groupby(["Mes", "Tipo"])["Energia_GWh"].sum().reset_index()

# === Graficar
plt.figure(figsize=(12, 5))
for tipo in df_mes["Tipo"].unique():
    datos = df_mes[df_mes["Tipo"] == tipo]
    plt.plot(datos["Mes"], datos["Energia_GWh"], label=f"{tipo}", marker="o")

plt.title("Distribución mensual de consumo energético - Train vs Test")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, LSTM, Dense, Dropout, Embedding, Concatenate,
RepeatVector, Flatten, Bidirectional, LeakyReLU
from tensorflow.keras.callbacks import EarlyStopping

```

```

# === Definir entradas ===
input_seq_shape = (X_train.shape[1], X_train.shape[2]) # ahora (18, 5)
num_grupos = len(np.unique(grupo_input_total))
embedding_dim = 4

seq_input = Input(shape=input_seq_shape, name="seq_input")
grupo_input = Input(shape=(1,), name="grupo_input")

# === Embedding para grupo ===
grupo_embedding = Embedding(input_dim=num_grupos, output_dim=embedding_dim)(grupo_input)
grupo_embedding_flat = Flatten()(grupo_embedding)
grupo_embedding_repeated = RepeatVector(input_seq_shape[0])(grupo_embedding_flat)

# === Concatenar ===
merged = Concatenate()([seq_input, grupo_embedding_repeated])

# === Bi-LSTM + Dropout
x = Bidirectional(LSTM(128, return_sequences=True))(merged)
x = Dropout(0.2)(x)
x = Bidirectional(LSTM(64))(x)

# === Dense con LeakyReLU
x = Dense(64)(x)
x = LeakyReLU()(x)
x = Dense(32)(x)
x = LeakyReLU()(x)
output = Dense(1)(x)

# === Compilar modelo
model = Model(inputs=[seq_input, grupo_input], outputs=output)
model.compile(optimizer="adam", loss="mse", metrics=["mae"])
model.summary()

early_stop = EarlyStopping(monitor="val_loss", patience=20, restore_best_weights=True)

history = model.fit(
    {"seq_input": X_train, "grupo_input": grupo_train},
    y_train,
    validation_split=0.1,
    epochs=100,
    batch_size=64,
    callbacks=[early_stop],
    verbose=1
)

from sklearn.metrics import mean_absolute_error, mean_absolute_percentage_error, r2_score,
mean_squared_error

```

```

import matplotlib.pyplot as plt
import pandas as pd

# === Predicción sobre test ===
y_pred_test = model.predict({"seq_input": X_test, "grupo_input": grupo_test}).flatten()

# === DataFrame con resultados
df_test_resultados = pd.DataFrame({
    "Fecha": fechas_test,
    "Real": y_test,
    "Pred": y_pred_test
})
df_test_resultados["Mes"] =
df_test_resultados["Fecha"].dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes a nivel nacional
df_test_mensual = df_test_resultados.groupby("Mes")[["Real", "Pred"]].sum()

# === Métricas
mae = mean_absolute_error(df_test_mensual["Real"], df_test_mensual["Pred"])
rmse = np.sqrt(mean_squared_error(df_test_mensual["Real"], df_test_mensual["Pred"]))
mape = mean_absolute_percentage_error(df_test_mensual["Real"], df_test_mensual["Pred"]) * 100

print(" MÉTRICAS TEST - 2024:")
print(f" MAE   : {mae:.2f} GWh")
print(f" RMSE  : {rmse:.2f} GWh")
print(f" MAPE  : {mape:.2f} %")

# === Gráfica
plt.figure(figsize=(12, 5))
plt.plot(df_test_mensual.index, df_test_mensual["Real"], label="Consumo real (2023)", marker="o")
plt.plot(df_test_mensual.index, df_test_mensual["Pred"], label="Predicción LSTM (2023)", marker="x",
linestyle="--")
plt.title("Predicción LSTM del consumo energético nacional (enero-diciembre 2023)")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

import matplotlib.pyplot as plt
import pandas as pd

# === Agrupar entrenamiento por mes
df_train_plot = pd.DataFrame({

```

```

    "Fecha": fechas_train,
    "Energia_GWh": y_train
})
df_train_plot["Mes"] = pd.to_datetime(df_train_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()
df_train_mensual = df_train_plot.groupby("Mes")["Energia_GWh"].sum().reset_index()
df_train_mensual.columns = ["Mes", "Real_GWh"]

# === Preparar test con predicción
df_test_mensual = df_test_resultados.groupby("Mes")["Real", "Pred"].sum().reset_index()
df_test_mensual.columns = ["Mes", "Real_GWh", "Prediccion_GWh"]

# === Unir ambas fases
df_entrenamiento = df_train_mensual.copy()
df_test_real = df_test_mensual[["Mes", "Real_GWh"]]
df_test_pred = df_test_mensual[["Mes", "Prediccion_GWh"]]

# === Graficar
plt.figure(figsize=(12, 6))

# Real entrenamiento (2014-2022)
plt.plot(df_entrenamiento["Mes"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2022)", color="black", linewidth=2)

# Real test (2023)
plt.plot(df_test_real["Mes"], df_test_real["Real_GWh"],
         label="Consumo Real 2023", color="red", marker="o", linewidth=2)

# Predicción LSTM
plt.plot(df_test_pred["Mes"], df_test_pred["Prediccion_GWh"],
         label="Predicción BiLSTM 2023", color="blue", linestyle="--", marker="x", linewidth=2)

# Estética
plt.title("Predicción del Consumo Energético Nacional - BiLSTM Desagregado (2014-2023)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

#BiLSTM (2014-2024)

import pandas as pd
import numpy as np
from sklearn.preprocessing import LabelEncoder

```

```

# === Cargar el CSV ===
df = pd.read_csv("df_nn.csv", parse_dates=["Fecha"])

# === Filtrar fechas válidas ===
df2024=df.copy()
df = df[(df["Fecha"] >= "2014-01-01") & (df["Fecha"] <= "2024-12-31")].copy()

# === Eliminar valores negativos
df = df[df["Energia_GWh"] >= 0]

# === Crear columna Mes
df["Mes"] = df["Fecha"].dt.to_period("M").dt.to_timestamp()

# === Identificar series válidas (>=119 meses)
series = df.groupby(["Latitud", "Longitud", "Grupo_Consumo"])[["Mes"]].nunique().reset_index()
series.columns = ["Lat", "Lon", "Grupo", "Meses_disponibles"]
series_validas = series[series["Meses_disponibles"] >= 119]

# === Filtrar DataFrame a solo series válidas
df = df.merge(series_validas, how="inner", left_on=["Latitud", "Longitud", "Grupo_Consumo"],
              right_on=["Lat", "Lon", "Grupo"])
df = df.drop(columns=["Meses_disponibles", "Lat", "Lon", "Grupo"])

# === Agrupar por provincia + grupo + mes
df_grouped = df.groupby(["Mes", "Grupo_Consumo", "Latitud", "Longitud"],
                        as_index=False)[["Energia_GWh"]].sum()

# === Agregar estacionalidad
df_grouped["Mes_num"] = df_grouped["Mes"].dt.month
df_grouped["Mes_sin"] = np.sin(2 * np.pi * df_grouped["Mes_num"] / 12)
df_grouped["Mes_cos"] = np.cos(2 * np.pi * df_grouped["Mes_num"] / 12)

# === Codificar grupo de consumo
le_grupo = LabelEncoder()
df_grouped["Grupo_Consumo_Cod"] = le_grupo.fit_transform(df_grouped["Grupo_Consumo"])

# === 1 Verificar
print(df_grouped.head())
print("Series válidas:", df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"]).ngroups)

from tqdm import tqdm
import numpy as np

# === Inicialización ===
n_steps = 12
X_total, y_total = [], []

```

```

grupo_input_total = []
fechas_total = []
serie_clave_total = []

# === Generar secuencias por serie ===
grupos = df_grouped.groupby(["Latitud", "Longitud", "Grupo_Consumo_Cod"])

for (lat, lon, grupo_cod), group in tqdm(grupos, desc="Procesando series"):
    group = group.sort_values("Mes").reset_index(drop=True)

    if len(group) < n_steps + 1:
        continue

    for i in range(len(group) - n_steps):
        ventana = group.iloc[i:i + n_steps]
        target = group.iloc[i + n_steps]["Energia_GWh"]
        fecha_target = group.iloc[i + n_steps]["Mes"]

        secuencia = ventana[["Energia_GWh", "Mes_sin", "Mes_cos", "Latitud", "Longitud"]].values

        X_total.append(secuencia)
        y_total.append(target)
        grupo_input_total.append(grupo_cod)
        fechas_total.append(fecha_target)
        serie_clave_total.append((lat, lon, grupo_cod))

# === Convertir a arrays ===
X_total = np.array(X_total)
y_total = np.array(y_total)
grupo_input_total = np.array(grupo_input_total)
fechas_total = np.array(fechas_total)
serie_clave_total = np.array(serie_clave_total)

# === Dividir por fecha (test = desde 2024-01-01) ===
fechas_total_ts = pd.to_datetime(fechas_total)
fecha_corte = pd.Timestamp("2024-01-01")

mask_train = fechas_total_ts < fecha_corte
mask_test = fechas_total_ts >= fecha_corte

X_train = X_total[mask_train]
y_train = y_total[mask_train]
grupo_train = grupo_input_total[mask_train]
fechas_train = fechas_total[mask_train]
clave_train = serie_clave_total[mask_train]

X_test = X_total[mask_test]

```

```

y_test = y_total[mask_test]
grupo_test = grupo_input_total[mask_test]
fechas_test = fechas_total[mask_test]
clave_test = serie_clave_total[mask_test]

# === Verificar ===
print(" División por fecha aplicada correctamente:")
print("Entrenamiento:", fechas_train.min(), "→", fechas_train.max())
print("Test:", fechas_test.min(), "→", fechas_test.max())
print("X_train:", X_train.shape, " | X_test:", X_test.shape)

import matplotlib.pyplot as plt
import pandas as pd

# === Crear DataFrame para entrenamiento
df_train_plot = pd.DataFrame({
    "Fecha": fechas_train,
    "Energia_GWh": y_train,
    "Tipo": "Entrenamiento"
})

# === Crear DataFrame para test
df_test_plot = pd.DataFrame({
    "Fecha": fechas_test,
    "Energia_GWh": y_test,
    "Tipo": "Test"
})

# === Unir ambos DataFrames
df_plot = pd.concat([df_train_plot, df_test_plot])
df_plot["Mes"] = pd.to_datetime(df_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes y tipo
df_mes = df_plot.groupby(["Mes", "Tipo"])["Energia_GWh"].sum().reset_index()

# === Graficar
plt.figure(figsize=(12, 5))
for tipo in df_mes["Tipo"].unique():
    datos = df_mes[df_mes["Tipo"] == tipo]
    plt.plot(datos["Mes"], datos["Energia_GWh"], label=f"{tipo}", marker="o")

plt.title("Distribución mensual de consumo energético - Train vs Test")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()

```

```

plt.show()

from tensorflow.keras.models import Model
from tensorflow.keras.layers import Input, LSTM, Dense, Dropout, Embedding, Concatenate,
RepeatVector, Flatten, Bidirectional, LeakyReLU
from tensorflow.keras.callbacks import EarlyStopping

# === Definir entradas ===
input_seq_shape = (X_train.shape[1], X_train.shape[2])
num_grupos = len(np.unique(grupo_input_total))
embedding_dim = 4

# === Capas de entrada ===
seq_input = Input(shape=input_seq_shape, name="seq_input")
grupo_input = Input(shape=(1,), name="grupo_input")

# === Embedding del grupo ===
grupo_embedding = Embedding(input_dim=num_grupos, output_dim=embedding_dim)(grupo_input)
grupo_embedding_flat = Flatten()(grupo_embedding)
grupo_embedding_repeated = RepeatVector(input_seq_shape[0])(grupo_embedding_flat)

# === Combinar entrada secuencia + embedding ===
merged = Concatenate()([seq_input, grupo_embedding_repeated])

# === Capas Bi-LSTM
x = Bidirectional(LSTM(128, return_sequences=True))(merged)
x = Dropout(0.2)(x)
x = Bidirectional(LSTM(64))(x)

# === Capas densas con LeakyReLU
x = Dense(32)(x)
x = LeakyReLU()(x)
output = Dense(1)(x)

# === Modelo y compilación
model = Model(inputs=[seq_input, grupo_input], outputs=output)
model.compile(optimizer="adam", loss="mse", metrics=["mae"])
model.summary()

# === Entrenamiento
early_stop = EarlyStopping(monitor="val_loss", patience=15, restore_best_weights=True)

history = model.fit(
    {"seq_input": X_train, "grupo_input": grupo_train},
    y_train,
    validation_split=0.1,
    epochs=100,

```

```

        batch_size=64,
        callbacks=[early_stop],
        verbose=1
    )

from sklearn.metrics import mean_absolute_error, mean_absolute_percentage_error, r2_score,
mean_squared_error
import matplotlib.pyplot as plt
import pandas as pd

# === Predicción sobre test ===
y_pred_test = model.predict({"seq_input": X_test, "grupo_input": grupo_test}).flatten()

# === DataFrame con resultados
df_test_resultados = pd.DataFrame({
    "Fecha": fechas_test,
    "Real": y_test,
    "Pred": y_pred_test
})
df_test_resultados["Mes"] =
pd.to_datetime(df_test_resultados["Fecha"]).dt.to_period("M").dt.to_timestamp()

# === Agrupar por mes a nivel nacional
df_test_mensual = df_test_resultados.groupby("Mes")[["Real", "Pred"]].sum()

# === Métricas
mae = mean_absolute_error(df_test_mensual["Real"], df_test_mensual["Pred"])
rmse = np.sqrt(mean_squared_error(df_test_mensual["Real"], df_test_mensual["Pred"]))
mape = mean_absolute_percentage_error(df_test_mensual["Real"], df_test_mensual["Pred"]) * 100

print(" MÉTRICAS TEST - 2024:")
print(f" MAE : {mae:.2f} GWh")
print(f" RMSE : {rmse:.2f} GWh")
print(f" MAPE : {mape:.2f} %")

# === Gráfica
plt.figure(figsize=(12, 5))
plt.plot(df_test_mensual.index, df_test_mensual["Real"], label="Consumo real (2023)", marker="o")
plt.plot(df_test_mensual.index, df_test_mensual["Pred"], label="Predicción BiLSTM (2023)",
marker="x", linestyle="--")
plt.title("Predicción LSTM del consumo energético nacional (enero-diciembre 2024)")
plt.xlabel("Mes")
plt.ylabel("Consumo total (GWh)")
plt.grid(True)
plt.legend()

```

```

plt.tight_layout()
plt.show()

import matplotlib.pyplot as plt
import pandas as pd

# === Agrupar entrenamiento por mes
df_train_plot = pd.DataFrame({
    "Fecha": fechas_train,
    "Energia_GWh": y_train
})
df_train_plot["Mes"] = pd.to_datetime(df_train_plot["Fecha"]).dt.to_period("M").dt.to_timestamp()
df_train_mensual = df_train_plot.groupby("Mes")["Energia_GWh"].sum().reset_index()
df_train_mensual.columns = ["Mes", "Real_GWh"]

# === Preparar test con predicción
df_test_mensual = df_test_resultados.groupby("Mes")["Real", "Pred"].sum().reset_index()
df_test_mensual.columns = ["Mes", "Real_GWh", "Prediccion_GWh"]

# === Unir ambas fases
df_entrenamiento = df_train_mensual.copy()
df_test_real = df_test_mensual[["Mes", "Real_GWh"]]
df_test_pred = df_test_mensual[["Mes", "Prediccion_GWh"]]

# === Graficar
plt.figure(figsize=(12, 6))

# Real entrenamiento (2014-2023)
plt.plot(df_entrenamiento["Mes"], df_entrenamiento["Real_GWh"],
         label="Entrenamiento (2014-2023)", color="black", linewidth=2)

# Real test (2024)
plt.plot(df_test_real["Mes"], df_test_real["Real_GWh"],
         label="Consumo Real 2024", color="red", marker="o", linewidth=2)

# Predicción LSTM
plt.plot(df_test_pred["Mes"], df_test_pred["Prediccion_GWh"],
         label="Predicción BiLSTM 2024", color="blue", linestyle="--", marker="x", linewidth=2)

# Estética
plt.title("Predicción del Consumo Energético Nacional - BiLSTM Desagregado (2014-2024)")
plt.xlabel("Fecha")
plt.ylabel("Consumo Energético (GWh)")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

```

Comparativa del desempeño entre redes neuronales recurrentes y modelos estadísticos en la predicción del consumo energético en Ecuador

Erick Manuel Mendoza Pico

Universidad Internacional de la Rioja, Logroño (España)

Fecha: 23/07/2025

RESUMEN

Ecuador depende en un 78 % de la generación hidroeléctrica, lo que lo hace altamente vulnerable ante fenómenos climáticos como El Niño. Esta vulnerabilidad afecta la planificación y operación del sistema eléctrico, especialmente cuando la demanda presenta comportamientos no lineales y difíciles de anticipar. Los enfoques tradicionales como ARIMA y SARIMA muestran limitaciones en estos contextos. El estado del arte evidencia un rezago en la adopción de modelos de inteligencia artificial en el país, pese a sus beneficios demostrados en otros sectores. Este trabajo propone una metodología en seis etapas para predecir el consumo energético mensual en Ecuador entre 2014 y 2024. Se construye un conjunto de datos a partir de fuentes oficiales, se aplica un proceso de limpieza y normalización, y se comparan modelos estadísticos (ARIMA, SARIMA) con redes neuronales recurrentes (LSTM, BiLSTM). Los resultados indican que el modelo LSTM desagregado alcanza la mayor precisión, con un RMSE de 68 GWh y un MAPE de 2.65 % bajo condiciones normales. Además, demuestra una mejor adaptación ante escenarios anómalos. Estas evidencias respaldan el uso de redes neuronales para fortalecer la planificación energética y aumentar la resiliencia del sistema eléctrico ecuatoriano.



PALABRAS CLAVE

ARIMA, Consumo Eléctrico, LSTM, Planificación Energética, Predicción Energética, Redes Neuronales Recurrentes.

I. INTRODUCCIÓN

La planificación energética en Ecuador enfrenta un escenario de alta complejidad debido a su fuerte dependencia de fuentes hidroeléctricas que representan más del 65 % de la matriz de generación, como se observa en la Figura 1 [1]. Esta situación convierte al sistema eléctrico nacional en un entorno especialmente vulnerable a la variabilidad climática como se evidenció en 2024 con la ocurrencia del fenómeno El Niño, que generó una crisis energética a nivel nacional. Ante esta realidad, la necesidad de herramientas predictivas más precisas y robustas es fundamental para anticipar escenarios de alta demanda o disminución de generación [2].




Fig. 1. Composición de la generación eléctrica por fuente en Ecuador.

Tradicionalmente la predicción del consumo energético se ha basado en modelos estadísticos como ARIMA o SARIMA. Sin

embargo, su capacidad para adaptarse a eventos anómalos o patrones no lineales es limitada. Por ello, se plantea explorar modelos de inteligencia artificial, en particular redes neuronales recurrentes como LSTM y BiLSTM, que han demostrado un alto rendimiento en series temporales complejas.

Este trabajo presenta un estudio comparativo entre modelos estadísticos y redes neuronales para predecir el consumo energético mensual en Ecuador durante el período 2014–2024. Se estructura en seis etapas metodológicas que abarcan la recolección y preprocesamiento de datos, el desarrollo e implementación de modelos, y la evaluación de su desempeño bajo condiciones normales y anómalas. Los resultados evidencian el potencial de los modelos LSTM para superar a los enfoques tradicionales lo que respalda su aplicación futura en entornos reales de planificación energética.

En la Sección II se muestra el estado del arte explicando la situación actual de los métodos de predicción en Ecuador y los métodos propuestos en este trabajo. En la Sección III se explica los objetivos del trabajo y la metodología aplicada. En la Sección IV se presenta las contribuciones del trabajo mediante la comparativa de los modelos. En la Sección V se muestra los resultados obtenidos comparando las métricas de los distintos modelos. En la Sección VI se discute los resultados obtenidos y finalmente en la Sección VII se definen las conclusiones del trabajo.

II. ESTADO DEL ARTE

La predicción del consumo energético ha sido ampliamente estudiada mediante modelos estadísticos tradicionales, entre los

que destacan el modelo autorregresivo integrado de medias móviles (ARIMA) y su variante estacional (SARIMA). Estos modelos son particularmente eficaces en la detección de tendencias y patrones estacionales en series temporales [1], [2]. Sin embargo, su capacidad de modelado se limita a relaciones lineales, y su desempeño se ve afectado negativamente ante datos con comportamientos no estacionarios, alta variabilidad o ruido estructural [3].

La incorporación de técnicas de inteligencia artificial (IA) ha ganado terreno en las últimas décadas como alternativa para superar estas limitaciones. En este contexto, se han explorado modelos basados en aprendizaje automático como regresores lineales, árboles de decisión, random forest, máquinas de soporte vectorial (SVM) y redes neuronales artificiales (ANN) [4], [5]. Estas técnicas han mostrado un mayor poder de generalización, especialmente cuando se integran múltiples variables explicativas y se trabaja con series temporales de alta dimensionalidad [6].

Uno de los avances más significativos en este campo ha sido la introducción de redes neuronales recurrentes (RNN) y, en particular, de las arquitecturas LSTM (Long Short-Term Memory), diseñadas para capturar dependencias de largo plazo en series temporales [7]. Estas redes han sido ampliamente utilizadas para tareas de predicción energética, tanto en contextos residenciales como industriales, debido a su capacidad para modelar dinámicas no lineales y adaptarse a patrones cambiantes [8], en la Figura 2 se observa su arquitectura frente a las RNN. Las variantes bidireccionales (BiLSTM) permiten capturar relaciones temporales en ambas direcciones de la serie lo que mejora el desempeño en algunos contextos [9].




Fig. 2. RNN y LSTM comparativa.

Numerosos estudios comparativos han confirmado que los modelos basados en LSTM superan a ARIMA y otros enfoques tradicionales en precisión especialmente en sistemas energéticos con alta variabilidad estacional o exposición a eventos externos, como los climáticos [10], [11], [12]. Además, investigaciones recientes han combinado LSTM con arquitecturas híbridas, mecanismos de atención o modelos exógenos para mejorar aún más la capacidad de predicción [13].

Sin embargo, pese al avance global en Ecuador el uso de modelos de inteligencia artificial en el ámbito energético sigue siendo incipiente. La mayoría de los trabajos locales se centran en técnicas estadísticas convencionales o en análisis retrospectivos de consumo [14], y son escasos los estudios que integran redes neuronales con datos reales y pruebas bajo escenarios anómalos. Esta brecha justifica la necesidad de investigaciones aplicadas que permitan validar y adaptar estas metodologías al contexto nacional contribuyendo tanto al conocimiento académico como a la planificación energética estratégica.

III. OBJETIVOS Y METODOLOGÍA

El objetivo principal de este estudio fue evaluar la precisión de las redes neuronales recurrentes (LSTM y BiLSTM) frente a modelos estadísticos tradicionales (ARIMA y SARIMA) para predecir el consumo eléctrico mensual en Ecuador entre 2014 y 2024. El propósito es identificar la metodología más precisa y robusta que pueda ser aplicada en contextos de alta variabilidad climática, contribuyendo así a una planificación energética más eficaz.

La metodología se estructuró en seis etapas:

1. Adquisición y análisis exploratorio de datos: Se recolectaron series temporales del consumo eléctrico nacional a través de plataformas oficiales.
2. Preprocesamiento del dataset: Se aplicaron técnicas de limpieza, imputación de valores faltantes, normalización y transformación estacional, garantizando la calidad de los datos para los modelos.
3. Implementación de modelos estadísticos: Se aplicaron modelos ARIMA y SARIMA, seleccionando parámetros óptimos mediante AIC y validación cruzada.
4. Desarrollo de modelos con redes neuronales: Se diseñó y entrenó modelos LSTM y BiLSTM con arquitecturas recurrentes, dropout, y ventanas temporales de entrada, utilizando Keras y TensorFlow.
5. Evaluación comparativa: Se evaluó el rendimiento de todos los modelos mediante métricas estándar (RMSE, MAE, MAPE) bajo condiciones normales (2023) y anómalas (2024).
6. Formulación de recomendaciones: Finalmente, se generaron conclusiones técnicas aplicables a la planificación energética nacional, considerando la aplicabilidad real de los modelos en escenarios complejos.

Este enfoque permite no solo comparar el desempeño predictivo de modelos clásicos y modernos, sino también proponer herramientas prácticas que respondan a la necesidad de predicción robusta en el contexto energético ecuatoriano.

IV. CONTRIBUCIÓN

La principal contribución de este trabajo consiste en el desarrollo de un enfoque comparativo entre modelos estadísticos tradicionales y redes neuronales recurrentes para la predicción del consumo energético mensual en Ecuador. Se aplicaron modelos estadísticos (ARIMA y SARIMA) y modelos RNN (LSTM y BiLSTM) sobre datos históricos desagregados por grupo de consumo y ubicación geográfica, lo que permitió una evaluación más detallada y realista del comportamiento del sistema eléctrico nacional.

Se recopiló datos históricos correspondiente al periodo 2014-2024, a partir de fuentes oficiales como el Ministerio de Energía y Minas y la Agencia de Regulación y Control de Electricidad (ARCONEL). La Figura 3 presenta la evolución del consumo energético mensual total en Ecuador expresado en gigavatios-hora (GWh) durante el periodo 2014-2024. Se observan patrones cíclicos consistentes con la estacionalidad típica del consumo eléctrico reflejando variaciones periódicas que podrían estar asociadas a estaciones del año, comportamiento productivo o condiciones climáticas.

Entre los años 2016 y 2019 se mantiene una tendencia creciente moderada. Sin embargo, en 2020 se evidencia una caída abrupta del consumo coherente con la reducción de la actividad económica y la movilidad asociada a la pandemia por COVID-19. Esta disminución es seguida de una recuperación sostenida a partir de 2021.




Fig. 3. Consumo energético mensual total en Ecuador 2014-2024 (GWh).

A finales de 2023 e inicios de 2024 se identifican nuevos descensos pronunciados los cuales coinciden con los efectos del fenómeno de El Niño y la crisis energética que afectó al país provocando cortes prolongados de suministro. Esta anomalía es especialmente relevante en el contexto de este trabajo, ya que resalta la necesidad de contar con modelos predictivos robustos capaces de anticipar caídas abruptas en el consumo.

Con los datos correctamente procesados, se procede a implementar los modelos estadísticos, para ello, se sigue la metodología clásica de Box-Jenkins. Esta metodología contempla cuatro etapas principales, mostradas en la Figura 4: identificación del modelo, estimación de parámetros, validación y pronóstico.




Fig. 4. Metodología Box-Jenkins.

Todos los modelos se evaluaron en dos situaciones distintas, en condiciones normales, es decir, datos de entrenamiento del periodo 2014-2022 y datos de evaluación del año 2023, y en condiciones anómalas, es decir, datos de entrenamiento del periodo 2014-2023 y datos de evaluación del año 2024, con el objetivo de observar la robustez de los modelos en condiciones poco comunes y con grandes consecuencias.

El primer modelo ARIMA, fue diseñado a través de la prueba de estacionariedad Dickey-Fuller aumentada (ADF), la cual mostro un modelo ARIMA (1,1,1), la predicción de este modelo se muestra en la Figura 5, con resultados de RMSE, MAE y

MAPE de 123.03 GWh, 108.79 GWh, 5.43 %, respectivamente.

Los resultados poco favorables son producto de la naturaleza de los datos, es por lo que se eligió un enfoque de modelado de datos desagregado mediante la segmentación de la serie temporal en subconjuntos por grupo de consumo y coordenadas (latitud y longitud). Este procedimiento permitió construir una serie

temporal específica para cada combinación (grupo + ubicación) resultando en decenas de subseries con al menos 120 meses de datos.



Fig. 5. Predicción del consumo energético con ARIMA (1,1,1).




Fig. 6. Predicción del consumo energético (2014-2023) con ARIMA Desagregado.




Fig. 7. Predicción del consumo energético (2014-2024) con ARIMA Desagregado

Los modelos ARIMA y SARIMA con enfoque desagregado definieron sus variables mediante la herramienta `auto_arima` que permite identificar los mejores hiperparámetros mediante un proceso iterativo. Mediante el proceso desagregado los resultados de los modelos se vieron favorecidos en condiciones normales como se muestra en la Figura 6, y 8, sin embargo en condiciones anómalas, los modelos no logran seguir el comportamiento del consumo eléctrico, lo que se observa en la Figura 7 y 9.




Fig. 8. Predicción del consumo energético (2014-2023) con SARIMA Desagregado.




Fig. 9. Predicción del consumo energético (2014-2024) con SARIMA Desagregado.

Los modelos RNN se implementaron con arquitectura ajustada específicamente para series energéticas con estacionalidad, incorporando técnicas de normalización, ajuste de ventanas temporales, codificación geográfica y regularización mediante Dropout y activaciones suaves. La Figura 10 muestra las predicciones del modelo LSTM desagregado en condiciones normales, su comportamiento se logra adaptar a la curva de consumo con márgenes aceptables ($RMSE = 68 \text{ GWh}$).

La Figura 11 muestra el comportamiento de las predicciones en condiciones anómalas, aunque las predicciones logran captar el comportamiento, los errores en estas son considerablemente grandes, lo que indica que se necesitan una comprensión mayor por parte del modelo para poder predecir correctamente estas situaciones poco frecuentes.




Fig. 10. Predicción del consumo energético (2014-2023) con LSTM Desagregado

El desarrollo de los modelos BiLSTM se basan en la misma metodología de preprocesamiento y estructura de datos utilizada en los modelos LSTM. El objetivo es evaluar si el uso de esta arquitectura bidireccional mejora el ajuste del modelo, especialmente en series energéticas con alta variabilidad o influencias no lineales más complejas.




Fig. 11. Predicción del consumo energético (2014-2024) con LSTM Desagregado.

Las Figuras 12 y 13 muestran las predicciones de los modelos BiLSTM, el modelo BiLSTM no evidenció una mejora sustancial frente a su contraparte unidireccional, lo cual sugiere que en este contexto el consumo energético responde mayoritariamente a patrones temporales causales donde la bidireccionalidad no aporta un valor predictivo adicional. No obstante, la exploración de BiLSTM permitió validar empíricamente esta hipótesis y fortalecer la robustez metodológica del estudio.




Fig. 12. Predicción del consumo energético (2014-2023) con BiLSTM Desagregado.




Fig. 13. Predicción del consumo energético (2014-2024) con BiLSTM Desagregado.

Los resultados muestran que el modelo LSTM desagregado logra superar a los modelos ARIMA y SARIMA con una mejora significativa en métricas como RMSE (68 GWh) y MAPE (2,65 %) en condiciones normales. Asimismo, demostró mayor capacidad de adaptación en contextos inestables, confirmando su aplicabilidad en sistemas eléctricos con alta sensibilidad climática. Este enfoque representa una base sólida para el uso de inteligencia artificial en la planificación energética ecuatoriana.

V. RESULTADOS

La comparación entre modelos estadísticos y redes neuronales se realizó utilizando tres métricas de error estándar: RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) y MAPE (Mean Absolute Percentage Error). Los resultados se evaluaron

para dos escenarios: condiciones normales (año 2023) y condiciones anómalas (año 2024).

En condiciones normales, el modelo LSTM desagregado obtuvo el mejor desempeño global en 2023, alcanzando los valores más bajos en las tres métricas. Este modelo logra un RMSE de 68.00 GWh y un MAPE de 2.65 %, lo cual representa una mejora significativa frente a los modelos estadísticos.

TABLA I
COMPARACIÓN DE MODELOS PREDICTIVOS DEL AÑO 2023.

Modelo	RMSE (GWh)	MAE (GWh)	MAPE (%)
ARIMA (1,1,1)	123.03	108.79	5.43
ARIMA Desagregado	118.09	97.25	4.88
SARIMA Desagregado	179.17	168.15	8.46
LSTM Desagregado	68.00	51.01	2.65
BiLSTM Desagregado	64.92	58.23	2.96

Aunque el modelo BiLSTM desagregado mostró un RMSE ligeramente menor (64.92 GWh), su MAE fue superior al del modelo LSTM lo que indica mayor variabilidad en sus errores. Además, su implementación conlleva una mayor complejidad computacional, sin representar una ventaja significativa en precisión.

En cambio, los modelos estadísticos desagregados (ARIMA y SARIMA) lograron mejorar ligeramente los resultados respecto al primer modelo ARIMA desarrollado lo cual confirma que la desagregación permite capturar mejor la heterogeneidad espacial y sectorial del consumo energético. Sin embargo, su capacidad de modelar dinámicas no lineales fue inferior frente a las redes neuronales, reflejándose en métricas de error más altas.

En resumen, los modelos basados en redes neuronales recurrentes, y en particular la arquitectura LSTM, ofrecieron un mejor ajuste a los patrones energéticos observados durante el 2023, confirmando su idoneidad para tareas de predicción bajo condiciones normales del sistema eléctrico ecuatoriano.

El año 2024 representó un escenario energético atípico en Ecuador, marcado por la influencia del fenómeno de El Niño y una profunda crisis hidroeléctrica que afectó la oferta y demanda del sistema eléctrico nacional. Estas condiciones generaron caídas abruptas en el consumo energético mensual interrumpiendo patrones estacionales previamente observados. Este contexto se convierte en una oportunidad para evaluar la robustez de los modelos implementados, entendida como su capacidad de mantener un rendimiento aceptable ante cambios extremos o no anticipados en la serie temporal.

Los resultados muestran que todos los modelos experimentaron un deterioro en su rendimiento respecto al año anterior, lo cual es esperable dado el comportamiento anómalo del 2024. Sin embargo, se observan diferencias importantes en la capacidad de cada enfoque para adaptarse a este nuevo contexto.

En primer lugar, el modelo SARIMA desagregado logra los mejores resultados en términos de RMSE y MAPE. Su capacidad para modelar patrones estacionales permitió una mejor adaptación al cambio, aunque con errores absolutos aún elevados. Este comportamiento sugiere que SARIMA, pese a sus limitaciones estructurales, puede ofrecer cierto nivel de amortiguación ante eventos repetitivos que aún conservan alguna estacionalidad interna.

Los modelos LSTM y BiLSTM desagregados, si bien no superaron a SARIMA en este escenario, lograron mantener una curva de predicción coherente y estructurada sin los colapsos observados en ARIMA. Sus errores absolutos se mantuvieron en niveles aceptables considerando la magnitud de las anomalías, y sus gráficas evidencian una mejor captación de la tendencia decreciente frente a modelos puramente lineales.

Finalmente, los modelos ARIMA (agregado y desagregado) fueron los más afectados, con errores cercanos a los 180 GWh en RMSE lo que evidencia poca capacidad para reaccionar ante rupturas de patrón o eventos fuera de la media histórica. Esto refleja su sensibilidad al ruido y su dependencia de la linealidad de la serie.

En resumen, ante condiciones adversas, los modelos estadísticos tradicionales se vieron superados por modelos con componentes estacionales (SARIMA) y, en menor medida, por redes neuronales recurrentes. Aunque estas últimas no lograron replicar la precisión alcanzada en 2023, demostraron una mayor estabilidad estructural en sus predicciones, lo que las posiciona como herramientas más robustas para contextos energéticos altamente variables.

TABLA II
COMPARACIÓN DE MODELOS PREDICTIVOS DEL AÑO 2024.

Modelo	RMSE (GWh)	MAE (GWh)	MAPE (%)
ARIMA (1,1,1)	181.99	157.88	8.63
ARIMA Desagregado	177.86	155.22	8.38
SARIMA Desagregado	159.20	140.44	7.56
LSTM Desagregado	158.18	143.16	7.80
BiLSTM Desagregado	156.30	143.10	7.75

VI. DISCUSIÓN

Los resultados obtenidos en este estudio reafirman las limitaciones de los modelos estadísticos tradicionales como ARIMA y SARIMA frente a dinámicas energéticas no lineales y contextos de alta incertidumbre climática. Aunque estos modelos presentan un rendimiento aceptable en condiciones normales, su precisión se ve severamente afectada en presencia de anomalías como las registradas en 2024.

Por otro lado, los modelos basados en redes neuronales recurrentes, en especial el LSTM desagregado, mostraron un mejor ajuste a la realidad del consumo energético en Ecuador. Su capacidad para capturar relaciones temporales de largo plazo y adaptarse a variaciones abruptas lo posiciona como una herramienta más robusta y confiable para la planificación energética.

Sin embargo, el modelo BiLSTM no logra superar al LSTM, lo que indica que una mayor complejidad arquitectónica no garantiza necesariamente una mejora en la precisión. Este hallazgo sugiere la importancia de adaptar cada modelo al contexto específico del sistema energético nacional, considerando tanto la calidad de los datos como la naturaleza del fenómeno a predecir.

Finalmente, estos resultados resaltan el potencial de la inteligencia artificial para fortalecer la resiliencia del sistema eléctrico ecuatoriano, pero también evidencian la necesidad de contar con bases de datos de mayor granularidad y con variables exógenas relevantes, como indicadores climáticos o macroeconómicos.

VII. CONCLUSIONES

El presente estudio logra cumplir con el objetivo general planteado, evaluando la precisión de las redes neuronales recurrentes frente a los modelos estadísticos tradicionales en la predicción del consumo energético mensual en Ecuador. Los resultados demuestran que los modelos basados en inteligencia artificial, particularmente el modelo LSTM desagregado, superan ampliamente a los modelos ARIMA y SARIMA, tanto en condiciones normales como en escenarios anómalos. Este modelo alcanza los mejores resultados con un RMSE de 68 GWh, un MAE de 51 GWh y un MAPE de 2.65 % para el año 2023. Estas métricas evidencian una mejora sustancial frente a los modelos estadísticos, cuyos errores fueron superiores a los 100 GWh en RMSE y más del 5 % en MAPE. La implementación del LSTM desagregado podría contribuir directamente a mitigar los efectos de eventos meteorológicos extremos como los registrados en 2024 y aumentar la resiliencia del sistema eléctrico nacional.

Se identificó que la alta dependencia del Ecuador en fuentes hidroeléctricas (78 % en 2023) lo expone a una marcada vulnerabilidad frente a fenómenos climáticos como El Niño. Esta situación genera escenarios de inestabilidad energética y justifica la necesidad de desarrollar herramientas predictivas más precisas y adaptables, que permitan anticipar crisis y planificar con mayor eficacia.

El análisis del estado del arte reveló un notable rezago en la aplicación de técnicas de inteligencia artificial en el sector energético ecuatoriano, en contraste con el avance registrado en otros países. Este trabajo contribuye a reducir dicha brecha, acercando al contexto nacional modelos predictivos avanzados que han demostrado su efectividad a nivel internacional.

Se construyó una base de datos robusta a partir de fuentes

oficiales gubernamentales, con un riguroso proceso de preprocesamiento, normalización y estructuración. Esta calidad permitió que los modelos fueran evaluados de forma justa y comparable, garantizando que los resultados reflejen con fidelidad el comportamiento real del consumo energético en Ecuador durante el período 2014–2024.

Se implementaron y compararon diversos modelos. El modelo LSTM desagregado fue el más preciso en condiciones normales (2023), mientras que BiLSTM, a pesar de su arquitectura más compleja, no mejoró significativamente los resultados. En escenarios extremos como el año 2024, los modelos estadísticos vieron deteriorarse sus métricas ($RMSE > 170$ GWh en ARIMA), mientras que el LSTM mantuvo un RMSE de 158 GWh y un MAPE aceptable de 7.8 %, evidenciando mayor capacidad de adaptación a cambios inesperados.

Sin embargo, con base en las limitaciones encontradas y las oportunidades detectadas durante el desarrollo del presente trabajo, se proponen las siguientes líneas futuras de investigación, con el fin de mejorar la precisión de los modelos y fortalecer la planificación energética mediante inteligencia artificial:

1. Incorporación de variables meteorológicas y exógenas

Una de las principales oportunidades de mejora consiste en integrar variables climáticas relevantes como temperatura, precipitación, radiación solar o humedad relativa que inciden directamente en el consumo energético, especialmente en contextos altamente dependientes de la generación hidroeléctrica como el ecuatoriano. La incorporación de variables exógenas permitiría capturar mejor la influencia de eventos climáticos extremos como El Niño, incrementando así la capacidad de los modelos para anticiparse a escenarios de crisis. Además, se sugiere incluir variables macroeconómicas que puedan explicar el comportamiento en ocasiones en donde el clima no tenga una alta variabilidad.

2. Aplicación de modelos híbridos y arquitecturas modernas

Otra línea de trabajo futura consiste en experimentar con modelos híbridos (como ARIMA-LSTM) y arquitecturas avanzadas como Transformers o TCN (Temporal Convolutional Networks), que han demostrado gran potencial para el análisis de series temporales complejas. Estos enfoques podrían mejorar la precisión de predicción y la capacidad de generalización de los modelos, especialmente ante datos con patrones no lineales o comportamiento errático.

3. Mejora en la calidad y resolución del dataset energético

Una limitación transversal en este trabajo, y en muchos otros estudios de predicción, es la disponibilidad y estructura de los datos. En este caso, los datos disponibles corresponden a registros mensuales por provincias, cantones y parroquias, lo cual reduce considerablemente la granularidad temporal y espacial de la información. Contar con series temporales de mayor resolución (diarias o semanales) y mejor estructuradas facilitaría el entrenamiento de modelos más potentes y precisos. En este sentido, se destaca la necesidad urgente de que los organismos públicos y entidades del sector energético prioricen la recolección, estandarización y liberación de datos de calidad. La disponibilidad de datasets abiertos, actualizados y bien documentados es un factor crítico para el desarrollo de soluciones basadas en inteligencia artificial que beneficien tanto a la investigación como a la toma de decisiones estratégicas.

REFERENCIAS

- [1] G. P. Zhang, “Time series forecasting using a hybrid ARIMA and neural network model,” *Neurocomputing*, vol. 50, pp. 159–175, 2003.
- [2] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed., OTexts, 2021.
- [3] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, “Statistical and Machine Learning forecasting methods: Concerns and ways forward,” *PLoS ONE*, vol. 13, no. 3, 2018.
- [4] M. Q. Raza, N. T. Ali, and M. S. Iqbal, “Electricity consumption forecasting using machine learning: A case study,” *Energies*, vol. 14, no. 1, pp. 1–19, 2021.
- [5] H. R. Heidari, F. Mahmoudi, and M. Askarzadeh, “Electricity consumption prediction using hybrid models based on decision trees and metaheuristics,” *Energy*, vol. 213, 2020.
- [6] T. Chen, C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794.
- [7] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [8] S. Kong et al., “Short-term residential load forecasting based on LSTM recurrent neural network,” *IEEE Access*, vol. 7, pp. 157633–157643, 2019.
- [9] R. Rundo et al., “Bidirectional LSTM networks for accurate electricity load forecasting,” *Applied Sciences*, vol. 10, no. 9, pp. 3105–3118, 2020.
- [10] J. Qin et al., “A hybrid deep learning model for load forecasting using LSTM and CNN,” *Electric Power Systems Research*, vol. 189, 2020.
- [11] L. Liu et al., “An improved LSTM-based electricity load forecasting model using empirical mode decomposition,” *Energies*, vol. 13, no. 8, 2020.
- [12] K. Khosravi et al., “Comparative study of ARIMA and LSTM in short-term load forecasting,” *Energy Reports*, vol. 7, pp. 1996–2008, 2021.
- [13] X. Zhang et al., “Attention-based LSTM for multivariate time series forecasting,” *Information Sciences*, vol. 536, pp. 246–262, 2020.
- [14] ARCONEL, “Estadísticas del Sector Eléctrico,” Agencia de Regulación y Control de Electricidad, Ecuador, 2024. [En línea]. Disponible: <https://www.regulacionelectrica.gob>.

Performance comparison between recurrent neural networks and statistical models in predicting energy consumption in Ecuador

Erick Manuel Mendoza Pico

Universidad Internacional de la Rioja, Logroño (España)

Date: 23/07/2025

ABSTRACT

Ecuador relies 78% on hydroelectric generation, making it highly vulnerable to climate phenomena such as El Niño. This vulnerability affects the planning and operation of the electricity system, especially when demand exhibits nonlinear behaviors that are difficult to anticipate. Traditional approaches such as ARIMA and SARIMA show limitations in these contexts. The state of the art shows a lag in the adoption of artificial intelligence models in the country, despite their proven benefits in other sectors.

This work proposes a six-stage methodology to predict monthly energy consumption in Ecuador between 2014 and 2024. A dataset is constructed from official sources, a cleaning and normalization process is applied, and statistical models (ARIMA, SARIMA) are compared with recurrent neural networks (LSTM, BiLSTM).

The results indicate that the disaggregated LSTM model achieves the highest accuracy, with an RMSE of 68 GWh and a MAPE of 2.65% under normal conditions. Furthermore, it demonstrates improved adaptation to anomalous scenarios. This evidence supports the use of neural networks to strengthen energy planning and increase the resilience of the Ecuadorian electricity system.

I. INTRODUCTION

Energy planning in Ecuador faces a highly complex scenario due to its heavy dependence on hydroelectric sources, which represent more than 65% of the generation mix, as seen in Figure 1 [1]. This situation makes the national electricity system especially vulnerable to climate variability, as evidenced in 2024 with the occurrence of the El Niño phenomenon, which generated a national energy crisis. Given this reality, the need for more accurate and robust predictive tools is essential to anticipate scenarios of high demand or decreased generation [2].




Fig. 1. Composition of electricity generation by source in Ecuador.

Energy consumption prediction has traditionally been based on statistical models such as ARIMA or SARIMA. However, their ability to adapt to anomalous events or nonlinear patterns is limited. Therefore, there is interest in exploring artificial

intelligence models, particularly recurrent neural networks such as LSTM and BiLSTM, which have demonstrated high performance in complex time series.

This work presents a comparative study between statistical models and neural networks for predicting monthly energy consumption in Ecuador during the period 2014–2024. It is structured in six methodological stages that include data collection and preprocessing, model development and implementation, and evaluation of their performance under normal and anomalous conditions. The results demonstrate the potential of LSTM models to outperform traditional approaches, supporting their future application in real-world energy planning environments.

Section II presents the state of the art, explaining the current status of prediction methods in Ecuador and the methods proposed in this work. Section III explains the objectives of this work and the methodology applied. Section IV presents the contributions of this work through a comparison of models. Section V shows the results obtained by comparing the metrics of the different models. Section VI discusses the results obtained, and finally, Section VII defines the conclusions of this work.

II. STATE OF THE ART

Energy consumption prediction has been widely studied using traditional statistical models, including the autoregressive integrated moving average (ARIMA) model and its seasonal variant (SARIMA). These models are particularly effective in detecting trends and seasonal patterns in time series [1], [2]. However, their modeling capabilities are limited to linear

unir
LA UNIVERSIDAD
EN INTERNET

Universidad
de Alcalá

Universidad
Rey Juan Carlos

KEY WORDS

ARIMA, Energy
Planning, Energy
Prediction, LSTM,
Power Consumption,
Recurrent Neural
Networks.

relationships, and their performance is negatively affected by data with non-stationary behavior, high variability, or structural noise [3].

The incorporation of artificial intelligence (AI) techniques has gained ground in recent decades as an alternative to overcome these limitations. In this context, machine learning-based models such as linear regressors, decision trees, random forests, support vector machines (SVMs), and artificial neural networks (ANNs) have been explored [4], [5]. These techniques have demonstrated greater generalization power, especially when integrating multiple explanatory variables and working with high-dimensional time series [6]. One of the most significant advances in this field has been the introduction of recurrent neural networks (RNNs) and, in particular, LSTM (Long Short-Term Memory) architectures, designed to capture long-term dependencies in time series [7]. These networks have been widely used for energy prediction tasks, both in residential and industrial contexts, due to their ability to model nonlinear dynamics and adapt to changing patterns [8]. Figure 2 shows their architecture compared to RNNs. Bidirectional variants (BiLSTM) allow capturing temporal relationships in both directions of the series, which improves performance in some contexts [9].




Fig. 2. RNN and LSTM comparison.

Numerous comparative studies have confirmed that LSTM-based models outperform ARIMA and other traditional approaches in accuracy, especially in energy systems with high seasonal variability or exposure to external events, such as climate [10], [11], [12]. Furthermore, recent research has combined LSTM with hybrid architecture, attention mechanisms, and exogenous models to further improve predictive capacity [13]. However, despite global progress, the use of artificial intelligence models in the energy sector in Ecuador remains in its infancy. Most local work focuses on conventional statistical techniques or retrospective consumption analyses [14], and few studies integrate neural networks with real-world data and test them under anomalous scenarios. This gap justifies the need for applied research that validates and adapts these methodologies to the national context, contributing to both academic knowledge and strategic energy planning.

III. OBJECTIVES AND METHODOLOGY

The main objective of this study was to evaluate the accuracy of recurrent neural networks (LSTM and BiLSTM) versus traditional statistical models (ARIMA and SARIMA) in predicting monthly electricity consumption in Ecuador between 2014 and 2024. The goal was to identify the most accurate and robust methodology that can be applied in contexts of high climate variability, thus contributing to more effective energy planning.

The methodology was structured in six stages:

1. Data acquisition and exploration analysis: Time series of national electricity consumption were collected through official platforms.
2. Dataset preprocessing: Data cleaning, missing value imputation, normalization, and seasonal transformation techniques were applied, ensuring data quality for the models.
3. Statistical model implementation: ARIMA and SARIMA models were applied, selecting optimal parameters using AIC and cross-validation.
4. Model development with neural networks: LSTM and BiLSTM models were designed and trained with recurrent architecture, dropout, and input windows, using Keras and TensorFlow.
5. Comparative evaluation: The performance of all models was evaluated using standard metrics (RMSE, MAE, MAPE) under normal (2023) and anomalous (2024) conditions.
6. Formulation of recommendations: Finally, technical conclusions applicable to national energy planning were generated, considering the real-world applicability of the models in complex scenarios.

This approach allows not only comparing the predictive performance of classic and modern models but also proposing practical tools that address the need for robust prediction in the Ecuadorian energy context.

IV. CONTRIBUTION

The main contribution of this work is the development of a comparative approach between traditional statistical models and recurrent neural networks for predicting monthly energy consumption in Ecuador. Statistical models (ARIMA and SARIMA) and RNN models (LSTM and BiLSTM) were applied to historical data disaggregated by consumption group and geographic location, allowing for a more detailed and realistic assessment of the behavior of the national electricity system.

Historical data for the period 2014–2024 were collected from official sources such as the Ministry of Energy and Mines and the Electricity Regulation and Control Agency (ARCONEL). Figure 3 presents the evolution of total monthly energy consumption in Ecuador, expressed in gigawatt-hours (GWh), during the period 2014–2024. Cyclical patterns are observed, consistent with the typical seasonality of electricity consumption, reflecting periodic variations that could be associated with seasons, production behavior, or weather conditions.




Fig. 3. Total monthly energy consumption in Ecuador 2014-2024 (GWh).

Between 2016 and 2019, a moderate upward trend continued. However, in 2020, a sharp drop in consumption was evident, consistent with the reduction in economic activity and mobility associated with the COVID-19 pandemic. This decline was

followed by a sustained recovery beginning in 2021.

At the end of 2023 and beginning of 2024, further sharp declines were identified, coinciding with the effects of the El Niño phenomenon and the energy crisis that affected the country, causing prolonged power outages. This anomaly is especially relevant in the context of this work, as it highlights the need for robust predictive models capable of anticipating abrupt drops in consumption.

Once the data has been properly processed, the statistical models are implemented using the classic Box-Jenkins methodology. This methodology includes four main stages, shown in Figure 4: model identification, parameter estimation, validation, and forecasting.




Fig. 4. Box-Jenkins methodology.

All models were evaluated under two different conditions: normal conditions, i.e., training data from the 2014-2022 period and evaluation data from 2023, and anomalous conditions, i.e., training data from the 2014-2023 period and evaluation data from 2024, to observe the robustness of the models under unusual and high-consequence conditions.

The first ARIMA model was designed using the Augmented Dickey-Fuller (ADF) stationarity test, which yielded a (1,1,1) ARIMA model. The prediction of this model is shown in Figure 5, with RMSE, MAE, and MAPE results of 123.03 GWh and 108.79 GWh, respectively.




Fig. 5. Prediction of energy consumption with ARIMA (1,1,1).

The unfavorable results are a product of the nature of the data, which is why a disaggregated data modeling approach was chosen, segmenting the time series into subsets by consumption group and coordinates (latitude and longitude). This procedure allowed for the construction of a specific time series for each combination (group + location), resulting in dozens of subseries with at least 120 months of data.




Fig. 6. Prediction of energy consumption (2014-2023) with Disaggregated ARIMA.




Fig. 7. Prediction of energy consumption (2014-2024) with Disaggregated ARIMA.




Fig. 8. Prediction of energy consumption (2014-2023) with Disaggregated SARIMA.




Fig. 9. Prediction of energy consumption (2014-2024) with Disaggregated SARIMA.

The disaggregated ARIMA and SARIMA models defined their variables using the `auto_arima` tool, which allows the optimal hyperparameters to be identified through an iterative process. Using the disaggregated process, the model results were improved under normal conditions, as shown in Figures 6 and 8. However, under anomalous conditions, the models failed to track the behavior of electricity consumption, as seen in Figures 7 and 9.

The RNN models were implemented with an architecture specifically tuned for energy series with seasonality, incorporating normalization techniques, time window adjustment, geocoding, and regularization using Dropout and soft activations. Figure 10 shows the predictions of the disaggregated LSTM model under normal conditions; its behavior adapts to the consumption curve with acceptable margins ($RMSE = 68$ GWh). Figure 11 shows the behavior of predictions under anomalous conditions. Although the predictions manage to capture the behavior, the errors in these are large, indicating that the model needs a greater understanding to be able to correctly predict these rare situations.




Fig. 10. Energy consumption prediction (2014-2023) with Disaggregated LSTM.




Fig. 11. Energy consumption prediction (2014-2024) with Disaggregated LSTM.

The development of the BiLSTM models is based on the same preprocessing methodology and data structure used in the LSTM models. The objective is to evaluate whether the use of this bidirectional architecture improves model fit, especially in energy series with high variability or more complex nonlinear influences.

Figures 12 and 13 show the predictions of the BiLSTM models. The BiLSTM model did not show a substantial improvement compared to its unidirectional counterpart, suggesting that in this context, energy consumption mostly responds to causal temporal patterns where bidirectionality does not provide additional predictive value. However, the exploration of BiLSTM allowed for empirical validation of this hypothesis and strengthened the methodological robustness of the study.

The results show that the disaggregated LSTM model outperformed the ARIMA and SARIMA models, with significant improvements in metrics such as RMSE (68 GWh) and MAPE (2.65%) under normal conditions. It also demonstrated greater adaptability in unstable environments, confirming its applicability in highly climate-sensitive electrical systems. This approach represents a solid foundation for the use of artificial intelligence in Ecuadorian energy planning,




Fig. 12. Energy consumption prediction (2014-2023) with Disaggregated BiLSTM.




Fig. 13. Energy consumption prediction (2014-2024) with Disaggregated BiLSTM.

V. RESULTS

The comparison between statistical models and neural networks was performed using three standard error metrics: RMSE (Root Mean Squared Error), MAE (Mean Absolute Error), and MAPE (Mean Absolute Percentage Error). The results were evaluated for two scenarios: normal conditions (2023) and anomalous conditions (2024).

Under normal conditions, the disaggregated LSTM model performed best overall in 2023, achieving the lowest values in all three metrics. This model achieved an RMSE of 68.00 GWh and a MAPE of 2.65%, which represents a significant improvement over the statistical models.

Although the disaggregated BiLSTM model showed a slightly lower RMSE (64.92 GWh), its MAE was higher than that of the LSTM model, indicating greater variability in its errors. Furthermore, its implementation entails greater computational complexity, without representing a significant advantage in accuracy. In contrast, disaggregated statistical models (ARIMA and SARIMA) slightly improved their results compared to the first ARIMA model developed, confirming that disaggregation better captures the spatial and sectoral heterogeneity of energy consumption. However, their ability to model nonlinear dynamics was inferior to that of neural networks, reflected in higher error metrics.

In summary, models based on recurrent neural networks, and in particular the LSTM architecture, offered a better fit to the energy patterns observed during 2023, confirming their suitability for prediction tasks under normal conditions in the Ecuadorian electricity system.

TABLE I
COMPARISON OF PREDICTIVE MODELS FOR 2023.

Model	RMSE (GWh)	MAE (GWh)	MAPE (%)
ARIMA (1,1,1)	123.03	108.79	5.43
ARIMA Disaggregated	118.09	97.25	4.88
SARIMA Disaggregated	179.17	168.15	8.46
LSTM Disaggregated	68.00	51.01	2.65
BiLSTM Disaggregated	64.92	58.23	2.96

The year 2024 represented an atypical energy scenario in Ecuador, marked by the influence of the El Niño phenomenon and a profound hydroelectric crisis that affected the supply and demand of the national electricity system. These conditions generated abrupt drops in monthly energy consumption, disrupting previously observed seasonal patterns. This context becomes an opportunity to evaluate the robustness of the implemented models, understood as their ability to maintain acceptable performance in the face of extreme or unanticipated changes in the time series.

The results show that all models experienced a deterioration in performance compared to the previous year, which is expected given the anomalous behavior in 2024. However, significant differences are observed in the ability of each approach to adapt to this new context.

First, the disaggregated SARIMA model achieved the best results in terms of RMSE and MAPE. Its ability to model seasonal patterns allowed for better adaptation to change, although with still high absolute errors. This behavior suggests that SARIMA, despite its structural limitations, can offer some level of cushioning against repetitive events that still retain some internal seasonality.

The disaggregated LSTM and BiLSTM models, while not outperforming SARIMA in this scenario, managed to maintain a coherent and structured prediction curve without the collapses observed in ARIMA. Their absolute errors remained at acceptable levels considering the magnitude of the anomalies, and their graphs show a better capture of the downward trend compared to purely linear models.

Finally, the ARIMA models (aggregated and disaggregated) were the most affected, with errors close to 180 GWh in RMSE, showing little ability to react to pattern breaks or events outside the historical average. This reflects their sensitivity to noise and their dependence on the linearity of the series.

In summary, under adverse conditions, traditional statistical models were outperformed by models with seasonal components (SARIMA) and, to a lesser extent, by recurrent neural networks.

Although the latter failed to replicate the accuracy achieved in 2023, they demonstrated greater structural stability in their predictions, positioning them as more robust tools for highly variable energy environments.

TABLE II
COMPARISON OF PREDICTIVE MODELS FOR 2024.

Modelo	RMSE (GWh)	MAE (GWh)	MAPE (%)
ARIMA (1,1,1)	181.99	157.88	8.63
ARIMA Disaggregated	177.86	155.22	8.38
SARIMA Disaggregated	159.20	140.44	7.56
LSTM Disaggregated	158.18	143.16	7.80
BiLSTM Disaggregated	156.30	143.10	7.75

VI. DISCUSSION

The results obtained in this study reaffirm the limitations of traditional statistical models such as ARIMA and SARIMA in the face of nonlinear energy dynamics and contexts of high climate uncertainty. Although these models perform under normal conditions, their accuracy is severely affected by anomalies such as those recorded in 2024.

On the other hand, models based on recurrent neural networks, especially the disaggregated LSTM, showed a better fit to the reality of energy consumption in Ecuador. Its ability to capture long-term temporal relationships and adapt to abrupt variations positions as a more robust and reliable tool for energy planning.

However, the BiLSTM model failed to outperform the LSTM, indicating that greater architectural complexity does not necessarily guarantee improved accuracy. This finding suggests the importance of adapting each model to the specific context of the national energy system, considering both the quality of the data and the nature of the phenomenon to be predicted. Finally, these results highlight the potential of artificial intelligence to strengthen the resilience of the Ecuadorian electricity system but also demonstrate the need for more granular databases with relevant exogenous variables, such as climate or macroeconomic indicators.

VII. CONCLUSION

This study successfully met its overall objective by evaluating the accuracy of recurrent neural networks (RNNs) versus traditional statistical models in predicting monthly energy consumption in Ecuador. The results demonstrate that AI-based models, particularly the disaggregated LSTM model, significantly outperform ARIMA and SARIMA models, both under normal

and anomalous conditions. This model achieved the best results with an RMSE of 68 GWh, an MAE of 51 GWh, and a MAPE of 2.65% for 2023. These metrics demonstrate a substantial improvement compared to statistical models, whose errors were greater than one hundred GWh in RMSE and more than 5% in MAPE. The implementation of the disaggregated LSTM could directly contribute to mitigating the effects of extreme weather events such as those recorded in 2024 and increasing the resilience of the national electricity system. It was identified that Ecuador's high dependence on hydroelectric sources (78% in 2023) exposes it to significant vulnerability to climate phenomena such as El Niño. This situation generates scenarios of energy instability and justifies the need to develop more accurate and adaptable predictive tools that allow for anticipating crises and planning more effectively.

The state-of-the-art analysis revealed a notable lag in the application of artificial intelligence techniques in the Ecuadorian energy sector, in contrast to the progress made in other countries. This work contributes to reducing this gap by bringing advanced predictive models that have proven their effectiveness intentionally closer to the national context.

A robust database was built from official government sources, with a rigorous preprocessing, normalization, and structuring process. This quality allowed the models to be evaluated in a fair and comparable manner, ensuring that the results faithfully reflect the actual behavior of energy consumption in Ecuador during the period 2014–2024.

Various models were implemented and compared. The disaggregated LSTM model was the most accurate under normal conditions (2023), while BiLSTM, despite its more complex architecture, did not significantly improve its results. In extreme scenarios such as 2024, the statistical models saw their metrics deteriorate (RMSE > 170 GWh in ARIMA), while the LSTM maintained an RMSE of 158 GWh and an acceptable MAPE of 7.8%, demonstrating greater adaptability to unexpected changes.

However, based on the limitations encountered and the opportunities identified during the development of this work, the following future lines of research are proposed to improve model accuracy and strengthen energy planning through artificial intelligence:

1. Incorporation of meteorological and exogenous variables

One of the main opportunities for improvement is to integrate relevant climatic variables such as temperature, precipitation, solar radiation, and relative humidity, which directly impact energy consumption, especially in contexts highly dependent on hydroelectric generation, such as Ecuador. The incorporation of exogenous variables would allow for better capture of the influence of extreme weather events such as El Niño, thus increasing the models' ability to anticipate crisis scenarios. It would also allow for the inclusion of macroeconomic variables that can explain behavior in situations where the climate does not have high variability.

2. Application of hybrid models and modern architectures

Another line of future work consists of experimenting with hybrid models (such as ARIMA-LSTM) and advanced architecture such as Transformers or TCN (Temporal Convolutional Networks), which have demonstrated enormous potential for the analysis of complex time series. These approaches could improve the prediction accuracy and generalization capacity of the models, especially when faced with data with nonlinear patterns or erratic behavior.

3. Improving the quality and resolution of the energy dataset

A cross-cutting limitation in this work, and in many other prediction studies, is the availability and structure of the data. In this case, the available data corresponds to monthly records by province, canton, and parish, which reduces the temporal and spatial granularity of the information. Having higher resolution (daily or weekly) and better-structured time series would facilitate the training of more powerful and accurate models. In this regard, there is an urgent need for public agencies and entities in the energy sector to prioritize the collection, standardization, and release of quality data. The availability of open, up-to-date, and well-documented datasets is a critical factor for the development of artificial intelligence-based solutions that benefit both research and strategic decision-making.

REFERENCES

- [1] G. P. Zhang, "Time series forecasting using a hybrid ARIMA and neural network model," *Neurocomputing*, vol. 50, pp. 159–175, 2003.
- [2] R. J. Hyndman and G. Athanasopoulos, *Forecasting: Principles and Practice*, 3rd ed., OTexts, 2021.
- [3] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "Statistical and Machine Learning forecasting methods: Concerns and ways forward," *PLoS ONE*, vol. 13, no. 3, 2018.
- [4] M. Q. Raza, N. T. Ali, and M. S. Iqbal, "Electricity consumption forecasting using machine learning: A case study," *Energies*, vol. 14, no. 1, pp. 1–19, 2021.
- [5] H. R. Heidari, F. Mahmoudi, and M. Askarzadeh, "Electricity consumption prediction using hybrid models based on decision trees and metaheuristics," *Energy*, vol. 213, 2020.
- [6] T. Chen, C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794.
- [7] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [8] S. Kong et al., "Short-term residential load forecasting based on LSTM recurrent neural network," *IEEE Access*, vol. 7, pp. 157633–157643, 2019.
- [9] R. Rundo et al., "Bidirectional LSTM networks for accurate electricity load forecasting," *Applied Sciences*, vol. 10, no. 9, pp. 3105–3118, 2020.
- [10] J. Qin et al., "A hybrid deep learning model for load forecasting using LSTM and CNN," *Electric Power Systems Research*, vol. 189, 2020.
- [11] L. Liu et al., "An improved LSTM-based electricity load forecasting model using empirical mode decomposition," *Energies*, vol. 13, no. 8, 2020.
- [12] K. Khosravi et al., "Comparative study of ARIMA and LSTM in short-term load forecasting," *Energy Reports*, vol. 7, pp. 1996–2008, 2021.
- [13] X. Zhang et al., "Attention-based LSTM for multivariate time series forecasting," *Information Sciences*, vol. 536, pp. 246–262, 2020.
- [14] ARCONEL, "Estadísticas del Sector Eléctrico," Agencia de Regulación y Control de Electricidad, Ecuador, 2024. [En línea]. Disponible: <https://www.regulacionelectrica.gob>.

